



Pre-symptomatic detection of COVID-19 from smartwatch data

Tejaswini Mishra^{1,3}, Meng Wang^{1,3}, Ahmed A. Metwally^{1,3}, Gireesh K. Bogu^{1,3}, Andrew W. Brooks^{1,3}, Amir Bahmani^{1,3}, Arash Alavi^{1,3}, Alessandra Celli¹, Emily Higgs¹, Orit Dagan-Rosenfeld¹, Bethany Fay¹, Susan Kirkpatrick¹, Ryan Kellogg¹, Michelle Gibson¹, Tao Wang¹, Erika M. Hunting¹, Petra Mamic¹, Ariel B. Ganz¹, Benjamin Rolnik¹, Xiao Li²✉ and Michael P. Snyder¹✉

Consumer wearable devices that continuously measure vital signs have been used to monitor the onset of infectious disease. Here, we show that data from consumer smartwatches can be used for the pre-symptomatic detection of coronavirus disease 2019 (COVID-19). We analysed physiological and activity data from 32 individuals infected with COVID-19, identified from a cohort of nearly 5,300 participants, and found that 26 of them (81%) had alterations in their heart rate, number of daily steps or time asleep. Of the 25 cases of COVID-19 with detected physiological alterations for which we had symptom information, 22 were detected before (or at) symptom onset, with four cases detected at least nine days earlier. Using retrospective smartwatch data, we show that 63% of the COVID-19 cases could have been detected before symptom onset in real time via a two-tiered warning system based on the occurrence of extreme elevations in resting heart rate relative to the individual baseline. Our findings suggest that activity tracking and health monitoring via consumer wearable devices may be used for the large-scale, real-time detection of respiratory infections, often pre-symptomatically.

Early detection of infectious disease is important to mitigate the spread of disease by increasing self-isolation and early treatments. Presently, most diagnostic methods involve sampling nasal fluids, saliva or blood, followed by nucleic acid-based tests for detecting active infections or blood-based serological detection for past infections. Although they are highly sensitive, nucleic acid-based diagnostics may require samples gathered several days post-exposure for unambiguous positive detection¹. Moreover, they cannot be implemented routinely at low cost and are constrained by emerging shortages in key reagents.

Consumer wearable devices are an accurate and widely deployed technology to establish individual baseline parameters of health, which may be used to detect substantial deviations from baseline physiology at the onset of infection^{2–4}. We have previously shown that smartwatches and simple pulse oximeters can be used for the early detection of Lyme disease, and in retrospective studies, heart rate and skin temperature can be used to detect viral respiratory infections, including asymptomatic infections⁵. Wearable sensors have also been used to detect atrial fibrillation⁶. Other recent studies have shown that elevated heart rate measurements from smartwatches can be used in epidemiological studies to track the spread of respiratory viruses^{7,8}.

The use of wearable devices has ample potential to mitigate the coronavirus disease 2019 (COVID-19) pandemic. To date, the pandemic has infected tens of millions of individuals and caused over one million deaths worldwide (<https://covid19.who.int>). There is a substantial need for improved infection tracking, and population-scale technology solutions provide a promising avenue to identify cases in real time for infection detection and tracking⁹. Active infections are currently identified using PCR assays, which may require up to 3 d after infection for a reliable positive signal¹. In addition, PCR

tests are not widely used on a daily basis. Moreover, since most infections become apparent only upon symptom onset, the current methods of testing are unlikely to identify pre-symptomatic carriers, which is a considerable challenge for the implementation of early-stage interventions that reduce transmission. It is believed that as many as 50% of individuals with COVID-19 are asymptomatic, facilitating further viral spread^{10,11}. As such, accessible and inexpensive methods for the early detection of COVID-19 in real time are urgently needed.

Smartwatches and other wearable devices are already used by tens of millions of people worldwide and measure many physiological parameters, such as heart rate, skin temperature and sleep¹². Here, we investigate the use of wearable devices for the early detection of COVID-19 in a retrospective manner, and also present an approach for using wearable device-detected physiological parameters for real-time health monitoring and surveillance. Using heart rate and steps data from a large cohort of 5,262 individuals, we show that heart rate signals from fitness trackers can be used to retrospectively detect COVID-19 infection well in advance of symptom onset (offline detection). In addition, we developed an online detection algorithm to identify early stages of infection by real-time heart rate monitoring. We also examine the association between symptom type and severity, heart rate signals and the effect of infection on activity and sleep.

Results

Study design and overview. We investigated whether smartwatches could be used to detect COVID-19 at an early, pre-symptomatic stage. We enrolled a cohort of participants who had self-reported COVID-19 or other infections, as well as a wearable device capable of detecting heart rate, steps and other physiological measurements

¹Department of Genetics, Stanford University School of Medicine, Stanford, CA, USA. ²The Center for RNA Science and Therapeutics, Case Western University, Cleveland, OH, USA. ³These authors contributed equally: Tejaswini Mishra, Meng Wang, Ahmed A. Metwally, Gireesh K. Bogu, Andrew W. Brooks, Amir Bahmani, Arash Alavi. ✉e-mail: xiao.li9@case.edu; mpsnyder@stanford.edu



스마트워치 데이터를 통해 코로나19의 사전 증상 감지

Tejaswini Mishra^{1,3}, Meng Wang^{1,3}, Ahmed A. Metwally^{1,3}, Gireesh K. Bogu^{1,3}, Andrew W. Brooks^{1,3}, Amir Bahmani^{1,3}, Arash Alavi^{1,3}, Alessandra Celli¹, Emily Higgs¹, Orit Dagan-Rosenfeld¹, Bethany Fay¹, Susan Kirkpatrick¹, Ryan Kellogg¹, Michelle Gibson¹, Tao Wang¹, Erika M. Hunting¹, Petra Mamic¹, Ariel B. Ganz¹, Benjamin Rolnik¹, Xiao Li² 및 Michael P. 스나이더¹

활력 징후를 지속적으로 측정하는 소비자 웨어러블 장치는 전염병의 발병을 모니터링하는 데 사용되었습니다. 여기에서는 소비자 스마트워치의 데이터가 코로나바이러스감염증-19(COVID-19)의 증상 전 감지에 사용될 수 있음을 보여줍니다. 우리는 약 5,300명의 참가자로 구성된 코호트에서 확인된 코로나19에 감염된 32명의 개인의 생리학적 및 활동 데이터를 분석한 결과, 그 중 26명(81%)이 심박수, 일일 걸음 수 또는 수면 시간에 변화가 있는 것으로 나타났습니다. 우리가 증상 정보를 갖고 있는 생리적 변화가 감지된 25건의 코로나19 사례 중 22건은 증상 발생 전(또는 증상 발생 시)에 발견되었으며, 4건은 최소 9일 전에 발견되었습니다. 후향적 스마트워치 데이터를 사용하여, 우리는 개인 기준에 비해 안정시 심박수가 극단적으로 상승하는 발생을 기반으로 하는 2단계 경고 시스템을 통해 증상이 시작되기 전에 코로나19 사례의 63%가 실시간으로 감지될 수 있음을 보여줍니다. 우리의 연구 결과는 소비자 웨어러블 장치를 통한 활동 추적 및 건강 모니터링이 종종 증상이 나타나기 전에 호흡기 감염을 대규모로 실시간 감지하는 데 사용될 수 있음을 시사합니다.

감염병의 조기 발견은 자가 격리와 조기 치료를 통해 질병 확산을 완화하는 데 중요합니다. 현재 대부분의 진단 방법에는 콧물, 타액 또는 혈액을 채취한 후 활동성 감염을 검출하기 위한 핵산 기반 검사나 과거 감염에 대한 혈액 기반 혈청학적 검출이 포함됩니다. 매우 민감하기는 하지만 핵산 기반 진단에서는 명확한 양성 검출을 위해 노출 후 며칠 동안 샘플을 수집해야 할 수도 있습니다. 더욱이, 이는 저렴한 비용으로 일상적으로 구현될 수 없으며 주요 시약의 부족으로 인해 제약을 받고 있습니다.

소비자 웨어러블 기기는 건강의 개별 기본 매개변수를 설정하기 위해 정확하고 널리 배포된 기술입니다. 이는 감염이 시작될 때 기준 생리학에서 상당한 편차를 감지하는 데 사용될 수 있습니다²⁻⁴. 우리는 이전에 스마트워치와 간단한 맥박산소측정기를 라임병의 조기 발견에 사용할 수 있다는 것을 보여주었으며, 후향적 연구에서는 심박수와 피부 온도를 사용하여 무증상 감염을 포함한 바이러스성 호흡기 감염을 검출할 수 있음을 보여주었습니다⁵. 심박동을 감지하는 데에도 웨어러블 센서가 사용되었습니다⁶. 다른 최근 연구에 따르면 스마트워치의 높은 심박수 측정값을 역학 연구에 사용하여 호흡기 바이러스의 확산을 추적할 수 있는 것으로 나타났습니다^{7,8}.

웨어러블 장치의 사용은 코로나바이러스감염증-19(COVID-19) 전염병을 완화할 수 있는 충분한 잠재력을 가지고 있습니다. 현재까지 전염병은 전 세계적으로 수천만 명의 개인을 감염시켰고 백만 명이 넘는 사망자를 발생시켰습니다(<https://covid19.who.int>). 향상된 감염 추적에 대한 실질적인 요구가 있으며, 인구 규모 기술 솔루션은 감염 감지 및 추적을 위해 실시간으로 사례를 식별할 수 있는 유망한 방법을 제공합니다. 활성 감염은 현재 PCR 분석을 사용하여 식별되며, 신뢰할 수 있는 양성 신호를 얻으려면 감염 후 최대 3일이 필요할 수 있습니다. 또한, PCR

테스트는 매일 널리 사용되지 않습니다. 더욱이, 대부분의 감염은 증상이 시작된 후에만 명백해지기 때문에 현재의 테스트 방법으로는 증상이 나타나기 전의 보균자를 식별할 가능성이 낮습니다. 이는 전파를 줄이는 초기 단계 개입을 구현하는 데 상당한 과제입니다. 코로나19에 걸린 사람 중 최대 50%가 무증상인 것으로 추정되며, 이로 인해 추가 바이러스 확산이 촉진됩니다^{10,11}. 따라서 코로나19를 실시간으로 조기 발견할 수 있는 접근 가능하고 저렴한 방법이 시급히 필요합니다.

스마트워치 및 기타 웨어러블 장치는 이미 전 세계적으로 수천만 명의 사람들이 사용하고 있으며 심박수, 피부 온도 및 수면과 같은 다양한 생리적 매개변수를 측정합니다¹². 여기에서는 코로나19의 조기 발견을 위한 웨어러블 장치의 사용을 후향적으로 조사하고, 실시간 건강 모니터링 및 감지를 위해 웨어러블 장치로 감지된 생리적 매개변수를 사용하는 접근 방식도 제시합니다. 5,262명으로 구성된 대규모 코호트의 심박수 및 걸음 수 데이터를 사용하여 피트니스 트래커의 심박수 신호를 사용하여 증상이 시작되기 훨씬 전에 코로나19 감염을 후향적으로 감지할 수 있음을 보여줍니다(오프라인 감지). 또한 실시간 심박수 모니터링을 통해 감염 초기 단계를 식별할 수 있는 온라인 감지 알고리즘을 개발했습니다. 또한 증상 유형과 심각도, 심박수 신호, 감염이 활동과 수면에 미치는 영향 간의 연관성을 조사합니다.

결과

연구 설계 및 개요. 우리는 스마트워치를 사용하여 증상이 나타나기 전의 초기 단계에서 코로나19를 감지할 수 있는지 조사했습니다. 우리는 자가 보고된 코로나19 또는 기타 감염이 있는 참가자 집단과 심박수, 걸음 수 및 기타 생리학적 측정을 감지할 수 있는 웨어러블 장치를 등록했습니다.

¹Department of Genetics, Stanford University School of Medicine, Stanford, CA, USA. ²The Center for RNA Science and Therapeutics, Case Western University, Cleveland, OH, USA. ³These authors contributed equally: Tejaswini Mishra, Meng Wang, Ahmed A. Metwally, Gireesh K. Bogu, Andrew W. Brooks, Amir Bahmani, Arash Alavi. ✉e-mail: xiao.li9@case.edu; mpsnyder@stanford.edu




Fig. 1 | Overview of the study design, cohort and data. A total of 5,262 participants were recruited, including individuals who were: (1) sick and tested positive for COVID-19 (dark red); (2) sick and tested positive for other illnesses (dark grey); (3) sick without a confirmed diagnosis (dark grey); and (4) not sick but were at high risk of exposure (light grey). Participants were asked to log daily symptoms and to share their fitness tracker data via the study app, MyPHD. The data types collected included heart rate, steps and sleep over a period of several months. Two infection detection algorithms were developed (RHR-Diff and HROS-AD). The bottom two panels represent derived heart rate metrics from the two algorithms over a period of months in one individual, centred around the onset of symptoms (day 0). The earliest detected abnormal heart rate elevations are marked by red stars. The anomaly periods detected by RHR-Diff are spanned by red arrows. The anomaly time points detected by HROS-AD are marked by red dots. The symptom onset day and diagnosis day are indicated by vertical dashed red and purple lines, respectively.

(Fig. 1). We then examined whether physiological deviations from baseline were detected around the period of illness, as well as the detection frequency and timing of onset of the event, and associations with symptoms. Finally, we used retrospectively collected data to develop an online method for potential real-time, early detection of illness onset.

Under protocol number 55577, approved by the Stanford University Institutional Review Board, we enrolled 5,262 participants who completed surveys of illness, diagnosis and symptom dates, illness severity and symptom type (Figs. 1 and 2a and Supplementary Tables 1–5) through a secure REDCap system. Of these participants, 4,642 reported wearing a smartwatch: 3,325 wore Fitbits, 984 wore Apple watches, 428 wore a Garmin device and the remaining wore other devices (Supplementary Fig. 1). Of these, 114 individuals reported COVID-19 illness with symptom and diagnosis dates, and another 47 individuals reported a different respiratory infection with symptom and diagnosis dates for an identified pathogen. We were not able to acquire wearable device data near the symptom date from many of these. Since most people wore Fitbits, we focused on this group. Thirty-two COVID-19-positive participants (27 confirmed; see Methods) had Fitbit data spanning and adjacent to the COVID-19 disease dates, as well as symptom dates

and diagnosis dates. Four of these individuals with Fitbit devices lacked either a reported symptom date or a diagnosis date. Of note, at least five participants in our study had wearable device data but lacked measurements at or shortly after the time of infection, suggesting that some participants do not habitually wear their devices when ill (for example, participant AV2GF3B in Supplementary Fig. 3a).

We also analysed data from two classes of control individuals with Fitbit data: (1) 15 individuals with confirmed illness that was not due to severe acute respiratory syndrome coronavirus 2 (SARS-CoV-2) for whom wearable device data were available (see Methods) (one case was associated with influenza B, another was associated with rhinovirus and the remainder were of unknown cause; Supplementary Tables 3 and 4); and (2) 73 healthy individuals who did not report any illness or symptoms during the same period when we collected data from the COVID-19-positive individuals.

Abnormal resting heart rate (RHR) and heart rate-to-steps ratio are associated with COVID-19 illness. First, we determined whether abnormal physiological events are associated with SARS-CoV-2 infection and whether these can be detected using




그림 1 | 연구 설계, 코호트 및 데이터 개요. 다음과 같은 개인을 포함하여 총 5,262명의 참가자가 모집되었습니다. (2) 아프고 다른 질병에 대한 양성 반응을 보인 경우(골드); (3) 확진된 진단 없이 아픈 경우(진한 회색); (4) 아프지는 않지만 노출 위험이 높습니다(밝은 회색). 참가자들은 일일 증상을 기록하고 연구 앱인 MyPHD를 통해 피트니스 트래커 데이터를 공유하도록 요청 받았습니다. 수집된 데이터 유형에는 몇 달 동안의 심박수, 걸음 수, 수면이 포함되었습니다. 두 가지 감염 감지 알고리즘(RHR-Diff 및 HROS-AD)이 개발되었습니다. 하단 두 패널은 증상 발병(0일)을 중심으로 한 개인의 수개월 동안 두 알고리즘에서 파생된 심박수 측정항목을 나타냅니다. 가장 먼저 감지된 비정상적인 심박수 상승은 빨간색 별표로 표시됩니다. RHR-Diff가 감지한 이상 기간은 빨간색 화살표로 표시됩니다. HROS-AD가 감지한 이상 시점은 빨간색 점으로 표시됩니다. 증상 발병일과 진단일은 각각 빨간색 수직 점선과 보라색 점선으로 표시됩니다.

(그림 1). 그런 다음 질병 기간 동안 기준치로부터의 생리적 편차가 감지되었는지 여부와 사건 발생의 감지 빈도 및 시기, 증상과의 연관성을 조사했습니다. 마지막으로, 우리는 후향적으로 수집된 데이터를 사용하여 질병 발병을 실시간으로 조기에 발견할 수 있는 온라인 방법을 개발했습니다.

Stanford University Institutional Review Board에서 승인한 프로토콜 번호 55577에 따라 안전한 REDCap 시스템을 통해 질병, 진단 및 증상 날짜, 질병 심각도 및 증상 유형(그림 1 및 2a 및 보충 표 1-5)에 대한 설문조사를 완료한 5,262명의 참가자를 등록했습니다. 이들 참가자 중 4,642명이 스마트워치를 착용했다고 보고했습니다. 3,325명은 Fitbits를, 984명은 Apple Watch를, 428명은 Garmin 장치를, 나머지는 기타 장치를 착용했습니다(보충 그림 1). 이 중 114명은 증상 및 진단 날짜와 함께 COVID-19 질병을 보고했고, 또 다른 47명은 확인된 병원체에 대한 증상 및 진단 날짜와 함께 다른 호흡기 감염을 보고했습니다. 이들 중 다수에서는 증상 발생일 근처의 웨어러블 장치 데이터를 얻을 수 없었습니다. 대부분의 사람들이 Fitbit을 착용했기 때문에 우리는 이 그룹에 집중했습니다. 32명의 코로나19 양성 참가자(27명은 확인됨, 방법 참조)는 코로나19 발병 날짜 및 증상 날짜와 관련된 Fitbit 데이터를 보유하고 있었습니다.

및 진단 날짜. Fitbit 기기를 사용하는 이들 중 4명은 보고된 증상 날짜나 진단 날짜가 부족했습니다. 주목할 만한 점은 우리 연구에 참여한 최소 5명의 참가자가 웨어러블 장치 데이터를 가지고 있었지만 감염 당시 또는 직후에 측정값이 부족하여 일부 참가자가 앓을 때 습관적으로 장치를 착용하지 않는다는 것을 시사합니다(예: 보충 그림 3a의 참가자 AV2GF3B).

우리는 또한 Fitbit 데이터를 사용하여 두 그룹의 대조군 데이터를 분석했습니다. (1) 웨어러블 장치 데이터를 사용할 수 있는 중증 급성 호흡기 증후군 코로나바이러스 2(SARS-CoV-2)로 인한 것이 아닌 확인된 질병이 있는 15명의 개인(방법 참조)(한 사례는 B형 인플루엔자와 관련이 있었고 다른 사례는 라이노바이러스와 관련이 있었으며 나머지는 원인을 알 수 없었습니다. 보충 표 3 및 4); (2) 코로나19 양성자로부터 데이터를 수집한 같은 기간 동안 질병이나 증상을 보고하지 않은 건강한 사람 73명.

비정상적인 안정시 심박수(RHR)와 심박수-걸음 비율은 코로나19 질병과 관련이 있습니다. 먼저, 우리는 비정상적인 생리적 사건이 SARS-CoV-2 감염과 연관되어 있는지, 그리고 이를 다음을 사용하여 감지할 수 있는지 여부를 확인했습니다.

a smartwatch at or near the time of infection. Several parameters were investigated: elevated RHR relative to a previous healthy window; an increased heart rate relative to number of steps (that is, the RHR-to-steps ratio); and sleep (see Methods). We focused primarily on early-onset events since participants often take medications or undergo other treatments once symptomatic.

We developed two methods for detecting aberrant physiology. (1) Using the RHR difference (RHR-Diff) method, we detected and identified elevated RHR time intervals based on the standardized residuals (see Methods). The standardized residuals were constructed at 1-h resolution by comparing each interval with the average daily curve using a 28-d sliding window. We applied a non-parametric approach¹³ to test whether the sequence of standardized residuals was a homogeneous process. Using a significance level of 0.05, the elevated regions were reported as abnormal RHR periods (Supplementary Table 6). (2) Using the heart rate over steps anomaly detection (HROS-AD) method, we created a new feature known as heart rate over steps (HROS) by dividing heart rate by steps data and comparing the HROS value at each hourly interval with the rest of the intervals using Gaussian density estimation^{14,15}. We smoothed and standardized the HROS value (see Methods). Using Gaussian density estimation, we computed an anomaly score for each observation and classified them as normal (1) or an anomaly (−1) with an outlier threshold of 0.1 (see Methods and Supplementary Table 7). Analyses were performed on all of the data available for each individual, including data collected before, during and after the reported illness. A method similar to HROS-AD, the RHR anomaly detector (RHR-AD; see Methods) produced similar results (Supplementary Table 8).

Using dates of symptom onset and diagnosis to define sick periods, we then defined a sickness detection window for each individual based on the symptom onset date wherever available (14 d before to 7 d after), and the diagnosis date when the symptom date was not available (two cases). The timeframe of 14 d was chosen since this has been suggested to cover the duration of the COVID-19 incubation period in most cases^{16,17}. We scored both of our detection methods based on the interval (RHR-Diff) or HROS-AD period that overlapped with the sickness detection window. In all of the 26 individuals detected (100%; groups I and II; see below for details), we found outlying periods near the time of infection using either RHR-Diff or HROS-AD, with 22 identified using both methods (Supplementary Tables 9–12). RHR-Diff detected two high-signal regions not identified by HROS-AD, and HROS-AD detected one high-signal region not identified by RHR-Diff. Interestingly, we observed that neither method detected stable signal regions specifically at COVID-19-infected regions in six individuals, as described below.

The 32 individuals fell into three types of patterns (Supplementary Fig. 2a and Fig. 2b). Group I included 16 individuals for whom we were able to detect disease primarily as a single elevated period

or a tight cluster of elevated periods before or overlapping with the disease period. Two examples are shown in Fig. 3a,b in which we detected elevated heart rates starting 15 and 4 d before symptom onset, respectively. In cases where a tight cluster of elevated periods was observed, it is possible that the normal physiological periods reflect times of self-medication or, less likely, disease remission.

Group II comprised ten individuals and formed a cluster where we were able to detect a symptom-associated peak as well as an earlier significant heart rate elevation period within 28 d of the symptom onset based on RHR-Diff (−21/+7 d). An example is shown in Fig. 3c. In some cases, this affected our ability to clearly differentiate physiological changes associated with the COVID-19 infection since it merged with the earlier elevations in heart rate. Three of these individuals had a self-reported stress period (either illness or other), raising the possibility that the stress-associated event may have contributed to COVID-19 illness onset.

Group III consisted of the six individuals for whom a single stable elevated period could not be easily discerned at or before symptom onset; these individuals often had many signals distributed across a substantial period of time (Fig. 3d is an example) or no significant signal. Interestingly, two of these individuals had respiratory lung disease and another had severe allergies, and it is likely that these conditions and/or the pharmacological therapies used to treat them interfered with outlier detection. However, not all individuals with respiratory conditions are missed using a Fitbit; three other individuals with these conditions gave high RHR-Diff (Supplementary Fig. 3a) and HROS-AD (Supplementary Fig. 3b) signals associated with illness.

For groups I and II, the number of days between the beginning of the aberrant signal and the date of symptom onset (when available), as well as the date of diagnosis, were distributed as shown in Fig. 4a,b (Supplementary Table 13). Of the 26 detected cases, 24 had both a symptom onset date and a diagnosis date, and the remaining two cases had either one, but not both dates. In total, 88% (22 out of 25) and 100% (25 out of 25) of individuals with a symptom onset date ($n=25$ cases) or a diagnosis date ($n=25$ cases) showed elevated signals in advance or at the time of symptom onset or diagnosis, respectively. Signals were detected several days ahead of symptom onset and diagnosis, with median values of 4 and 7 d in advance, respectively. The median heart rate increase in the first period of onset was 7 beats per minute, with a broad range (Fig. 4d and Supplementary Table 14). Overall, these results indicate that altered physiology is associated with COVID-19 illness, often in advance of symptoms, and that this can be detected with a wearable device.

To determine whether the increased RHR signal was specific for COVID-19, we also analysed the 15 cases where individuals reported non-COVID-19 illness. For 14 cases in which the first symptom was reported, increased RHR was evident near symptom onset in

Fig. 2 | Association of heart rate with COVID-19 illness. **a**, Summary of data collected from 32 study participants who reported a confirmed diagnosis of COVID-19 with a symptom onset and/or test date. Each row along the y axis represents one participant, with prediction groups labelled to the left. The plot shows sick periods for COVID-19 (between black arrows, with dashed lines for unknown bounds where the symptom onset or recovery day was unclear), COVID-19 test dates (red crosses), sick periods for other illnesses (between orange arrows) and the days for which participants filled in the daily survey (diamonds), with purple diamonds representing days when symptoms were reported and blue diamonds representing days when symptoms were not reported. **b**, Overlapping bar plots depicting heart rate metrics and timings of infection detection from RHR-Diff and HROS-AD with respect to the infection detection window for COVID-19-positive participants. The plots are manually grouped into three groups: group I (single region; blue); group II (early and multiple regions; red); and group III (other; gold), focusing mainly on the single-region group. One additional participant who reported a diagnosis of influenza B is also shown for comparison (purple). Summary plots for all COVID-19-positive participants from all three groups are shown in Supplementary Fig. 2a, and all participants with other illnesses are shown in Supplementary Fig. 2b. The x axis shows days during the infection detection window and the y axis shows standardized residual values from RHR-Diff (brown bars) and standardized (0 to −1) HROS values from HROS-AD (transparent green bars) in the intervals during which COVID-19 infection was detected by each algorithm. These values are plotted separately for each participant. This window is a period of time centred around symptom onset at day 0 (substituted by the diagnosis day wherever the day of symptom onset was unavailable). The infection detection window spans a period of 15 d before day 0 and 7 d after day 0.

감염 당시 또는 감염 당시 스마트워치. 몇 가지 매개변수가 조사되었습니다. 이전의 정상 창에 비해 RHR이 증가했습니다. 걸음 수에 비해 심박수가 증가합니다(즉, RHR 대 걸음 비율). 및 수면(방법 참조). 참가자들은 종종 증상이 나타나면 약을 복용하거나 다른 치료를 받기 때문에 우리는 주로 초기 발병 사례에 중점을 두었습니다.

우리는 비정상적인 생리를 탐지하는 두 가지 방법을 개발했습니다. (1) RHR 차이(RHR-Diff) 방법을 사용하여 표준화된 잔차를 기반으로 증가된 RHR 시간 간격을 감지하고 식별했습니다(방법 참조). 표준화된 잔차는 28일 슬라이딩 윈도우를 사용하여 각 간격을 평균 일일 곡선과 비교하여 1시간 해상도로 구성되었습니다. 우리는 표준화된 잔차의 시퀀스가 동종 프로세스인지 테스트하기 위해 비모수적 접근 방식을 적용했습니다. 0.05의 유의 수준을 사용하여 상승된 영역은 비정상적인 RHR 기간으로 보고되었습니다(보충 표 6). (2) HROS-AD(심박수 이상 감지) 방법을 사용하여 심박수를 걸음 수 데이터로 나누고 가우스 밀도 추정^{14,15}을 사용하여 각 시간 간격의 HROS 값을 나머지 간격과 비교하여 HROS(심박수 초과 심박수)라는 새로운 기능을 만들었습니다. HROS 값을 평활화하고 표준화했습니다(방법 참조). 가우스 밀도 추정을 사용하여 각 관측값에 대한 이상 점수를 계산하고 이상점 임계값이 0.1인 정상(1) 또는 이상(-1)으로 분류했습니다(방법 및 보충 표 7 참조). 보고된 질병 이전, 도중, 이후에 수집된 데이터를 포함하여 각 개인에 대해 이용 가능한 모든 데이터에 대한 분석이 수행되었습니다. HROS-AD와 유사한 방법인 RHR 이상 탐지기(RHR-AD, 방법 참조)는 유사한 결과를 생성했습니다(보충 표 8).

증상 발생 날짜와 진단 날짜를 사용하여 질병 기간을 정의한 다음 가능한 경우 증상 발생 날짜(14일 전 ~ 7일 후)와 증상 날짜를 확인할 수 없는 진단 날짜(2건)를 기준으로 개인별 질병 감지 창을 정의했습니다. 대부분의 경우에 코로나19 잠복기 기간을 포괄하는 것으로 제안되었기 때문에 14일이라는 기간이 선택되었습니다^{16,17}. 질병 감지 창과 겹치는 간격(RHR-Diff) 또는 HROS-AD 기간을 기반으로 두 가지 감지 방법 모두 점수를 매겼습니다. 감지된 26명의 개인 모두(100%, 그룹 I 및 II, 자세한 내용은 아래 참조)에서 RHR-Diff 또는 HROS-AD를 사용하여 감염 시점 근처의 외곽 기간을 발견했으며, 두 방법을 모두 사용하여 22명이 식별되었습니다(보충 표 9-12). RHR-Diff는 HROS-AD로 식별되지 않은 두 개의 고신호 영역을 감지했으며, HROS-AD는 RHR-Diff로 식별되지 않은 하나의 고신호 영역을 감지했습니다. 흥미롭게도 우리는 아래 설명된 대로 두 방법 모두 특히 6명의 개인의 코로나19 감염 지역에서 안정적인 신호 영역을 감지하지 못하는 것을 관찰했습니다.

32명의 개인은 세 가지 유형의 패턴에 속했습니다(보조 그림 2a 및 그림 2b). 그룹 I에는 주로 단일 상승 기간으로 질병을 감지할 수 있는 16명의 개인이 포함되었습니다.

또는 질병 기간 이전 또는 질병 기간과 겹치는 높은 기간의 밀집된 클러스터입니다. 그림 3a,b에는 증상 발병 전 각각 15일과 4일에 심박수가 상승한 것을 감지한 두 가지 예가 나와 있습니다. 상승된 기간이 밀집되어 관찰된 경우, 정상적인 생리적 기간은 자가 투약 시간 또는 질병 완화 시간을 반영할 가능성이 있습니다.



그룹 II는 10명의 개인으로 구성되었으며 RHR-Diff(-21/+7d)를 기반으로 증상 발생 28일 이내에 증상 관련 최고점과 초기의 상당한 심박수 상승 기간을 감지할 수 있는 클러스터를 형성했습니다. 예가 그림 3c에 나와 있습니다. 어떤 경우에는 이것이 코로나19 감염과 관련된 생리적 변화가 초기 심박수 상승과 합쳐졌기 때문에 명확하게 구별하는 능력에 영향을 미쳤습니다. 이들 중 3명은 스스로 스트레스 기간(질병 또는 기타)을 겪었다고 보고했으며, 이는 스트레스 관련 사건이 코로나19 발병에 영향을 미쳤을 가능성을 높입니다.


그룹 III은 증상 시작 시 또는 그 이전에 안정적인 단일 상승 기간을 쉽게 식별할 수 없는 6명의 개인으로 구성되었습니다. 이러한 개인은 상당한 기간 동안 많은 신호가 분산되어 있거나(그림 3d가 예) 중요한 신호가 없는 경우가 많습니다. 흥미롭게도 이들 중 두 명은 호흡기 폐 질환이 있었고 다른 한 명은 심각한 알레르기가 있었으며 이러한 상태 및/또는 그들을 치료하는 데 사용된 약리학적 치료법이 이상값 탐지를 방해했을 가능성이 있습니다. 그러나 호흡기 질환이 있는 모든 개인이 Fitbit 사용을 놓치는 것은 아닙니다. 이러한 조건을 가진 다른 세 명의 개인은 질병과 관련된 높은 RHR-Diff(보조 그림 3a) 및 HROS-AD(보충 그림 3b) 신호를 나타냈습니다.

그룹 I과 II의 경우, 이상 신호의 시작과 증상 발병 날짜(가능한 경우) 사이의 일수와 진단 날짜가 그림 4a,b(보충 표 13)에 표시된 대로 분포되었습니다. 발견된 26건 중 24건은 증상 발생 날짜와 진단 날짜가 모두 있었고, 나머지 2건은 둘 중 하나지만 둘 다 날짜는 없었습니다. 전체적으로 증상 발생 날짜($n = 25$ 건) 또는 진단 날짜($n = 25$ 건)가 있는 개인의 88%(25명 중 22명)와 100%(25명 중 25명)가 각각 사전 또는 증상 발생 또는 진단 시에 상승된 신호를 보였습니다. 증상 발병 및 진단 며칠 전에 신호가 감지되었으며, 중앙값은 각각 4일과 7일이었습니다. 발병 첫 번째 기간의 평균 심박수 증가는 분당 7회였으며 범위가 넓습니다(그림 4d 및 보충 표 14). 전반적으로, 이러한 결과는 변화된 생리학이 종종 증상이 나타나기 전에 코로나19 질병과 연관되어 있으며, 이는 웨어러블 장치로 감지될 수 있음을 나타냅니다.

증가된 RHR 신호가 코로나19에 특정한 것인지 확인하기 위해 우리는 개인이 코로나19가 아닌 질병을 보고한 15건의 사례도 분석했습니다. 첫 번째 증상이 보고된 14건의 경우, RHR의 증가는 증상 발생 근처에서 분명했습니다.

Fig. 2 | Association of heart rate with COVID-19 illness. **a**, Summary of data collected from 32 study participants who reported a confirmed diagnosis of COVID-19 with a symptom onset and/or test date. Each row along the y axis represents one participant, with prediction groups labelled to the left. The plot shows sick periods for COVID-19 (between black arrows, with dashed lines for unknown bounds where the symptom onset or recovery day was unclear), COVID-19 test dates (red crosses), sick periods for other illnesses (between orange arrows) and the days for which participants filled in the daily survey (diamonds), with purple diamonds representing days when symptoms were reported and blue diamonds representing days when symptoms were not reported. **b**, Overlapping bar plots depicting heart rate metrics and timings of infection detection from RHR-Diff and HROS-AD with respect to the infection detection window for COVID-19-positive participants. The plots are manually grouped into three groups: group I (single region; blue); group II (early and multiple regions; red); and group III (other; gold), focusing mainly on the single-region group. One additional participant who reported a diagnosis of influenza B is also shown for comparison (purple). Summary plots for all COVID-19-positive participants from all three groups are shown in Supplementary Fig. 2a, and all participants with other illnesses are shown in Supplementary Fig. 2b. The x axis shows days during the infection detection window and the y axis shows standardized residual values from RHR-Diff (brown bars) and standardized (0 to -1) HROS values from HROS-AD (transparent green bars) in the intervals during which COVID-19 infection was detected by each algorithm. These values are plotted separately for each participant. This window is a period of time centred around symptom onset at day 0 (substituted by the diagnosis day wherever the day of symptom onset was unavailable). The infection detection window spans a period of 15 d before day 0 and 7 d after day 0.








Fig. 3 | Examples of heart rate metrics during COVID-19 illness. a–d, Examples of heart rate metrics during COVID-19 infection for four individual participants, two from group I (**a** and **b**) and one each from group II (**c**) and group III (**d**). Red and purple vertical dashed lines indicate the days of symptom onset and diagnosis, respectively. Shown are the standardized HROS from the HROS-AD method (bottom plot in each panel; dark blue lines) and the standardized heart rate residuals from the RHR-Diff method (top plot in each panel; black lines). For RHR-Diff, the green dashed line is at 0. Gold solid triangles mark the infection detection window used to score detections as a hit or a miss. Also indicated are time intervals when the heart rate residuals were significantly elevated from RHR-Diff (red arrows in the top plots of each panel) and times when anomalies were detected by HROS-AD (red dots in the bottom plots of each panel).

nine instances; moreover, in these nine cases, increased RHR was apparent before or at the time of symptom onset (Supplementary Figs. 2b and 3a,b and Supplementary Tables 6 and 15–17). One example for an influenza B infection is shown in Fig. 2b. The median time of signal onset relative to symptoms was 2 d (Fig. 4c). These results indicate that the elevated heart rates that occur before disease also provide utility as a general signal of respiratory illness, consistent with our previous results⁵.

Sleep and activity alterations associated with COVID-19 illness. Having established aberrant physiological signals associated with COVID-19 illness, we investigated whether COVID-19 also affected behaviour, specifically steps and sleep duration (Fig. 5a–d and Supplementary Tables 18–23; see Methods). Although Fitbit devices are not considered gold standards for many sleep parameters, they most accurately measure sleep duration and are widely used^{18,19}. They are less accurate for the sleep stages (for example,




그림 3 | 코로나19 질병 중 심박수 지표의 예. a-d, 그룹 I(a 및 b)의 2명, 그룹 II(c) 및 그룹 III(d)의 각 1명, 총 4명의 개별 참가자에 대한 COVID-19 감염 중 심박수 지표의 예. 빨간색과 보라색 수직 점선은 각각 증상 발병일과 진단일을 나타냅니다. HROS-AD 방법의 표준화된 HROS(각 패널의 하단 플롯, 진한 파란색 선)와 RHR-Diff 방법의 표준화된 심박수 잔차(각 패널의 상단 플롯, 검은색 선)가 표시됩니다. RHR-Diff의 경우 녹색 점선은 0입니다. 금색 실선 삼각형은 감지 항목의 적중 또는 실패 점수를 매기는 데 사용되는 감염 감지 창을 표시합니다. 또한 RHR-Diff(각 패널의 상단 플롯에 있는 빨간색 화살표)에서 심박수 잔차가 크게 증가한 시간 간격과 HROS-AD에 의해 이상이 감지된 시간(각 패널의 하단 플롯에 있는 빨간색 점)도 표시되어 있습니다.

9개의 경우; 또한, 이 9개 사례에서 RHR 증가는 증상 발병 전이나 증상 발생 시에 명백히 나타났습니다(보충 그림 2b 및 3a,b 및 보충 표 6 및 15-17). B형 인플루엔자 감염의 한 예가 그림 2b에 나와 있습니다. 증상과 관련된 신호 발생 시간의 중앙값은 2일이었습니다(그림 4c). 이러한 결과는 질병 이전에 발생하는 심박수 증가가 이전 결과와 일치하는 호흡기 질환의 일반적인 신호로서 유용성을 제공한다는 것을 나타냅니다⁵.

COVID-19 질병과 관련된 수면 및 활동 변화. 코로나19 질병과 관련된 비정상적인 생리학적 신호를 확인한 후, 우리는 코로나19가 행동, 특히 걸음 수와 수면 시간에도 영향을 미치는지 여부를 조사했습니다(그림 5a-d 및 보충 표 18-23, 방법 참조). Fitbit 기기는 많은 수면 매개변수에 대한 최적의 표준으로 간주되지 않지만 수면 시간을 가장 정확하게 측정하며 널리 사용됩니다^{18,19}. 수면 단계에서는 정확도가 떨어집니다(예:


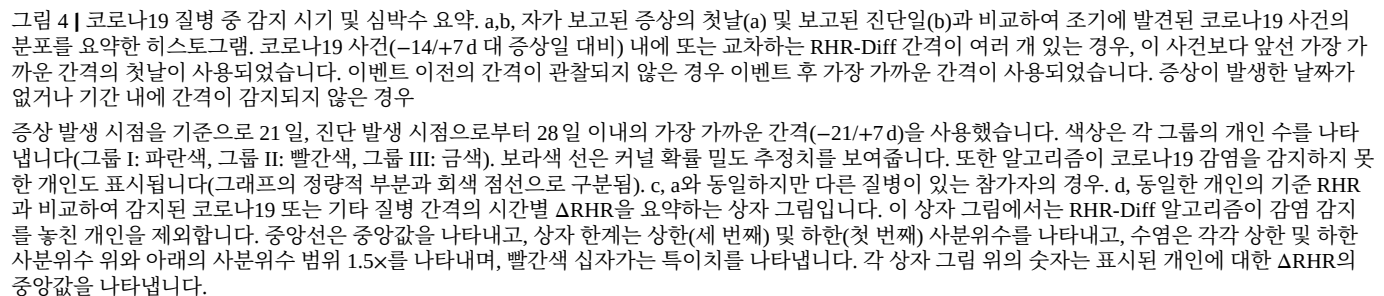


Fig. 4 | Summary of detection timing and heart rate during COVID-19 illness. **a, b,** Histograms summarizing the distribution of early-detected COVID-19 events compared with the first day of self-reported symptoms (**a**) and the reported diagnosis day (**b**). If multiple RHR-Diff intervals existed within or intersecting the COVID-19 event ($-14/+7$ d versus the symptom day), the first day of the closest interval ahead of this event was used. If no interval before the event was observed, the closest interval after the event was used. If the symptom day was not available or there was no interval detected within the 21 d surrounding the symptom onset, the closest interval within 28 d of the diagnosis onset ($-21/+7$ d) was used. The colours represent the number of individuals in each group (group I: blue; group II: red; group III: gold). The purple line shows the kernel probability density estimate. Also shown are individuals for whom the algorithm missed detecting COVID-19 infection (separated from the quantitative part of the graph by grey dashed lines). **c,** As in **a**, but for participants with other illnesses. **d,** Boxplots summarizing the hourly ΔRHR of the detected COVID-19 or other illness interval compared with the baseline RHR of the same individual. These boxplots exclude individuals for whom the RHR-Diff algorithm missed detecting infection. Central lines represent median values, box limits represent upper (third) and lower (first) quartiles, whiskers represent $1.5 \times$ the interquartile range above and below the upper and lower quartiles, respectively, and red crosses represent outliers. The number above each boxplot represents the median value of ΔRHR for the indicated individual.

rapid eye movement (REM) and deep sleep) and this was not pursued. We examined the parameters reported by the manufacturer (see Methods) and found that steps (with missing data imputation and without) significantly decreased at the onset of the outlying RHR-Diff signal associated with COVID-19 illness (linear mixed model (LMM); $P = 8.71 \times 10^{-33}$; Fig. 5a,b and Supplementary Fig. 4a). Sleep duration significantly increased after the onset of the outlying RHR-Diff signal, but only with missing data imputation (LMM; $P = 0.003$; Fig. 5c,d and Supplementary Fig. 4b). These results indicate that COVID-19 illness alters steps and sleep patterns, which can be tracked using a wearable device.

Association between heart rate signals and symptoms. A subset of participants filled out daily logs before or during their COVID-19 illness, providing a detailed time course of symptom severity, progression and relapse (Fig. 6a–d), while others filled out detailed past illness surveys that summarized their symptoms over the entire illness period (Fig. 6e). The first individual, APGIB2T, (Fig. 6a) had an early RHR-Diff signal 1 week before symptom onset. The disease progressed quickly into severe diarrhoea, fatigue, headaches, elevated temperature and positive COVID-19, peaking in sever-

ity and then declining over 2 weeks. In total, 18 d of initial illness were followed by 12 d when the participant felt recovered, before a relapse characterized by elevated temperature, fatigue, diarrhoea and elevated heart metric signals. A second participant, AQC0L71, (Fig. 6b) began daily logs when symptoms developed, reporting a 22-d period of mild-to-moderate coughing, fatigue and aches and pains that was anticipated by both the RHR-Diff and HROS-AD heart rate metrics. Symptoms then deteriorated rapidly, coupled with abnormal physiological signals suggested by both algorithms, elevated temperature and a positive COVID-19 test. The participant was admitted to hospital 5 days later and the time from symptom onset to recovery was 41 d. A third participant, AOVFT1N, reported COVID-19 illness lasting 13 d (Fig. 6c) that was led by an RHR-Diff alarm, followed by ongoing symptoms of fatigue and occasional chest pains. Heart rate metrics alarms accompanied the return of shortness of breath, for which the participant was hospitalized 35 d after initial symptom onset. Daily logs began at symptom onset for A1K5DRI, the fourth participant (Fig. 6d), 3 d after an RHR-Diff alarm. Illness progressed over 23 d, with a rapid rise in temperature and HROS-AD alarms accompanied by severe fatigue, aches and pains and slow recovery.



심박수 신호와 증상 사이의 연관성. 참가자 중 일부는 증상 심각도, 진행 및 재발에 대한 자세한 시간 경과를 제공하면서 코로나 19 질병 전이나 도중에 일일 기록을 작성했으며(그림 6a-d), 다른 참가자는 전체 질병 기간 동안 증상을 요약하는 상세한 과거 질병 설문조사를 작성했습니다(그림 6e). 첫 번째 개인인 APGIB2T(그림 6a)는 증상이 시작되기 1주 전에 초기 RHR-Diff 신호를 보였습니다. 이 질병은 심한 설사, 피로, 두통, 발열 및 코로나19 양성 반응으로 빠르게 진행되었으며,

그러다가 2주에 걸쳐 감소합니다. 전체적으로, 초기 질병 18일 후 참가자가 회복되었다고 느꼈을 때 12일이 뒤따랐고, 발열, 피로, 설사 및 심장 측정 신호 상승을 특징으로 하는 재발이 발생했습니다. 두 번째 참가자인 AQ00L71(그림 6b)은 증상이 나타날 때 일일 기록을 시작하여 RHR-Diff 및 HROS-AD 심박수 측정항목 모두에서 예상되는 경증 내지 중등도 기침, 피로, 통증 및 통증의 22일 기간을 보고했습니다. 그 후 두 알고리즘에서 제안된 비정상적인 생리적 신호, 발열 및 양성 코로나19 테스트와 함께 증상이 빠르게 악화되었습니다. 참가자는 5일 후 병원에 입원하였고, 증상 발현부터 회복까지의 시간은 41일이었습니다. 세 번째 참가자인 A0VFT1N은 RHR-Diff 경보로 인해 13일 동안 지속된 COVID-19 질병(그림 6c)과 이어서 계속되는 피로 증상과 가끔 가슴 통증이 나타났다고 보고했습니다. 심박수 지표 알람은 호흡 곤란의 재발을 동반했으며, 이로 인해 참가자는 초기 증상 발병 후 35일에 입원했습니다. 일일 로그는 RHR-Diff 경보 3일 후, 네 번째 참가자(그림 6d)인 A1K5DRI의 증상 발병 시점에 시작되었습니다. 질병은 23일에 걸쳐 진행되었으며 온도가 급격하게 상승하고 HROS-AD 경보가 발생하며 심한 피로, 통증 및 느린 회복을 동반했습니다.




Fig. 5 | Summary of steps and sleep during COVID-19 illness. a, Heatmap showing standardized daily steps per participant (that is, z scores of daily steps) for the 22 participants we have steps data for, and for whom RHR-Diff detected a change of RHR any day between 14 d before the symptom onset date and 2 d after. Tile colours indicate the z score and asterisks represent the first day of detection for each participant. **b,** Boxplot showing the change in daily steps between days before and after the detection start date in a window of -21 d before to +7 d after the symptom onset date. **c,** Heatmap showing the standardized sleep duration per participant (that is, z scores of total sleep duration) for the 13 participants we have sleep data for and for whom RHR-Diff detected a change of RHR any day between 14 d before the symptom onset date and 2 d after. **d,** Boxplot showing the change in total sleep duration between days before and after the detection start date in a window of -21 d before to +7 d after the date of symptom onset. For the heatmaps in **a** and **c**, black rectangles highlight the period after symptom onset. The boxplots in **b** and **d** include data with imputation (see Methods). Data without imputation are shown in Supplementary Figs. 4a,b. For both **b** and **d**, central lines represent median values, box limits represent upper (third) and lower (first) quartiles and whiskers represent 1.5x the interquartile range above and below the upper and lower quartiles, respectively.

Lastly, in addition to the daily survey, we also examined symptoms reported post-illness (that is, retrospectively). In this limited sample, we did not detect any obvious association between the magnitude of RHR differences during alarm periods and symptom type or number, illness length or temperature (Fig. 6e). Overall, at the individual level, COVID-19 progression and severity were generally concordant with heart rate metrics, but these cases highlight temporal and individual variation more widely observed with the illness^{11,20}.

An approach to detect early COVID-19 onset in real time. The ability to detect altered physiology in advance of symptoms raises the possibility that an online method can be developed to detect early stages of COVID-19 illness in advance of symptoms using a

smartwatch. To test this possibility, we developed an online detection method called CuSum (see Methods). This detection was based on cumulative statistics^{21–23} that cumulate the deviations of the elevated residual RHRs. The test statistics from the previous 28 d of baseline records built an empirical null distribution.

We report a warning alarm as the first time we observed a test statistic more extreme compared with the null distribution, with a *P* value generated from comparing the current test statistics with the baseline measurements. To reduce the number of alarms, a two-tiered warning system was developed. The first time the *P* value was less than 0.01 (usually in the first few hours), an initial warning alarm (yellow alert) signalled. Monitoring continued, and if it remained elevated over 24 h, it signalled a positive event (red alert; see Methods).




그림 5 | 코로나19 질병 중 단계 및 수면 요약. a, 참가자당 표준화된 일일 걸음 수(즉, 일일 걸음 수의 z 점수)를 보여주는 히트맵. 22명의 참가자에 대한 걸음수 데이터가 있으며 RHR-Diff는 증상 발생일 14d 전과 2일 후 사이에 RHR 변화를 감지했습니다. 타일 색상은 z 점수를 나타내고 별표는 각 참가자의 감지 첫 번째 날을 나타냅니다. b, 증상 발생일 이전 -21d부터 증상 발생일 이후 +7d까지의 기간에서 감지 시작일 전후 일 수 변화를 보여주는 상자 그림. c, RHR-Diff가 증상 발생 날짜 전 14d와 그 후 2d 사이에 RHR 변화를 감지한 13명의 참가자에 대한 참가자당 표준화된 수면 시간(즉, 총 수면 시간의 z 점수)을 보여주는 히트맵입니다. d, 증상 발생일 이후 +7d 이전의 -21d 기간에서 감지 시작일 전후의 총 수면 시간 변화를 보여주는 상자 그림. a와 c의 히트맵의 경우 검정색 직사각형은 증상 발병 후 기간을 강조 표시합니다. b와 d의 상자 그림에는 대치된 데이터가 포함됩니다(방법 참조). 대치되지 않은 데이터는 보충 그림에 표시됩니다. 4a,b, b와 d 모두에 대해 중앙선은 중앙값을 나타내고 상자 한계는 상한(세 번째) 및 하한(첫 번째) 사분위수를 나타내고 수염은 각각 상한 및 하한 사분위수 위와 아래의 사분위수 범위 1.5x를 나타냅니다.

마지막으로 일일 조사 외에 질병 후 보고된 증상에 대해서도(즉, 회고적으로) 조사했습니다. 이 제한된 샘플에서는 경보 기간 동안 RHR 차이의 크기와 증상 유형 또는 수, 질병 기간 또는 온도 사이의 명확한 연관성을 발견하지 못했습니다(그림 6e). 전반적으로, 개인 수준에서 코로나19 진행 및 중증도는 일반적으로 심박수 지표와 일치했지만, 이러한 사례는 질병과 함께 더 광범위하게 관찰되는 시간적 및 개인별 변화를 강조합니다.^{11,20}

코로나19 초기 발병을 실시간으로 감지하는 접근 방식입니다. 증상이 나타나기 전에 변경된 생리학을 감지하는 능력은 증상이 나타나기 전에 코로나19 질병의 초기 단계를 감지하는 온라인 방법을 개발할 수 있는 가능성을 높입니다.

스마트워치. 이 가능성을 테스트하기 위해 CuSum이라는 온라인 감지 방법을 개발했습니다(방법 참조). 이 탐지는 상승된 잔여 RHR의 편차를 누적하는 누적 통계²¹⁻²³를 기반으로 했습니다. 이전 28일 기준 기록의 테스트 통계는 경험적 null 분포를 구축했습니다.

현재 테스트 통계를 기준 측정값과 비교하여 생성된 p 값을 사용하여 null 분포에 비해 더 극단적인 테스트 통계를 처음으로 관찰했을 때 경고 경보를 보고합니다. 경고 횟수를 줄이기 위해 2단계 경고 시스템이 개발되었습니다. 처음 P 값이 0.01 미만일 때(보통 처음 몇 시간 동안) 초기 경고 경보(노란색 경보)가 울렸습니다. 모니터링이 계속되었으며 24시간 이상 상승된 상태로 유지되면 긍정적인 이벤트 신호를 보냅니다(빨간색 경보, 방법 참조).

We tested this method initially on four individuals for whom we had collected >6 months of wearable device data (Fig. 7a,b, Supplementary Fig. 5 and Supplementary Table 24). In addition to the annotated COVID-19 infection, other strong elevated signals were identified, as well as smaller signals. Some of these corresponded to annotated infections. Others were not annotated but occurred at periods that might be associated with increased heart rate. For example, three of the four individuals had high heart rates in the November to December holiday period ('holiday bump', Fig. 7b and Supplementary Fig. 5), which is commonly associated with air travel, alcohol and stress, as well as illness. A number of alarms of lower duration or signal were also observed.

We also examined 24 individuals who had at least 28 d of data ahead of symptom onset (Supplementary Fig. 3a and Supplementary Table 25). In total, 62.5% (15/24) had an alarm on or before COVID-19 symptom onset using the CuSum alarm model. Four more people had an alarm 1 d after self-reported symptoms. Of the remainder, two individuals had previously been missed in offline detection and three had respiratory illnesses that had been difficult to detect in our initial retrospective study. As shown in Fig. 7e, 11 individuals had non-COVID-19 alarms before COVID-19 infections ranging from 0.14 to 1 alarms per month. Interestingly, the number of alarms increased considerably post-COVID-19 infection, suggesting the possibility of lingering physiological sequelae of COVID-19 illness (Fig. 7e and Supplementary Table 26).

We compared our online detection results with those observed using the RHR-Diff approach and found overall good agreement (either less than 1 d difference or both missed) in 13 of the cases (Fig. 7f and Supplementary Table 27). However, one case was only detected using the online CuSum approach and another was only detected by the RHR-Diff approach (this individual had a pre-existing chronic respiratory condition. Nine cases were detected 2–6 d later than offline (see Supplementary Fig. 3a for examples). RHR-Diff is more sensitive since it detects significant intervals based on the global dataset, whereas the detection by CuSum was solely based on the data received in advance of infection.

As controls, we used the CuSum online detection method to examine wearable device data for: (1) the 73 individuals who did not report illness during the same period as the COVID-19-positive individuals; and (2) the 13 individuals with 15 non-COVID-19 illnesses (Supplementary Table 25; examples in Fig. 7c,d). The healthy individuals also had alarms (Fig. 7d and Supplementary Fig. 6), although the alarm durations and peaks were generally shorter and smaller, respectively, than those of the COVID-19 and other illnesses (Fig. 7g,h and Supplementary Table 28). There were also signals that were similar to those for infections, possibly representing asymptomatic illnesses. The holiday bump was also observed in one of three other individuals whose data covered

that period. The 15 individuals with other illnesses gave a signal at or before the illness in nine of 15 cases (Supplementary Fig. 3a). The presence of alarms was expected during healthy periods for all individuals, since the alarming method was set to identify signals that lay near the end of the normal distribution; these will have occurred by statistical chance, as well as by triggers other than the identified illness.

Discussion

From a sizable cohort, we identified a number of individuals who tested positive for COVID-19 and other illnesses and who wore a smartwatch. Using these data, we developed algorithms that detected elevated RHRs and outlying heart rate/steps measurements, usually in advance of symptoms. The early times of detection were generally consistent with the latent period of pre-symptomatic illness reported previously¹⁰. In two group I individuals, the signal was observed nine or more days preceding symptoms. Because the actual timing of infection in these cases was not known, it is possible that these and other events represented early stress events that merged into the COVID-19 illness (for example, Fig. 6b). Indeed, in ten group II individuals, a discrete early event was observed, and in three individuals, this was associated with a self-reported illness or family stress event. It is possible that early stress events increased individuals' vulnerability to COVID-19, resulting in illness.

We used the information learned from the retrospective analysis to design a prototype approach for the real-time, early detection of COVID-19 illness (CuSum). In addition to detection of the COVID-19 events, other events were identified, of which some probably reflect illnesses, including asymptomatic cases, as we observed previously⁵. Many of the other events could reflect situations that stimulate sustained increased heart rate, such as medication, alcohol, travel and emotional or other stress inducers. Indeed, four of seven cases with data covering the December holidays showed significant elevations of long duration. Those events short in duration (for example, due to watching a scary movie) will probably go off after a brief period of time. Thus, using our proposed two-tiered continuous alarm system, early events can be acted on by self-isolation and, if an increased signal ensues, can be escalated to physician consultation and/or direct viral diagnostics. The alarming parameters can also be adjusted to increase or decrease sensitivity with a concomitant increase or decrease in the number of alarms. This adjustment may be valuable depending on the person's preference or risk. In the version presented here, we were able to detect 63% of known COVID-19 infections with an alarming frequency of 0.66 per month in the healthy individuals; 63% is likely to be an overestimate for COVID-19 as asymptomatic cases are not accounted for, but an underestimate for all infections as many signals may represent such illnesses (both unreported symptomatic and asymptomatic).

Fig. 6 | Association of COVID-19 symptoms with heart rate signal. a–d, Plots of four individual participants (APGIB2T (a), AQC0L71 (b), AOVFT1N (c) and A1K5DRI (d)) over the course of COVID-19 infection. Vertical columns along the x axes each represent a single day of symptoms (from early illness (leftmost) to late illness) and are aligned with the heart rate metrics below. Columns showing symptoms are only present for the days when the daily survey was completed, while heart rate metrics progress continually below. 'Overall feeling' indicates how the participants reported feeling on a particular day, with a bar plot above indicating the measured temperature if reported, and specific symptoms highlighted below as a heatmap depicting the severity. Black vertical lines below the symptoms and descending into the heart rate metrics are labelled to highlight significant days during the illness course, and align with the symptoms above. The RHR-Diff plots show standardized heart rate residuals from RHR-Diff (black lines) and time intervals when the heart rate residuals were significantly elevated (red lines with arrowheads). The bottom plots in each panel show standardized HROS using the HROS-AD method (black line), and each detected anomaly is indicated by a red oval. **e,** Summary of symptoms data for individuals who provided surveys on a past COVID-19 illness. Each column represents a study participant, as labelled below. Shown are (from top to bottom): a bar plot of average temperatures in °C reported during illness; overall feelings (see legend above); total duration between reported symptom onset and recovery (if provided); a boxplot (showing numerical median values) of Δ RHR in beats per minute when heart rate residual alarms were raised; and a plot of individual symptoms (where black boxes indicate reported symptoms and white boxes indicate no reported symptoms). For the boxplot, central lines represent median values, box limits represent the upper (third) and lower (first) quartiles, the whiskers represent 1.5 $\times$ the interquartile range above and below the upper and lower quartiles, respectively, and red crosses are outliers.

우리는 처음에 >6개월 간의 웨어러블 기기 데이터를 수집한 4명의 개인을 대상으로 이 방법을 테스트했습니다(그림 7a,b, 보충 그림 5 및 보충 표 24). 주석이 달린 코로나19 감염 외에도 다른 강력한 상승 신호와 더 작은 신호가 확인되었습니다. 이들 중 일부는 주석이 달린 감염에 해당합니다. 다른 것들은 주석을 달지 않았지만 심박수 증가와 연관될 수 있는 기간에 발생했습니다. 예를 들어, 4명 중 3명은 11월부터 12월까지 휴가 기간(휴가 범프; 그림 7b 및 보충 그림 5)에 높은 심박수를 보였으며 이는 일반적으로 항공 여행, 알코올, 스트레스 및 질병과 관련이 있습니다. 더 낮은 지속 시간이나 신호의 여러 정보도 관찰되었습니다.

또한 증상 발병 전 최소 28일의 데이터를 보유한 24명의 개인을 조사했습니다(보충 그림 3a 및 보충 표 25). 전체적으로 62.5%(15/24)가 CuSum 경보 모델을 사용하여 COVID-19 증상 발병 시 또는 그 이전에 경보를 받았습니다. 증상을 자가 보고한 지 1일 후에 4명이 더 알람을 받았습니다. 나머지 중 2명은 이전에 오프라인 감지에서 누락되었으며 3명은 초기 후향적 연구에서 감지하기 어려웠던 호흡기 질환을 앓고 있었습니다. 그림 7e에서 볼 수 있듯이, 11명의 개인은 코로나19 감염 이전에 월 0.14~1개의 알람 범위에서 비COVID-19 알람을 받았습니다. 흥미롭게도, 경보 건수는 코로나19 감염 이후 상당히 증가했으며, 이는 코로나19 질병의 생리학적 후유증이 지속될 가능성을 시사합니다(그림 7e 및 보충 표 26).

우리는 온라인 감지 결과를 RHR-Diff 접근 방식을 사용하여 관찰한 결과와 비교했으며 13개 사례에서 전반적으로 좋은 일치(1d 미만 차이 또는 둘 다 누락)를 발견했습니다(그림 7f 및 보충 표 27). 그러나 한 사례는 온라인 CuSum 접근 방식을 통해서만 감지되었고 다른 사례는 RHR-Diff 접근 방식에 의해서만 감지되었습니다(이 개인은 기존 만성 호흡기 질환을 가지고 있었습니다. 9개 사례는 오프라인보다 2-6d 늦게 감지되었습니다(예를 보려면 보충 그림 3a 참조). RHR-Diff는 글로벌 데이터 세트를 기반으로 중요한 간격을 감지하므로 더 민감하지만 CuSum에 의한 감지는 감염 전에 수신된 데이터만을 기반으로 했습니다.

대조로서 우리는 CuSum 온라인 감지 방법을 사용하여 다음의 웨어러블 장치 데이터를 조사했습니다. (1) 코로나19 양성자와 같은 기간 동안 질병을 보고하지 않은 73명; (2) 15개의 비COVID-19 질병을 앓고 있는 13명의 개인(보충 표 25; 그림 7c,d의 예). 건강한 개인도 경보를 받았지만(그림 7d 및 보충 그림 6), 경보 지속 시간과 피크는 일반적으로 코로나19 및 기타 질병의 경보 기간보다 짧고 작았습니다(그림 7g,h 및 보충 표 28). 또한 무증상 질병을 나타내는 감염 신호와 유사한 신호도 있었습니다. 휴일 급증은 데이터가 포함된 다른 세 사람 중 한 명에게서도 관찰되었습니다.

그 기간. 다른 질병을 앓고 있는 15명의 개인은 15개 사례 중 9개 사례에서 질병 발생 시 또는 이전에 신호를 보냈습니다(보충 그림 3a). 경보 방법은 정규 분포의 끝 부분에 가까운 신호를 식별하도록 설정되었기 때문에 모든 개인의 건강한 기간 동안 경보가 발생할 것으로 예상되었습니다. 이는 통계적 우연뿐만 아니라 확인된 질병 이외의 유발 요인에 의해 발생했을 것입니다.


논의


우리는 대규모 코호트에서 코로나19 및 기타 질병에 대한 양성 반응을 보였으며 스마트워치를 착용한 다수의 개인을 식별했습니다. 이러한 데이터를 사용하여 우리는 일반적으로 증상이 발생하기 전에 RHR 상승과 심박수/결음수 측정값 상승을 감지하는 알고리즘을 개발했습니다. 발견 초기 시간은 일반적으로 이전에 보고된 증상 전 질병의 잠복기와 일치했습니다⁹. 두 그룹 I 개인의 경우 증상이 나타나기 9일 이상 전에 신호가 관찰되었습니다. 이러한 사례의 실제 감염 시기는 알려지지 않았기 때문에 이러한 사건과 기타 사건이 코로나19 질병에 병합된 초기 스트레스 사건을 나타낼 가능성이 있습니다(예: 그림 6b). 실제로 그룹 I I 개인 10명에서는 별개의 초기 사건이 관찰되었고, 3명에서는 이는 자가 보고된 질병이나 가족 스트레스 사건과 관련이 있었습니다. 초기 스트레스 사건으로 인해 개인의 COVID-19 취약성이 높아져 질병이 발생할 가능성이 있습니다.


우리는 후향적 분석을 통해 얻은 정보를 사용하여 코로나19 질병(CuSum)의 실시간 조기 발견을 위한 프로토타입 접근 방식을 설계했습니다. 코로나19 사건의 탐지 외에도 다른 사건도 확인되었으며, 그 중 일부는 이전에 관찰한 바와 같이 무증상 사례를 포함한 질병을 반영했을 가능성이 높습니다⁵. 다른 많은 사건들은 약물, 알코올, 여행, 정서적 또는 기타 스트레스 유발 요인과 같이 지속적인 심박수 증가를 자극하는 상황을 반영할 수 있습니다. 실제로 12월 연휴를 다룬 데이터가 포함된 7개 사례 중 4개 사례에서는 장기간 기간이 상당히 증가한 것으로 나타났습니다. 지속 시간이 짧은 이벤트(예: 무서운 영화 보기 등)는 아마도 짧은 시간 후에 종료될 것입니다. 따라서 우리가 제안한 2계층 연속 경보 시스템을 사용하면 초기 사건은 자가 격리를 통해 조치를 취할 수 있으며, 신호가 증가하면 의사 상담 및/또는 직접적인 바이러스 진단으로 확대될 수 있습니다. 또한 경보 매개변수를 조정하여 경보 수의 증가 또는 감소에 따라 민감도를 높이거나 낮출 수도 있습니다. 이러한 조정은 개인의 선호도나 위험도에 따라 가치가 있을 수 있습니다. 여기에 제시된 버전에서는 건강한 개인의 경우 월 0.66회의 놀라운 빈도로 알려진 코로나19 감염의 63%를 감지할 수 있었습니다. 무증상 사례는 설명되지 않으므로 코로나19의 경우 63%는 과대평가될 가능성이 있지만, 많은 신호가 그러한 질병(보고되지 않은 증상 및 무증상 모두)을 나타낼 수 있으므로 모든 감염에 대한 과소평가일 가능성이 높습니다.

그림 6 | 코로나19 증상과 심박수 신호의 연관성. a-d, COVID-19 감염 과정에서 4명의 개별 참가자(APGIB2T(a), AQC0L71(b), A0VFT1N(c) 및 A1K5DRI(d))의 플롯. x축을 따라 있는 세로 열은 각각 하루의 증상(초기 질병(가장 왼쪽)부터 후기 질병까지)을 나타내며 아래 심박수 측정항목과 일치합니다. 증상을 표시하는 열은 일일 조사가 완료된 날짜에만 표시되며, 심박수 측정항목은 아래에서 지속적으로 진행됩니다. '전반적인 느낌'은 참가자가 특정 날의 느낌을 어떻게 보고했는지를 나타냅니다. 위의 막대 그래프는 보고된 경우 측정된 온도를 나타내고 특정 증상은 심각도를 나타내는 히트맵으로 아래에 강조 표시됩니다. 증상 아래 및 심박수 지표로 내려가는 검은색 수직선은 질병 과정 중 중요한 날을 강조 표시하고 위의 증상과 일치하도록 표시됩니다. RHR-Diff 플롯은 RHR-Diff의 표준화된 심박수 잔차(검은색 선)와 심박수 잔차가 크게 증가한 시간 간격(화살표가 있는 빨간색 선)을 보여줍니다. 각 패널의 하단 플롯은 HROS-AD 방법(검은색 선)을 사용하여 표준화된 HROS를 표시하며, 감지된 각 이상은 빨간색 타원으로 표시됩니다. e, 과거 코로나19 질병에 대한 설문조사를 제공한 개인의 증상 데이터 요약. 각 열은 아래 표시된 대로 연구 참가자를 나타냅니다. (위에서 아래로) 질병 중 보고된 평균 온도(°C)의 막대 그래프가 표시됩니다. 전반적인 감점(위의 범례 참조) 보고된 증상 발병부터 회복까지의 총 기간(제공된 경우) a boxplot (showing

심박수 잔류 경보가 발생했을 때 분당 심박수로 표시되는 ΔRHR 의 수치 중앙값; 개별 증상의 플롯(검은색 상자는 보고된 증상을 나타내고 흰색 상자는 보고된 증상이 없음을 나타냄). 상자 그림의 경우 중앙선은 중앙값을 나타내고 상자 한계는 상위(세 번째) 및 하위(첫 번째) 사분위수를 나타내며 수염은 각각 상위 및 하위 사분위수 위와 아래의 사분위수 범위 1.5x를 나타내며 빨간색 십자가는 이상값입니다.








It should be noted that the wearable devices used in our study have not yet been approved by the US Food and Drug Administration for early illness detection and our study is still modest in size. Another limitation we observed is that some individuals do not wear their

devices (or let their charge expire) when symptomatic, which may affect monitoring patterns. Patterns of non-use were not Fitbit specific, and we expect that devices requiring daily charging will also have more missing data. Nonetheless, devices whose charge lasts for



우리 연구에 사용된 웨어러블 장치는 아직 미국 식품의약국(FDA)의 조기 질병 탐지 승인을 받지 않았으며 우리 연구의 규모도 아직 크지 않습니다. 우리가 관찰한 또 다른 제한 사항은 일부 개인이 증상이 있을 때 장치를 착용하지 않거나 충전이 완료되도록 방치하여 모니터링 패턴에 영향을 미칠 수 있다는 것입니다. 미사용 패턴은 Fitbit에만 국한된 것이 아니며, 매일 충전이 필요한 장치에도 누락된 데이터가 더 많을 것으로 예상됩니다. 그럼에도 불구하고 충전이 지속되는 장치

Fig. 7 | Online detection of COVID-19 infection. **a–d**, Examples of online prediction performance during COVID-19 infection for two participants with long-term data (**a** and **b**), one example of other (non-COVID-19) illness (**c**) and one example from the healthy group (**d**; note the smaller scale compared with **a–c**). For each plot, the x axis is the number of days pre- or post-symptom onset. The red and purple vertical dashed lines indicate days of symptom onset and diagnosis, respectively, and the blue dashed vertical lines indicate the alarming time from online detection (see Methods). **e**, Alarm counts per 30 d for participants with COVID-19. The blue and red bars indicate the alarm counts before and after the COVID-19 event. Average alarm counts are 0.29 versus 1.35 before and after infection, respectively. **f**, Early detection comparison between offline detection (RHR-Diff) and online detection (CuSum). Detection days are compared with the symptom day. Each red circle indicates one participant. The black dashed line is the identity line and the blue dashed lines surrounding it are at a distance of ± 1 d from the identity line. The grey dotted lines separate the quantitative part of the graph from the missed cases. **g**, Comparison of the total alarm duration across the COVID-19 positive group, other illness group and potentially healthy group. **h**, Comparison of the alarm peak height across the different groups described in **g**. For each sickness case in **g** and **h**, the alarms are further assigned to three categories: pre-sickness, during sickness and post-sickness. Only *P* values with a significance of <0.05 are shown. In addition, a slight increase in alarm frequency was observed, but it did not achieve significance (Supplementary Fig. 7 and Supplementary Table 29). For the boxplots in **g** and **h**, central lines represent median values, box limits represent the upper (third) and lower (first) quartiles, whiskers represent 1.5 $\times$ the interquartile range above and below the upper and lower quartiles, respectively and black dots represent outliers.

several days should be powerful enough for early detection before loss of device function.

Our approach is a general detection method and presently cannot distinguish infections with SARS-CoV-2 from those caused by other viruses (other than pre-symptomatic duration), since increased RHR is common to many respiratory infections. Regardless, any illness onset information is valuable, especially during a pandemic, and can be followed up with appropriate testing. It is also likely that other types of physiological measurements that are obtainable from wearable devices (for example, heart rate variability, respiration rate, skin temperature, blood oxygen saturation and electrocardiogram readings) will be valuable for distinguishing illnesses caused by different infectious agents and could be used to increase diagnostic sensitivity and perhaps even predict illness severity and symptoms^{24–27}. Data on reported respiratory rates and blood oxygen saturation are expected to be particularly useful in COVID-19 prediction²⁸, although the disease is quite heterogeneous in its physiological presentation^{29,30}, as observed in our study. At the time of writing, such data were not available to us; however, these data, especially when combined with machine learning approaches, as well as an increased number of study participants, will greatly improve diagnostics. Regardless, this continuous monitoring approach is expected to be powerful for early infectious illness detection and offers many advantages that may help increase disease detection during the current global pandemic. Specifically, wearable device-based disease detection does not require testing infrastructure, materials or personnel that can be overburdened by global supply chain shortages. In addition, real-time monitoring by smartwatches is a passive form of testing that does not burden patient schedules and can serve as a high-resolution continuous screening to inform follow-up testing and self-isolation. We hope that ongoing screening for COVID-19 risk using wearable devices can provide a scalable solution to help overcome current barriers with testing, and inform early diagnosis and treatment to mitigate the spread of the disease. Such information will inform patients for self-isolation, diagnosis confirmation and early treatment.

Methods

Participant recruitment. We recruited 5,262 adult individuals for this study under protocol number 55577 approved by the Stanford University Institutional Review Board. Participants were recruited using REDCap and informed electronic consent was obtained from all participants³¹. Recruitment was done through social media, word of mouth, COVID-19 registries and presentations, as well as via referrals from Stanford Health Care. We recruited participants with a confirmed or suspected COVID-19 infection, as well as those at high risk of exposure to COVID-19 (for example, via family members or relevant occupation), individuals with unknown respiratory illness and individuals who did not report any illness. Participants were asked to wear their fitness tracker daily, as much as possible, and to download a study app called MyPHD (see ‘MyPHD app for wearable device data collection’ below) with which to share their wearable device data. In addition, long-term wearable device data collected during periods before the COVID-19

pandemic (2019 or before) from seven individuals enrolled in our iPOP study³² were also extracted and analysed. The iPOP study was approved by the Stanford University Institutional Review Board under protocol number 23602.

Metadata collection and surveys. Study metadata, such as demographic information, reports of past illnesses, daily symptom tracking and so on, were collected via REDCap. At enrollment, participants were asked to provide: (1) demographic information, such as age, sex, ethnicity, height and weight; (2) medical history, including chronic illnesses, routinely taken medications and so on; and (3) COVID-19 illness status (that is, whether they had a confirmed or suspected COVID-19 infection and, if tested, the test date, results and symptom onset date).

In addition, all participants were asked to complete a daily symptom tracking survey, which tracked the symptoms experienced and their severity on a scale of 1–5 (mild, mild to moderate, moderate, severe or worst possible), body temperature (if recorded), new tests or diagnoses of COVID-19 or other respiratory illnesses, test results, recovery dates and so on. Finally, participants were also asked to fill out a one-time past illness survey, where they could report past sickness periods (up to five illnesses in total) since 1 November 2019. The past illnesses survey recorded the length of the sickness period and other elements similar to the daily survey: diagnoses (if any) of COVID-19 or other respiratory illnesses, any symptoms they reported experiencing during this period, as well as body temperature and symptom severity on a scale of 1–5.

For this study, we restricted our analyses to a dataset of 32 individuals who reported a positive COVID-19 diagnosis, a diagnosis date and/or symptom onset date (usually both; $n=28$) and wearable device data appropriate for the analyses. Five of these individuals also reported other non-COVID-19 respiratory infections, including four individuals who reported two other illnesses since October 2019. Nearly all ($n=27$) provided diagnosis confirmation: 23 of the participants provided written documentation of their test result and four others provided verbal confirmation. We also analysed data for 15 non-COVID-19 illness events from 13 other participants; one was diagnosed with influenza B, another with a rhinovirus infection and four with non-COVID-19 infections (type unknown). Long-term (>1 year) data during periods before the COVID-19 pandemic (2019 or before) from seven additional participants from the iPOP study with a total of nine infections were also analysed. Illness was confirmed for six of these events by elevated C-reactive protein levels (as determined by high-sensitivity C-reactive protein test; Supplementary Table 30). Data from February 2020 until June 2020 were also analysed from 73 healthy participants who did not report any illness.

MyPHD app for wearable device data collection. After participants enrolled on REDCap, they were directed to download MyPHD, a smartphone app developed by our study team, to collect their wearable device data in a de-identified and encrypted manner. The MyPHD app was made available to study participants for both Android and iOS platforms. For Fitbit watches, the data were accessed through the Fitbit application programming interfaces, and for wearable devices with Apple HealthKit integration, we obtained the data via HealthKit. Data transfer was done from the source to a Health Insurance Portability and Accountability Act-compliant Google Cloud Platform project in an encrypted form, then the data were decrypted for pre-processing and analysis in a controlled-access, secure environment.

Wearable devices and data types collected. Participants wore Fitbit smartwatches, including different versions, such as Fitbit Ionic, Charge 4 and Charge 3. The data types collected included heart rate, steps and sleep. Raw heart rate, steps and sleep data were collected in JavaScript Object Notation format. Heart rate data were retrieved at 15-s resolution, steps values at a resolution of 1 min and sleep data as sleep stage intervals (wake, light, deep and REM).

그림 7 | 코로나19 감염의 온라인 감지. a-d, 장기 데이터(a 및 b), 기타(COVID-19가 아닌) 질병의 한 예(c) 및 건강한 그룹의 한 예(d, a-c에 비해 더 작은 규모에 유의)가 있는 두 명의 참가자에 대한 COVID-19 감염 중 온라인 예측 성능의 예. 각 플롯에서 x축은 증상 발병 전후의 일수입니다. 빨간색과 보라색 세로 점선은 각각 증상 발병 및 진단 일수를 나타내고, 파란색 점선 세로선은 온라인 감지로 인한 경고 시간을 나타냅니다(방법 참조). e, 코로나19 참가자에 대한 30일당 알람 횟수입니다. 파란색과 빨간색 막대는 코로나19 사태 전후의 경고 횟수를 나타냅니다. 평균 경고 횟수는 감염 전후 각각 0.29대 1.35입니다. f, 오프라인 감지(RHR-Diff)와 온라인 감지(CuSum) 간의 조기 감지 비교. 검출일은 증상 발생일과 비교됩니다. 각 빨간색 원은 한 명의 참가자를 나타냅니다. 검은색 점선은 식별선이고 이를 둘러싼 파란색 점선은 식별선에서 $\pm 1d$ 거리에 있습니다. 회색 점선은 그래프의 정량적 부분과 누락된 사례를 구분합니다. g, 코로나19 양성 그룹, 기타 질병 그룹, 건강 가능성이 있는 그룹의 총 알람 지속 시간 비교. h, g에 설명된 여러 그룹의 경고 피크 높이 비교. g와 h의 각 질병 사례에 대해 정보는 질병 전, 질병 중, 질병 후의 세 가지 범주로 추가로 할당됩니다. <0.05의 의미를 갖는 P값만 표시됩니다. 또한, 경고 빈도의 약간의 증가가 관찰되었으나 유의성은 달성되지 않았습니다(보충 그림 7 및 보충 표 29). g 및 h의 상자 그림에서 중앙 선은 중앙값을 나타내고, 상자 한계는 상위(세 번째) 및 하위(첫 번째) 사분위수를 나타내고, 수염은 각각 상위 및 하위 사분위수 위와 아래의 사분위수 범위 1.5x를 나타내며, 검은 점은 이상값을 나타냅니다.

며칠은 조기 발견이 가능하도록 충분히 강력해야 합니다. 장치 기능 상실.

우리의 접근 방식은 일반적인 탐지 방법이며 RHR 증가는 많은 호흡기 감염에 공통적이기 때문에 현재 SARS-COV-2 감염을 다른 바이러스로 인한 감염(증상 발현 전 기간 제외)과 구별할 수 없습니다. 그럼에도 불구하고 질병 발병 정보는 특히 전염병 기간 동안 가치가 있으며 적절한 검사를 통해 후속 조치를 취할 수 있습니다. 또한 웨어러블 장치에서 얻을 수 있는 다른 유형의 생리학적 측정(예: 심박수 변화, 호흡수, 피부 온도, 혈중 산소 포화도 및 심전도 판독값)은 다양한 감염원으로 인한 질병을 구별하는 데 유용할 것이며 진단 민감도를 높이고 질병 심각도 및 증상을 예측하는 데 사용될 수도 있습니다²⁴⁻²⁷. 보고된 호흡수와 혈중 산소 포화도에 대한 데이터는 코로나19 예측에 특히 유용한 것으로 예상됩니다²⁸. 하지만 이 질병은 우리 연구에서 관찰된 바와 같이 생리학적 표현^{29,30}이 상당히 이질적입니다. 글을 쓰는 시점에는 그러한 데이터를 사용할 수 없었습니다. 그러나 이러한 데이터는 특히 기계 학습 접근 방식과 결합되고 연구 참가자 수가 증가하면 진단이 크게 향상될 것입니다. 그럼에도 불구하고, 이러한 지속적인 모니터링 접근 방식은 감염성 질병의 조기 발견에 강력할 것으로 예상되며, 현재 전 세계적인 유행병 기간 동안 질병 발견을 높이는 데 도움이 될 수 있는 많은 이점을 제공합니다. 특히, 웨어러블 장치 기반 질병 탐지에는 글로벌 공급망 부족으로 인해 과도한 부담을 받을 수 있는 테스트 인프라, 자재 또는 인력이 필요하지 않습니다. 또한, 스마트워치를 통한 실시간 모니터링은 환자 일정에 부담을 주지 않는 수동적인 형태의 검사이며, 후속 검사 및 자가격리를 알리기 위한 고해상도의 지속적인 검사 역할을 할 수 있습니다. 우리는 웨어러블 장치를 사용하여 지속적인 코로나19 위험 검사를 통해 현재의 검사 장벽을 극복하는 데 도움이 되는 확장 가능한 솔루션을 제공하고, 질병 확산을 완화하기 위한 조기 진단 및 치료 정보를 제공할 수 있기를 바랍니다. 이러한 정보는 환자에게 자가 격리, 진단 확인 및 조기 치료에 대한 정보를 제공합니다.

행동 양식

참가자 모집. 우리는 Stanford University Institutional Review Board가 승인한 프로토콜 번호 55577에 따라 이 연구를 위해 5,262명의 성인을 모집했습니다. 참가자는 REDCap을 사용하여 모집되었으며 모든 참가자로부터 사전 전자 동의를 얻었습니다³¹. 채용은 소셜 미디어, 입소문, 코로나19 등록 및 프레젠테이션은 물론 Stanford Health Care의 추천을 통해 이루어졌습니다. 우리는 코로나19 감염이 확인되었거나 의심되는 참가자뿐만 아니라 코로나19에 노출될 위험이 높은 사람(예: 가족이나 관련 직업을 통해), 알려지지 않은 호흡기 질환이 있는 사람, 질병을 보고하지 않은 사람을 모집했습니다. 참가자들은 가능한 한 매일 피트니스 트래커를 착용하고, 웨어러블 기기 데이터를 공유할 수 있는 MyPHD(아래 '웨어러블 기기 데이터 수집을 위한 MyPHD 앱' 참조)라는 학습 앱을 다운로드하도록 요청 받았습니다. 또한, 코로나19 이전 기간 동안 수집된 장기 웨어러블 기기 데이터

iPOP 연구³²에 등록된 7명의 개인으로부터 전염병(2019년 이전)도 추출 및 분석되었습니다. iPOP 연구는 프로토콜 번호 23602에 따라 Stanford University Institutional Review Board의 승인을 받았습니다.

메타데이터 수집 및 설문조사. 인구통계학적 정보, 과거 질병 보고서, 일일 증상 추적 등과 같은 연구 메타데이터는 REDCap을 통해 수집되었습니다. 등록 시 참가자들은 다음을 제공하도록 요청 받았습니다. (1) 연령, 성별, 민족, 키, 몸무게와 같은 인구통계학적 정보; (2) 만성 질환, 정기적으로 복용하는 약물 등을 포함한 병력; (3) 코로나19 질병 상태(즉, 코로나19 감염이 확인되었거나 의심되는지 여부, 검사를 받은 경우 검사 날짜, 결과 및 증상 발생 날짜).

또한 모든 참가자에게 매일 증상 추적 설문조사를 완료하도록 요청했습니다. 이 설문조사에서는 경험한 증상과 심각도를 1~5단계(경증, 경증~중등도, 중등도, 중등 또는 최악), 체온(기록된 경우), 새로운 검사 또는 코로나19 또는 기타 호흡기 질환 진단, 검사 결과, 회복 날짜 등을 추적했습니다. 마지막으로 참가자들은 2019년 11월 1일 이후 과거 질병 기간(총 5개 질병까지)을 보고할 수 있는 일회성 과거 질병 설문조사를 작성하도록 요청 받았습니다. 과거 질병 설문조사에는 질병 기간의 길이와 기타 요소가 기록되었습니다.

일일 설문조사와 유사합니다. 코로나19 또는 기타 호흡기 질환 진단(있는 경우), 이 기간 동안 경험했다고 보고한 증상, 체온 및 증상 심각도(1~5등급).

이 연구에서 우리는 코로나19 양성 진단을 보고한 32명의 개인, 진단 날짜 및/또는 증상 발병 날짜(일반적으로 둘 다, $n = 28$) 및 분석에 적합한 웨어러블 장치 데이터로 구성된 데이터 세트로 분석을 제한했습니다. 이들 중 5명은 기타 비COVID-19 호흡기 질환도 보고했습니다.

2019년 10월 이후 두 가지 다른 질병을 보고한 4명의 개인을 포함한 감염. 거의 모든($n = 27$)이 진단 확인을 제공했습니다. 참가자 중 23명은 테스트 결과에 대한 서면 문서를 제공했고 다른 4명은 구두 확인을 제공했습니다. 우리는 또한 13명의 다른 참가자로부터 15개의 비COVID-19 질병 사건에 대한 데이터를 분석했습니다. 한 명은 B형 인플루엔자로 진단받았고, 다른 한 명은 라노바이러스 감염, 네 명은 비COVID-19 감염(유형 불명)으로 진단되었습니다. iPOP 연구에서 추가 참가자 7명(총 9명 감염)을 대상으로 코로나19 팬데믹 이전(2019년 또는 그 이전) 기간 동안의 장기(>1년) 데이터도 분석되었습니다. 이러한 사건 중 6개에서 질병은 C-반응성 단백질 수준의 상승으로 확인되었습니다(고감도 C-반응성 단백질 테스트, 보충 표 30에 의해 결정됨). 2020년 2월부터 2020년 6월까지의 데이터도 질병을 보고하지 않은 건강한 참가자 73명의 데이터를 분석했습니다.

웨어러블 기기 데이터 수집을 위한 MyPHD 앱. 참가자들이 REDCap에 등록한 후, 우리 연구 팀이 개발한 스마트폰 앱인 MyPHD를 다운로드하여 비식별화 및 암호화된 방식으로 웨어러블 장치 데이터를 수집하라는 안내를 받았습니다. MyPHD 앱은 Android 및 iOS 플랫폼 모두에서 연구 참가자에게 제공되었습니다. Fitbit 시계의 경우 Fitbit 애플리케이션 프로그래밍 인터페이스를 통해 데이터에 액세스했으며 Apple HealthKit 통합 기능이 있는 웨어러블 장치의 경우 HealthKit을 통해 데이터를 얻었습니다. 데이터 전송

소스에서 건강 보험 이동성 및 책임법을 준수하는 Google Cloud Platform 프로젝트 암호화된 형식으로 수행된 후, 데이터는 액세스가 제어된 안전한 환경에서 전처리 및 분석을 위해 복호화되었습니다.

웨어러블 기기 및 수집되는 데이터 유형. 참가자들은 Fitbit 스마트워치를 착용했으며, Fitbit Ionic, Charge 4, Charge 3 등 다양한 버전이 포함됩니다. 수집된 데이터 유형에는 심박수, 걸음 수, 수면이 포함됩니다. 원시 심박수, 걸음 수 및 수면 데이터는 JavaScript 개체 표기법 형식으로 수집되었습니다. 심박수 데이터는 15초 해상도, 걸음 수 값은 1분 해상도, 수면 데이터는 수면 단계 간격(기상, 얕은, 깊은 및 REM)으로 검색되었습니다.

Wearable device data pre-processing. The retrieved raw heart rate, sleep and steps data from Fitbit were processed and integrated using a systematic workflow to produce a uniform format among different retrieval protocols. First, heart rate outliers (heart rate > 200 and heart rate < 30) were removed, as were all duplicates in the heart rate, steps and sleep data. Time stamps were unified to a standard time zone to be able to match different types of wearable device data with metadata. Heart rate features were extracted, such as median heart rate per minute, average heart rate per minute, night-time RHR and so on. Additionally, daily steps were calculated. For sleep features, total sleep duration per night, as well as wake, light, deep and REM stage durations and their corresponding percentages for each night, were calculated.

Symptoms and other metadata processing. Participant metadata and symptom surveys were downloaded and processed using a custom R and Python script. A total of 136 participants reported a positive COVID-19 diagnosis, but many were lacking a clear diagnosis or symptom date or appropriate wearable device data for the analyses. Height was converted to centimetres (Supplementary Tables 1 and 2), weight was converted to kilograms (Supplementary Tables 1 and 2) and reported temperature was converted to Celsius (Fig. 6) for all participants.

RHR-Diff offline anomaly detection. The RHRs were obtained using the same approach as in Li et al.⁵. For each person, the RHRs were then standardized in 1-h resolution based on the average of daily curves from a 28-d sliding window. The resulting values in the RHRs were imputed as zeroes before the detection. We applied anomaly time-interval detection based on rank scans from the work of Arias-Castro et al.¹³ on the standardized residuals. Under a significance level of 0.05, the detected elevated time intervals were reported. To reduce possible false positives, short detected intervals of <24 h were removed. If there was a gap of two days or less near the symptoms onset date, it was treated as a single signal.

HROS-AD offline anomaly detection. HROS-AD is an unsupervised anomaly detection model consisting of two major steps:

1. In the data pre-processing step, we combined heart rate and step data from each user to compute a new feature known as HROS. HROS is a feature of a user's HROS (a value of 1 is added to all steps to avoid the zero-division problem). Next, we used moving averages (mean = 400 h) and down-sampling (mean = 1 h) to smoothen the time-series data and standardized further with a Z score transformation.
2. In the anomaly detection step, when a HROS data point deviated markedly from others in a sample, it was called an anomaly or outlier. Any other expected observation was labelled as an inlier.

We used the covariance.EllipticEnvelope class from the scikit-learn package in Python^{14,15,33} to fit a Gaussian distribution of the data, pointing out the anomalies that might be contaminating our dataset because they are extreme points in the general distribution of the dataset. For simplicity, we call this method HROS-AD when the input data are HROS. Within the HROS-AD method, EllipticEnvelope is a function that calculates the distance of each HROS observation with respect to the grand mean that takes into account all of the observations in the data and detects both univariate and multivariate outliers.

HROS-AD uses a key parameter called contamination that provides information about the proportion of the HROS outliers present in each dataset and can take a value up to 0.5 (Supplementary Table 31). We start with a value of 0.01 because 0.01 is the percentage of observations that should fall over the absolute value 3 in the Z score distance from the mean in a standardized Gaussian distribution. If we do not detect any anomalies, we gradually increase the contamination value from 0.01 until we find an anomaly. If we find too many anomalies with a 0.01 contamination score, we gradually decrease the contamination value. The predictions contain a vector of values between 1 and -1 (1 being normal and -1 being anomalous).

We deleted the predictions if they were overlapping daytime (6:00–00:00) or missing steps in the alert window of 21 d before symptom onset and 7 d post-symptom onset. There were five participants who had missing step data for at least one day in the alert window, and three of the participants had at least one prediction overlapping daytime or missing steps in the alert window.

We also used resting heart rate (RHR) instead of HROS to check the model performance. We call this method RHR-AD. It uses the same pipeline as HROS-AD except the input is RHR, which is the heart rate at a given time point where the step count for the previous 12 min was 0. Overall, the results between HROS-AD and RHR-AD were very similar (Supplementary Tables 7, 8, and 15).

Activity and sleep analysis. In our analysis, we only considered individuals who had detectable changes in RHR between -14 d before symptom onset and 2 d after, using our RHR-Diff algorithm. We also removed individuals with more than 50% of steps or sleep (each individually) data missing in a window of 21 d before symptom onset and 7 d after. This resulted in 22 individuals for the steps analysis, and 13 individuals for the sleep analysis. Following this filtration criteria, missing values were imputed using the last observation carried forward (LOCF) method. Afterward, daily steps and total sleep duration were Z score normalized for each person independently.

Since wearable device data tend to have missing values (especially sleep, since some participants do not wear the watch every night), we evaluated the change in daily steps and total sleep duration without imputing the missing values. In a separate analysis (Supplementary Fig. 4), we compared daily steps and total sleep pre- and post-detection without the imputation process. We only considered 7 d pre-detection and 7 d post-detection.

LMMs were conducted for daily steps and total sleep duration using the nlme package (version 3.1-142) in R. In our model, we included day annotation as a fixed effect and subject ID as a random effect. An analysis of variance test was applied on the fitted model to retrieve a P value for the tested hypothesis.

CuSum online detection. CuSum statistics were calculated based on the work of Levin and Kline^{13,23}. The values of CuSum statistics in the previous baseline days were used to construct a null distribution for each hour, and a sliding 1 h interval was then interrogated for residuals compared with the baseline distribution for that hour. The baseline window was set to 28 d. The threshold parameter in the CuSum statistic was set as half of the 90% quantile of the baseline residuals for the short-term data and half of the 99% quantile for the long-term data. Under the significance level 0.01, an alarm candidate was recorded the first time that the CuSum statistic was significantly higher than the values from the null distribution. We tracked the records of CuSum statistics for 48 h. To reduce possible false positives, we started monitoring the statistic when it rose above the threshold in the second hour. In cases where the CuSum statistic stopped increasing within 24 h or returned to zero within 48 h, the initial alarm was removed.

Visualization methods. We used ggplot2, Matplotlib and MATLAB to plot most of the figures^{34,35}.

Reporting Summary. Further information on research design is available in the Nature Research Reporting Summary linked to this article.

Data availability

The de-identified raw heart rate, steps and sleep data used in this study can be downloaded from the study data repository (https://storage.googleapis.com/gbsec-gcp-project-ipop_public/COVID-19/COVID-19-Wearables.zip). Processed data, including algorithm outputs and the data used for plotting the figures are provided as Supplementary Data 1.

Code availability

Code for the algorithms used in this manuscript is available at <https://github.com/mwgrassgreen/WearableDetection> (RHR-Diff and CuSum) and <https://github.com/gireeshkbogu/AnomalyDetect> (HROS-AD).

Received: 1 July 2020; Accepted: 1 October 2020;
Published online: 18 November 2020

References

1. Sethuraman, N., Jeremiah, S. S. & Ryo, A. Interpreting diagnostic tests for SARS-CoV-2. *J. Am. Med. Assoc.* <https://doi.org/10.1001/jama.2020.8259> (2020).
2. Marinsek, N. et al. Measuring COVID-19 and influenza in the real world via person-generated health data. Preprint at *medRxiv* <https://doi.org/10.1101/2020.05.28.20115964> (2020).
3. Dunn, J., Runge, R. & Snyder, M. Wearables and the medical revolution. *Per. Med.* **15**, 429–448 (2018).
4. Kellogg, R. A., Dunn, J. & Snyder, M. P. Personal omics for precision health. *Circ. Res.* **122**, 1169–1171 (2018).
5. Li, X. et al. Digital health: tracking physiomes and activity using wearable biosensors reveals useful health-related information. *PLoS Biol.* **15**, e2001402 (2017).
6. Perez, M. V. et al. Large-scale assessment of a smartwatch to identify atrial fibrillation. *N. Engl. J. Med.* **381**, 1909–1917 (2019).
7. Radin, J. M., Wineinger, N. E., Topol, E. J. & Steinhilber, S. R. Harnessing wearable device data to improve state-level real-time surveillance of influenza-like illness in the USA: a population-based study. *Lancet Digital Health* **2**, e85–e93 (2020).
8. Zhu, G. et al. Learning from large-scale wearable device data for predicting epidemics trend of COVID-19. *Discrete Dyn. Nat. Soc.* **2020**, 6152041 (2020).
9. Seshadri, D. R. et al. Wearable sensors for COVID-19: a call to action to harness our digital infrastructure for remote patient monitoring and virtual assessments. *Front. Digital Health* <https://doi.org/10.3389/fdgh.2020.00008> (2020).
10. Arons, M. M. et al. Presymptomatic SARS-CoV-2 infections and transmission in a skilled nursing facility. *N. Engl. J. Med.* **382**, 2081–2090 (2020).
11. He, X. et al. Temporal dynamics in viral shedding and transmissibility of COVID-19. *Nat. Med.* **26**, 672–675 (2020).
12. Witt, D., Kellogg, R., Snyder, M. & Dunn, J. Windows into human health through wearables data analytics. *Curr. Opin. Biomed. Eng.* **9**, 28–46 (2019).

웨어러블 기기 데이터 전처리. Fitbit에서 검색된 원시 심박수, 수면 및 걸음 수 데이터는 체계적인 워크플로우를 사용하여 처리 및 통합되어 다양한 검색 프로토콜 간에 통일된 형식을 생성했습니다. 먼저, 심박수 이상값(심박수 > 200 및 심박수 < 30)이 제거되었으며 심박수, 걸음 수 및 수면 데이터의 모든 중복 항목도 제거되었습니다. 다양한 유형의 웨어러블 장치 데이터를 메타데이터와 일치시킬 수 있도록 타임스탬프가 표준 시간대로 통합되었습니다. 마음

분당 평균 심박수, 분당 평균 심박수, 야간 RHR 등과 같은 속도 특성이 추출되었습니다. 또한 일일 걸음 수도 계산되었습니다. 수면 기능의 경우 밤당 총 수면 시간과 각성, 얕은 및 REM 단계 지속 시간과 각 밤에 대한 해당 비율이 계산되었습니다.

증상 및 기타 메타데이터 처리. 참가자 메타데이터와 증상 설문조사는 사용자 지정 R 및 Python 스크립트를 사용하여 다운로드되고 처리되었습니다. 총 136 명의 참가자가 코로나19 양성 진단을 보고했지만, 이들 중 다수는 명확한 진단이나 증상 날짜 또는 분석을 위한 적절한 웨어러블 장치 데이터가 부족했습니다. 모든 참가자의 키는 센티미터로 변환되었고(보충 표 1 및 2), 체중은 킬로그램으로 변환되었으며(보충 표 1 및 2), 보고된 온도는 섭씨로 변환되었습니다(그림 6).

RHR-Diff 오프라인 이상 탐지. RHR은 Li et al.⁵에서와 동일한 접근 방식을 사용하여 획득되었습니다. 각 사람에 대해 RHR은 28일 슬라이딩 윈도우의 일일 곡선 평균을 기반으로 1시간 해상도로 표준화되었습니다. RHR의 누락된 값은 감지 전에 0으로 대체되었습니다. 우리는 표준화된 잔차에 대한 Arias-Castro et al.¹³의 작업에서 순위 스캔을 기반으로 이상 시간 간격 탐지를 적용했습니다. 0.05의 유의 수준에서 감지된 상승된 시간 간격이 보고되었습니다. 가능한 거짓 긍정을 줄이기 위해 <24시간의 짧은 감지 간격이 제거되었습니다. 2개 정도의 공백이 있었다면

증상 발현일로부터 며칠 이내에 단일 신호로 처리되었습니다.

HROS-AD 오프라인 이상 탐지. HROS-AD는 두 가지 주요 단계로 구성된 비지도 이상 탐지 모델입니다.

1. 데이터 전처리 단계에서는 각 사용자의 심박수와 걸음 수 데이터를 결합하여 HROS라는 새로운 기능을 계산했습니다. HROS는 사용자 i 의 HROS 기능입니다(0분할 문제를 피하기 위해 모든 단계에 값 1이 추가됨). 다음으로 이동 평균(평균 = 400h)과 다운샘플링을 사용했습니다.

(평균 = 1시간) 시계열 데이터를 평활화하고 Z 점수 변환을 통해 더욱 표준화했습니다. 2. 이상 탐지 단계에서 HROS 데이터 포인트가 표준 내 다른 데이터 포인트와 현저히 벗어난 경우 이를 이상 또는 이상치라고 합니다. 다른 이상 관찰은 인라이어로 표시되었습니다.

우리는 scikit-learn 패키지의 covariance.EllipticEnvelope 클래스를 사용했습니다. 데이터의 가우스 분포를 맞추기 위한 Python^{14,15,33}은 데이터 세트의 일반적인 분포에서 극단적인 지점이기 때문에 데이터 세트를 오염시킬 수 있는 변칙을 지적합니다. 단순화를 위해 입력 데이터가 HROS인 경우 이 방법을 HROS-AD라고 부릅니다. HROS-AD 방법 내에서 EllipticEnvelope는 데이터의 모든 관측치를 고려하고 단변량 및 다변량 이상값을 모두 감지하는 총 평균을 기준으로 각 HROS 관측치의 거리를 계산하는 함수입니다.

HROS-AD는 각 데이터세트에 존재하는 HROS 이상값의 비율에 대한 정보를 제공하고 최대 0.5의 값을 취할 수 있는 오염이라는 주요 매개변수를 사용합니다(보충 표 31). 0.01은 표준화된 가우스 분포의 평균으로부터 Z 점수 거리에 있는 절대값 3을 넘어야 하는 관측치의 백분율이기 때문에 0.01의 값으로 시작합니다. 이상이 발견되지 않으면 이상 현상이 발견될 때까지 오염 값을 0.01부터 점차적으로 늘립니다. 오염 점수가 0.01인 이상 징후가 너무 많이 발견되면 점차적으로 오염 값을 낮춥니다. 예측에는 1과 -1 사이의 값으로 구성된 벡터가 포함되어 있습니다.

(1은 정상이고 -1은 변칙적입니다).

증상 발생 전 21일과 증상 발생 후 7일의 경고 창에서 주간(6:00~00:00)이 겹치거나 단계가 누락된 경우 예측을 삭제했습니다. 경고 창에서 최소 하루 동안 걸음 수 데이터가 누락된 참가자는 5명이었고, 참가자 중 3명은 경고 창에서 주간과 겹치거나 걸음 수가 누락된 예측이 하나 이상 있었습니다.

또한 모델 성능을 확인하기 위해 HROS 대신 안정성 심박수(RHR)를 사용했습니다. 우리는 이 방법을 RHR-AD라고 부릅니다. 입력이 RHR이라는 점을 제외하면 HROS-AD와 동일한 파이프라인을 사용합니다. 이는 이전 12분 동안의 걸음 수가 0이었던 특정 시점의 심박수입니다. 전반적으로 HROS-AD와 RHR-AD 간의 결과는 매우 유사했습니다(보충 표 7, 8 및 15).

활동 및 수면 분석. 분석에서는 RHR-Diff 알고리즘을 사용하여 증상 발병 전 -14일과 후 2일 사이에 RHR에 감지 가능한 변화가 있는 개인만 고려했습니다. 또한 증상 발병 전 21일과 증상 발병 후 7일의 기간에서 걸음 수 또는 수면 데이터(각각 개별적으로)가 50% 이상 누락된 개인을 제거했습니다. 그 결과 단계 분석에는 22명이, 수면 분석에는 13명이 포함되었습니다. 이 필터링 기준에 따라 마지막 관찰 이월(LOCF) 방법을 사용하여 누락된 값이 대체되었습니다. 그 후, 일일 걸음 수와 총 수면 시간을 각 개인에 대해 독립적으로 Z 점수로 정규화했습니다.

웨어러블 디바이스 데이터는 결측값(특히 일부 참가자가 매일 밤 시계를 착용하지 않기 때문에 수면)이 있는 경향이 있으므로 결측값을 대체하지 않고 일일 걸음 수와 총 수면 시간의 변화를 평가했습니다. 별도의 분석(보조 그림 4)에서 대치 프로세스 없이 일일 단계와 총 수면 사전 및 사후 감지를 비교했습니다. 우리는 7d 사전 감지와 7d 감지 후만 고려했습니다.

LMM은 R의 nlme 패키지(버전 3.1-142)를 사용하여 일일 단계와 총 수면 시간에 대해 수행되었습니다. 우리 모델에서는 일 주석을 고정 효과로, 대상 ID를 무작위 효과로 포함했습니다. 테스트된 가설에 대한 P 값을 검색하기 위해 적합한 모델에 분산 테스트 분석을 적용했습니다.

CuSum 온라인 감지. CuSum 통계는 Levin과 Kline^{13,23}의 작업을 기반으로 계산되었습니다. 이전 기준 날짜의 CuSum 통계 값을 사용하여 각 시간에 대한 널 분포를 구성한 다음 슬라이딩 1시간 간격을 해당 시간의 기준 분포와 비교하여 잔차에 대해 조사했습니다. 기준선 창은 28일로 설정되었습니다. CuSum 통계의 임계값 매개변수는 단기 데이터의 경우 기준 잔차의 90% 분위수의 절반으로 설정되고 장기 데이터의 경우 99% 분위수의 절반으로 설정되었습니다. 유의 수준 0.01에서 CuSum 통계가 널 분포의 값보다 현저히 높을 때 처음으로 경고 후보가 기록되었습니다. 우리는 48시간 동안 CuSum 통계 기록을 추적했습니다. 가능한 오합지를 줄이기 위해 두 번째 시간에 임계값을 초과하면 통계 모니터링을 시작했습니다. CuSum 통계가 24시간 이내에 증가를 멈춘 경우

또는 48시간 이내에 0으로 돌아가면 초기 경보가 제거되었습니다.

시각화 방법. 우리는 ggplot2, Matplotlib 및 MATLAB을 사용하여 대부분의 그림^{34,35}을 그렸습니다.

보고 요약. 연구 설계에 대한 추가 정보는 이 기사에 링크된 자연 연구 보고 요약에서 확인할 수 있습니다.

데이터 가용성

본 연구에 사용된 식별되지 않은 원시 심박수, 걸음 수 및 수면 데이터는 연구 데이터 저장소(https://storage.googleapis.com/gbcs-gcp-project-ipop_public/COVID-19/COVID-19-Wearables.zip)에서 다운로드할 수 있습니다. 알고리즘 출력과 그림을 그리는 데 사용된 데이터를 포함한 처리된 데이터는 보충 데이터 1로 제공됩니다.

코드 가용성

이 원고에 사용된 알고리즘의 코드는 [https://github.com/mwgrassgreen/WearableDetection\(RHR-Diff 및 CuSum\)](https://github.com/mwgrassgreen/WearableDetection(RHR-Diff 및 CuSum)) 및 [https://github.com/gireeshkbogu/AnomalyDetect\(HROS-AD\)](https://github.com/gireeshkbogu/AnomalyDetect(HROS-AD)).

접수일: 2020년 7월 1일; 승인: 2020년 10월 1일;

온라인 게시: 2020년 11월 18일

참고자료

- Sethuraman, N., Jeremiah, S. S. & Ryo, A. SARS-CoV-2에 대한 진단 테스트 해석. J.Am. 메드. 협회 <https://doi.org/10.1001/jama.2020.8259> (2020).
- Marins ek, N. 외 개인이 생성한 건강 데이터를 통해 현실 세계의 코로나19와 인플루엔자를 측정합니다. medRxiv <https://doi.org/10.1101/2020.05.28.20115964> (2020).
- Dunn, J., Runge, R. & Snyder, M. 웨어러블과 의료 혁명. 당. 메드. 15, 429-448(2018).
- Kellogg, R. A., Dunn, J. & Snyder, M. P. 정밀 건강을 위한 개인용 옴닉스. 순환 결의안. 122, 1169~1171(2018).
- Li, X. et al. 디지털 건강: 웨어러블 바이오센서를 사용하여 신체 및 활동을 추적하면 유용한 건강 관련 정보가 드러납니다. PLoS Biol. 15, e2001402(2017).
- Peretz, M. V. et al. 심박세동을 식별하기 위한 스마트워치의 대규모 평가. N.Engl. J. Med. 381, 1909~1917(2019).
- Radin, J. M., Wineinger, N. E., Topol, E. J. & Steinhu bl, S. R. 미국에서 인플루엔자 유사 질병에 대한 주 차원의 실시간 감시를 개선하기 위해 웨어러블 장치 데이터 활용: 인구 기반 연구. Lancet Digital Health 2, e85-e93(2020).
- Zhu, G. et al. 대규모 웨어러블 디바이스 데이터를 통해 코로나19 전염병 동향을 예측합니다. 이산 다이나. Nat. Soc. 2020, 6152041(2020).
- Seshadri, D.R. et al. 코로나19용 웨어러블 센서: 원격 환자 모니터링 및 가상 평가를 위해 디지털 인프라를 활용하라는 요청입니다. 앞쪽. 디지털 헬스 <https://doi.org/10.3389/fdgth.2020.00008> (2020).
- Arons, M. M. 등 증상 전 SARS-CoV-2 감염 및 전염

전문 간호 시설에서. N.Engl. J. Med. 382, 2081~2090(2020).
- He, X. et al. 코로나19의 바이러스 배출 및 전염성의 시간적 역학. Nat. 메드. 26, 672-675(2020).
- Witt, D., Kellogg, R., Snyder, M. & Dunn, J. 웨어러블 데이터 분석을 통해 인간 건강에 대한 정보를 제공합니다. 현재 의견. 바이오메드. 영어 9, 28-46(2019).

13. Arias-Castro, E., Castro, R. M., Tanczos, E. & Wang, M. Distribution-free detection of structured anomalies: permutation and rank-based scans. *J. Am. Stat. Assoc.* **113**, 789–801 (2018).
14. Rousseeuw, P. J. & Van Driessen, K. A. Fast algorithm for the minimum covariance determinant estimator. *Technometrics* **41**, 212–223 (1999).
15. Garreta, R. & Moncecchi, G. *Learning scikit-learn: Machine Learning in Python* (Packt Publishing, 2013).
16. Backer, J. A., Klinkenberg, D. & Wallinga, J. Incubation period of 2019 novel coronavirus (2019-nCoV) infections among travellers from Wuhan, China, 20–28 January 2020. *Eurosurveillance* **25**, 2000062 (2020).
17. Lauer, S. A. et al. The incubation period of coronavirus disease 2019 (COVID-19) from publicly reported confirmed cases: estimation and application. *Ann. Intern. Med.* **172**, 577–582 (2020).
18. Haghighyegh, S., Khoshnevis, S., Smolensky, M. H., Diller, K. R. & Castriotta, R. J. Accuracy of wristband Fitbit models in assessing sleep: systematic review and meta-analysis. *J. Med. Internet Res.* **21**, e16273 (2019).
19. Liang, Z. & Chapa-Martell, M. A. Accuracy of Fitbit wristbands in measuring sleep stage transitions and the effect of user-specific factors. *JMIR Mhealth Uhealth* **7**, e13384 (2019).
20. Bi, Q. et al. Epidemiology and transmission of COVID-19 in 391 cases and 1286 of their close contacts in Shenzhen, China: a retrospective cohort study. *Lancet Infect. Dis.* [https://doi.org/10.1016/s1473-3099\(20\)30287-5](https://doi.org/10.1016/s1473-3099(20)30287-5) (2020).
21. Arias-Castro, E. & Wang, M. Distribution-free tests for sparse heterogeneous mixtures. *Test* **26**, 71–94 (2017).
22. Page, E. S. Cumulative sum charts. *Technometrics* **3**, 1–9 (1961).
23. Levin, B. & Kline, J. The CuSum test of homogeneity with an application in spontaneous abortion epidemiology. *Stat. Med.* **4**, 469–488 (1985).
24. Xie, J. et al. Association between hypoxemia and mortality in patients with COVID-19. *Mayo Clin. Proc.* **95**, 1138–1147 (2020).
25. Jouffroy, R., Jost, D. & Prunet, B. Prehospital pulse oximetry: a red flag for early detection of silent hypoxemia in COVID-19 patients. *Critical Care* **24**, 313 (2020).
26. Lorente-Ros, A. et al. Myocardial injury determination improves risk stratification and predicts mortality in COVID-19 patients. *Cardiol. J.* <https://doi.org/10.5603/CJ.a2020.0089> (2020).
27. Chen, R. et al. Personal omics profiling reveals dynamic molecular and medical phenotypes. *Cell* **148**, 1293–1307 (2012).
28. Miller, D. J. et al. Analyzing changes in respiratory rate to predict the risk of COVID-19 infection. Preprint at *medRxiv* <https://doi.org/10.1101/2020.06.18.20131417> (2020).
29. Mathew, D. et al. Deep immune profiling of COVID-19 patients reveals distinct immunotypes with therapeutic implications. *Science* **369**, eabc8511 (2020).
30. Siordia, J. A. Epidemiology and clinical features of COVID-19: a review of current literature. *J. Clin. Virol.* **127**, 104357 (2020).
31. Harris, P. A. et al. Research electronic data capture (REDCap)—a metadata-driven methodology and workflow process for providing translational research informatics support. *J. Biomed. Inform.* **42**, 377–381 (2009).
32. Zhou, W. et al. Longitudinal multi-omics of host–microbe dynamics in prediabetes. *Nature* **569**, 663–671 (2019).
33. Boschetti, A. & Massaron, L. *Python Data Science Essentials* (Packt Publishing, 2015).
34. Wickham, H. *Ggplot2: Elegant Graphics for Data Analysis* (Springer, 2016).
35. Hunter, J. D. Matplotlib: a 2D graphics environment. *Comput. Sci. Eng.* **9**, 90–95 (2007).

Acknowledgements

This work was supported by NIH grants and gifts from the Flu Lab, as well as departmental funding from the Stanford Genetics department. We thank D. Berrent from Survivor Corps for assistance with recruitment, and A. McDonough and T. Helgren from Fitbit Inc. for help with accessing the Fitbit data. We thank Fitbit Inc. for promoting this study and for the donation of devices. The Stanford Healthcare Innovation Lab gratefully acknowledges the support of A. Duisberg. The Google Cloud Platform costs were covered by Google for Education academic research and COVID-19 grant awards. This work was also supported by Case Western Reserve University through departmental start-up funding and the High-Performance Computing award for COVID-19 Research, both awarded to X.L.

Author contributions

M.P.S., T.M., X.L. and A.B. conceived of and designed the study. T.M., X.L., A.B. and M.P.S. supervised the project. T.M. performed the project administration. A.C., E.H., E.M.H., O.D.-R., T.M., B.F., S.K., B.R. and M.P.S. performed the Institutional Review Board review, recruited participants and coordinated the study. T.M., A.W.B., A.C., E.H., O.D.-R., B.F., S.K., M.G. and R.K. collected the survey data. A.A.M., A.B. and A.A. collected and processed the wearable device data. A.B., A.A., A.A.M., A.W.B. and T.M. coordinated and submitted the data. A.B. and A.A. developed the software (the MyPHD app). G.K.B., M.W. and X.L. developed the algorithm. T.M., M.W., A.A.M., G.K.B., A.W.B. and X.L. analysed the data. T.M., M.W., A.A.M., G.K.B., A.W.B., X.L. and M.P.S. prepared the manuscript. All co-authors reviewed and edited the manuscript. A.B.G., B.R., A.B., X.L. and M.P.S. sourced the funding.

Competing interests

M.P.S. is cofounder and a member of the scientific advisory board of Personalis, Qbio, January, SensOmics, Protos, Mirvie and Oralome. He is on the scientific advisory board of Danaher, GenapSys and Jupiter.

Additional information

Supplementary information is available for this paper at <https://doi.org/10.1038/s41551-020-00640-6>.

Correspondence and requests for materials should be addressed to X.L. or M.P.S.

Reprints and permissions information is available at www.nature.com/reprints.

Publisher's note Springer Nature remains neutral with regard to jurisdictional claims in published maps and institutional affiliations.

© The Author(s), under exclusive licence to Springer Nature Limited 2020

13. Arias-Castro, E., Castro, R. M., Tanczos, E. & Wang, M. 구조적 변칙의 배포 없는 탐지: 순열 및 순위 기반 스캔. *J. Am. 통계 협회* 113, 789-801(2018). 14. Rousseeuw, P. J. & Van Driessen, K. A. 최소 공분산 결정자 추정을 위한 빠른 알고리즘. *기술* 41, 212-223 (1999). 15. Garreta, R. & Moncecchi, G. scikit-learn 학습: Python의 기계 학습(Packt Publishing, 2013). 16. Backer, J. A., Klinkenberg, D. & Wallinga, J. 중국 우한에서 온 여행 중 2019년 신종 코로나바이러스(2019-nCoV) 감염의 잠복기, 2020년 1월 20~28일. *Eurosurveillance* 25, 2000062(2020). 17. Lauer, S. A. 등 공개적으로 보고된 확인 사례의 코로나바이러스 질병 2019(COVID-19)의 잠복기: 추정 및 적용. *앤. 인턴. 메드.* 172, 577-582(2020). 18. Haghighyeh, S., Khoshnevis, S., Smolensky, M. H., Diller, K. R. & Castriotta, R. J. 수면 평가에서 손목 밴드 Fitbit 모델의 정확도: 체계적 검토

그리고 메타 분석. *J. Med. 인터넷 해상도.* 21, e16273(2019). 19. Liang, Z. & Chapa-Martell, M. A. Fitbit 손목밴드 측정 정확도

수면 단계 전환 및 사용자별 요인의 영향. *JMIR 엠헬스 유헬스* 7, e13384(2019). 20. Bi, Q. et al. 중국 심천에서 391건의 사례와 밀접 접촉자 1,286명의 COVID-19 역학 및 전파: 후향적 코호트 연구. *랜셋 감염. 디스.* [https://doi.org/10.1016/s1473-3099\(20\)30287-5](https://doi.org/10.1016/s1473-3099(20)30287-5) (2020). 21. Arias-Castro, E. & Wang, M. 희박한 이중 혼합물에 대한 무분포 테스트. *테스트* 26, 71-94(2017). 22. 페이지, E. S. 누적 합계 차트. *기술* 3, 1-9(1961). 23. Levin, B. & Kline, J. 자연 유산 역학에 적용하여 동질성에 대한 CuSum 테스트. *통계 메드.* 4, 469-488(1985). 24. Xie, J. 등 al. 코로나19 환자의 저산소혈증과 사망률 사이의 연관성. *메이요 클린. 진행* 95, 1138-1147(2020). 25. Jouffroy, R., Jost, D. & Prunet, B. 병원 전 맥박 산소 측정법: 코로나19 환자의 무증상 저산소증 조기 발견을 위한 위험 신호. *중환자 치료* 24, 313(2020). 26. Lorente-Ros, A. 등. 심근 손상 판정은 위험 계층화를 개선하고 코로나19 환자의 사망률을 예측합니다. *카디올. J.* <https://doi.org/10.5603/CJ.a2020.0089> (2020). 27. Chen, R. 외. 개인 오믹스 프로파일링은 동적 분자 및 의학적 표현형을 드러냅니다. *셀* 148, 1293-1307(2012). 28. Miller, D. J. 외. 호흡수의 변화를 분석하여 코로나19 감염 위험을 예측합니다. *medRxiv* <https://doi.org/10.1101/2020.06.18.20131417> (2020). 29. Mathe, D. 등. 코로나19 환자의 심층 면역 프로파일링은 치료적 의미가 있는 뚜렷한 면역형을 드러냅니다. *과학* 369, eabc8511(2020). 30. Siordia, J. A. COVID-19의 역학 및 임상 특징: 최신 문헌 검토. *J. 클린. 비볼.* 127, 104357(2020). 31. Harris, P. A. 외. 연구 전자 데이터 캡처(REDCap) - 중개 연구 정보학 지원을 제공하기 위한 메타데이터 기반 방법론 및 작업 흐름 프로세스입니다. *J. Biomed. 알리다.* 42, 377-381 (2009).

32. Zhou, W. 외. 당뇨병 전증에서 숙주-미생물 역학의 종방향 다중 오믹스. *자연* 569, 663-671 (2019). 33. Boschetti, A. & Massaron, L. Python 데이터 과학 필수사항(Packt Publishing, 2015). 34. Wickham, H. Ggplot2: 데이터 분석을 위한 우아한 그래픽(Springer, 2016). 35. Hunter, J. D. Matplotlib: 2D 그래픽 환경. *계산. 과학. 영어* 9, 90-95 (2007).

감사의 말

이 작업은 NIH 보조금 및 Flu Lab의 선물과 Stanford Genetics 부서의 부서 자금으로 지원되었습니다. 채용에 도움을 준 Survivor Corps의 D. Berrent와 Fitbit 데이터 액세스에 도움을 준 Fitbit Inc.의 A. McDonough와 T. Helgren에게 감사드립니다. 본 연구를 홍보하고 기기를 기부해주신 Fitbit Inc.에 감사드립니다. Stanford Healthcare Innovation Lab은 A. Duisberg의 지원에 감사드립니다. Google Cloud Platform 비용은 Google for Education 학술 연구 및 코로나19 지원금으로 충당되었습니다. 이 작업은 또한 부서별 창업 자금 지원과 코로나19 연구에 대한 고성능 컴퓨팅 상을 통해 케이스 웨스턴 리저브 대학교(Case Western Reserve University)의 지원을 받았습니다. 두 상 모두 X.L.

저자 기여

M.P.S., T.M., X.L. 그리고 A.B. 연구를 구상하고 설계했습니다. T.M., X.L., A.B. 그리고 M.P.S. 프로젝트를 감독했습니다. T.M. 프로젝트 관리를 수행했습니다. A.C., E.H., E.M.H., O.D.-R., T.M., B.F., S.K., B.R. 그리고 M.P.S. 기관 검토 위원회(Institutional Review Board) 검토를 수행하고 참가자를 모집하고 연구를 조정했습니다. T.M., A.W.B., A.C., E.H., O.D.-R., B.F., S.K., M.G. 그리고 R.K. 설문조사 데이터를 수집했습니다. A.A.M., A.B. 그리고 A.A. 웨어러블 기기 데이터를 수집하고 처리했습니다. A.B., A.A., A.A.M., A.W.B. 그리고 T.M. 데이터를 조정하고 제출했습니다. A.B. 그리고 A.A. 소프트웨어(MyPHD 앱)를 개발했습니다. G.K.B., M.W. 및 X.L. 알고리즘을 개발했습니다. T.M., M.W., A.A.M., G.K.B., A.W.B. 그리고 X.L. 데이터를 분석했습니다. T.M., M.W., A.A.M., G.K.B., A.W.B., X.L. 그리고 M.P.S. 원고를 준비했습니다. 모든 공동저자는 원고를 검토하고 편집했습니다. A.B.G., B.R., A.B., X.L. 그리고 M.P.S. 자금을 조달했습니다.

이해관계 경쟁

M.P.S. Personalis, Qbio, January, SensOmics, Protos, Mirvie 및 Oralome의 공동 창립자이자 과학 자문 위원회의 회원입니다. 그는 Danaher, GenapSys 및 Jupiter의 과학 자문 위원회에 속해 있습니다.

추가 정보

이 문서에 대한 추가 정보는 <https://doi.org/10.1038/s41551-020-00640-6>에서 확인할 수 있습니다.

자료에 대한 서신 및 요청은 X.L.로 보내야 합니다. 또는 M.P.S. 재인쇄 및 허가 정보는 www.nature.com/reprints에서 확인할 수 있습니다. 발행인의 메모 Springer Nature는 발행된 지도 및 기관 제휴에 대한 관찰권 주장과 관련하여 중립을 유지합니다. © 저자(들), Springer Nature Limited 2020에 독점 라이선스 적용

Reporting Summary

Nature Research wishes to improve the reproducibility of the work that we publish. This form provides structure for consistency and transparency in reporting. For further information on Nature Research policies, see our [Editorial Policies](#) and the [Editorial Policy Checklist](#).

Statistics

For all statistical analyses, confirm that the following items are present in the figure legend, table legend, main text, or Methods section.

n/a Confirmed

- | | | |
|-------------------------------------|-------------------------------------|--|
| ☐ | ☒ | The exact sample size (n) for each experimental group/condition, given as a discrete number and unit of measurement |
| ☐ | ☒ | A statement on whether measurements were taken from distinct samples or whether the same sample was measured repeatedly |
| ☐ | ☒ | The statistical test(s) used AND whether they are one- or two-sided
<i>Only common tests should be described solely by name; describe more complex techniques in the Methods section.</i> |
| ☐ | ☒ | A description of all covariates tested |
| ☐ | ☒ | A description of any assumptions or corrections, such as tests of normality and adjustment for multiple comparisons |
| ☐ | ☒ | A full description of the statistical parameters including central tendency (e.g. means) or other basic estimates (e.g. regression coefficient) AND variation (e.g. standard deviation) or associated estimates of uncertainty (e.g. confidence intervals) |
| ☐ | ☒ | For null hypothesis testing, the test statistic (e.g. F , t , r) with confidence intervals, effect sizes, degrees of freedom and P value noted
<i>Give P values as exact values whenever suitable.</i> |
| ☒ | ☐ | For Bayesian analysis, information on the choice of priors and Markov chain Monte Carlo settings |
| ☒ | ☐ | For hierarchical and complex designs, identification of the appropriate level for tests and full reporting of outcomes |
| ☒ | ☐ | Estimates of effect sizes (e.g. Cohen's d , Pearson's r), indicating how they were calculated |

Our web collection on [statistics for biologists](#) contains articles on many of the points above.

Software and code

Policy information about [availability of computer code](#)

Data collection REDCap, custom study app, and MyPHD (available in the iOS and Android app stores).

Data analysis Matlab, Python 3, Python packages scikitlearn, matplotlib, R3.1-142 for LMM, R packages nlme, ggplot2. Code for the algorithms used in the manuscript is available at <https://github.com/mwgrassgreen/WearableDetection> (RHR-Diff and CuSum) and <https://github.com/gireeshkbogu/AnomalyDetect> (HROS-AD).

For manuscripts utilizing custom algorithms or software that are central to the research but not yet described in published literature, software must be made available to editors and reviewers. We strongly encourage code deposition in a community repository (e.g. GitHub). See the Nature Research [guidelines for submitting code & software](#) for further information.

Data

Policy information about [availability of data](#)

All manuscripts must include a [data availability statement](#). This statement should provide the following information, where applicable:

- Accession codes, unique identifiers, or web links for publicly available datasets
- A list of figures that have associated raw data
- A description of any restrictions on data availability

De-identified raw heart rate, steps, and sleep data used in this study can be downloaded from the study data repository (https://storage.googleapis.com/gbbsc-gcp-project-ipop_public/COVID-19/COVID-19-Wearables.zip). Processed data, including algorithm outputs, and data used for plotting figures are provided as a Supplementary Dataset.

보고 요약

Nature Research는 우리가 출판하는 작업의 재현성을 향상시키고자 합니다. 이 양식은 보고의 일관성과 투명성을 위한 구조를 제공합니다. Nature Research 정책에 대한 자세한 내용은 편집 정책 및 편집 정책 체크리스트를 참조하세요.

스테이션

모든 통계 분석에 대해 그림 범례, 표 범례, 본문 또는 방법 섹션에 다음 항목이 있는지 확인하십시오. . 해당 사항 없음 확인 개별 숫자 및 측정 단위로 제공된 각 실험 그룹/조건에 대한 정확한 표본 크기(n) 서로 다른 표본에서 측정을 수행했는지 또는 동일한 표본을 반복적으로 측정했는지에 대한 설명 사용된 기본 테스트 AND 단측 또는 양면인지 여부

Only common tests should be described solely by name; describe more complex techniques in the Methods section. 테스트된 모든 공변량에 대한 설명 다음과 같은 가정 또는 수정 사항에 대한 설명 다중 비교를 위한 정규성 테스트 및 조정 중심 경향(예: 평균) 또는 기타 기본 추정치(예: 회귀 계수) 및 변형(예: 표준 편차) 또는 관련 불확실성 추정치(예: 신뢰 구간)를 포함한 통계 매개변수에 대한 전체 설명 귀무 가설 테스트의 경우 테스트 통계 (예: F, t, r) 신뢰 구간, 효과 크기, 자유도 및 P 값이 기록됨 Give P values as exact values whenever suitable. 베이저안 분석의 경우 사전 및 마르코프 체인 몬테 카를로 설정 선택에 대한 정보 계층적이고 복잡한 설계의 경우 테스트에 적합한 수준을 식별하고 결과의 전체 보고 효과 크기 추정 (예: Cohen의 d, Pearson의 r), 계산 방법을 나타냅니다.

☒ ☒
☐ ☒
☐ ☒
☐ ☒
☒ ☐
☒ ☐
☒ ☐

Our web collection on [statistics for biologists](#) contains articles on many of the points above.

소프트웨어 및 코드

컴퓨터 코드 가용성에 대한 정책 정보

Data collection	REDCap, custom study app, and MyPHD (available in the iOS and Android app stores).
Data analysis	Matlab, Python 3, Python packages scikitlearn, matplotlib, R3.1-142 for LMM, R packages nlme, ggplot2. Code for the algorithms used in the manuscript is available at https://github.com/mwgrassgreen/WearableDetection (RHR-Diff and CuSum) and https://github.com/gireeshkbogu/AnomalyDetect (HROS-AD).

For manuscripts utilizing custom algorithms or software that are central to the research but not yet described in published literature, software must be made available to editors and reviewers. We strongly encourage code deposition in a community repository (e.g. GitHub). See the Nature Research [guidelines for submitting code & software](#) for further information.

데이터

데이터 가용성에 관한 정책 정보

모든 원고에는 데이터 가용성 설명이 포함되어야 합니다. 이 설명은 해당되는 경우 다음 정보를 제공해야 합니다. - 공개적으로 사용 가능한 데이터 세트에 대한 액세스 코드, 고유 식별자 또는 웹 링크 - 관련 원시 데이터가 있는 수치 목록 - 데이터 가용성에 대한 제한 사항에 대한 설명

본 연구에 사용된 식별되지 않은 원시 심박수, 걸음 수 및 수면 데이터는 연구 데이터 저장소(https://storage.googleapis.com/gbsec-gcp-project-ipop_public/COVID-19/COVID-19-Wearables.zip)에서 다운로드할 수 있습니다. 알고리즘 출력을 포함한 처리된 데이터와 플로팅 수치에 사용되는 데이터는 보충 데이터 세트로 제공됩니다.

Field-specific reporting

Please select the one below that is the best fit for your research. If you are not sure, read the appropriate sections before making your selection.

☒ Life sciences ☐ Behavioural & social sciences ☐ Ecological, evolutionary & environmental sciences

For a reference copy of the document with all sections, see [nature.com/documents/nr-reporting-summary-flat.pdf](https://www.nature.com/documents/nr-reporting-summary-flat.pdf)

Life sciences study design

All studies must disclose on these points even when the disclosure is negative.

Sample size	The most crucial aspect of the study was to compare the participant's continuous time-series data in sliding time windows or intervals to their own baseline to detect COVID-19 infection. Significance statistics and p-values were calculated for successive time intervals within an individual. Thus, in terms of sample size, the crucial aspect was to ensure maximal high-frequency sampling within an individual before and around the time of COVID-19 infection. For analysis, we only used individuals who had (1) confirmed COVID-19 diagnoses, (2) were able to provide symptom onset and/or diagnosis dates, and (3) had data recorded from wearables spanning and adjacent to the dates of the COVID-19 infection. We recruited as broadly as possible, and tried to maximize the number of individuals who fit these criteria, but were limited by the infection rates during the recruitment period of the study. Out of the 5,262 individuals enrolled, and 4,642 who were wearing fitness trackers, we identified 114 individuals with COVID-19 infection. Of these, 32 individuals were wearing the devices around the infection time; hence, this subset of individuals was chosen for analysis. We also added 73 potentially healthy participants as a 'control' dataset, and 13 participants with 15 other non-COVID-19 illnesses for comparison.
Data exclusions	All available data were used for analyses. There were no data excluded from the analyses, except in cases where data from the wearables was missing during or just prior to a self-reported COVID-19 infection.
Replication	This was an observational study in which we did not perform experiments.
Randomization	Participants were not randomized. There was no allocation to groups. We recruited individuals from 3 groups, COVID-19 positive, self-reported healthy, and individuals with other non-COVID-19 illnesses, but the only group-based analysis was to compare alarm duration and intensity in each group. The main detection algorithms were run on each individual participant's data separately. Each participant's longitudinal data as used to construct participant-specific heart-rate baselines, and deviations from the baseline were calculated in a participant-specific manner. In some analyses (mainly mixed effects models for sleep and steps analysis) we controlled for participant ID and day of annotation.
Blinding	Blinding was not relevant to the study (that is, there was no allocation to groups or interventions).

Reporting for specific materials, systems and methods

We require information from authors about some types of materials, experimental systems and methods used in many studies. Here, indicate whether each material, system or method listed is relevant to your study. If you are not sure if a list item applies to your research, read the appropriate section before selecting a response.

Materials & experimental systems

n/a	Involved in the study
☒	☐ Antibodies
☒	☐ Eukaryotic cell lines
☒	☐ Palaeontology and archaeology
☒	☐ Animals and other organisms
☐	☒ Human research participants
☒	☐ Clinical data
☒	☐ Dual use research of concern

Methods

n/a	Involved in the study
☒	☐ ChIP-seq
☒	☐ Flow cytometry
☒	☐ MRI-based neuroimaging

Human research participants

Policy information about [studies involving human research participants](#)

Population characteristics	The mean age of the 5,262 participants at time of enrollment was 44 (range, 18–88); 55.3% were women. However, out of the 32 individuals analysed, 25 (78.1%) were women. The self-reported ethnic distribution of the full cohort was 74.9% European, 3.9% East Asian, 2.9% African American, 19.2% Mixed/Other/Undeclared. The most common self-reported health conditions at entry were respiratory lung disease, high blood pressure, high cholesterol, and allergy/immune disease.
Recruitment	Participants were recruited by social media, word of mouth, and through Stanford Healthcare. Our inclusion criteria screened for people who either had a COVID-19 infection or were at high risk through living situation or employment, and were wearing fitness trackers. Since social media was one of the recruitment methods used, there could be a bias towards people

분야별 보고

아래에서 b를 선택하세요.

귀하의 연구에 가장 적합합니다. 확실하지 않은 경우 해당 섹션을 [원격참지](#) 외에 주의 사항을 확인하세요.

☒ 생명 과학 행동 및 사회 과학 생태, 진화 및 환경 과학 ☐

모든 섹션이 포함된 문서의 참조 사본을 보려면 [nature.com/documents/nr-reporting-summary-plat.pdf](https://www.nature.com/documents/nr-reporting-summary-plat.pdf)를 참조하세요.

생명과학 연구 설계

모든 연구는 공개가 부정적이더라도 이러한 사항을 공개해야 합니다.

Sample size

The most crucial aspect of the study was to compare the participant's continuous time-series data in sliding time windows or intervals to their own baseline to detect COVID-19 infection. Significance statistics and p-values were calculated for successive time intervals within an individual. Thus, in terms of sample size, the crucial aspect was to ensure maximal high-frequency sampling within an individual before and around the time of COVID-19 infection. For analysis, we only used individuals who had (1) confirmed COVID-19 diagnoses, (2) were able to provide symptom onset and/or diagnosis dates, and (3) had data recorded from wearables spanning and adjacent to the dates of the COVID-19 infection. We recruited as broadly as possible, and tried to maximize the number of individuals who fit these criteria, but were limited by the infection rates during the recruitment period of the study. Out of the 5,262 individuals enrolled, and 4,642 who were wearing fitness trackers, we identified 114 individuals with COVID-19 infection. Of these, 32 individuals were wearing the devices around the infection time; hence, this subset of individuals was chosen for analysis. We also added 73 potentially healthy participants as a 'control' dataset, and 13 participants with 15 other non-COVID-19 illnesses for comparison.

Data exclusions

All available data were used for analyses. There were no data excluded from the analyses, except in cases where data from the wearables was missing during or just prior to a self-reported COVID-19 infection.

Replication

This was an observational study in which we did not perform experiments.

Randomization

Participants were not randomized. There was no allocation to groups. We recruited individuals from 3 groups, COVID-19 positive, self-reported healthy, and individuals with other non-COVID-19 illnesses, but the only group-based analysis was to compare alarm duration and intensity in each group. The main detection algorithms were run on each individual participant's data separately. Each participant's longitudinal data as used to construct participant-specific heart-rate baselines, and deviations from the baseline were calculated in a participant-specific manner. In some analyses (mainly mixed effects models for sleep and steps analysis) we controlled for participant ID and day of annotation.

Blinding

Blinding was not relevant to the study (that is, there was no allocation to groups or interventions).

특정 재료, 시스템 및 방법에 대한 보고

우리는 [이 가이드](#)에 사용되는 일부 유형의 재료, 실험 시스템 및 방법에 대한 저자의 정보가 있습니다. 여기에는 각 물질의 여부를 나타냅니다. [이 가이드](#)의 시스템 또는 나열된 방법이 귀하의 연구와 관련이 있습니다. 목록 항목이 귀하의 연구에 적용되는지 확실하지 않은 경우 응답을 선택하기 전에 해당 섹션을 읽으십시오.

Materials & experimental systems

- | | |
|-------------------------------------|---|
| n/a | Involved in the study |
| ☒ | ☐ Antibodies |
| ☒ | ☐ Eukaryotic cell lines |
| ☒ | ☐ Palaeontology and archaeology |
| ☒ | ☐ Animals and other organisms |
| ☐ | ☒ Human research participants |
| ☒ | ☐ Clinical data |
| ☒ | ☐ Dual use research of concern |

Methods

- | | |
|-------------------------------------|---|
| n/a | Involved in the study |
| ☒ | ☐ ChIP-seq |
| ☒ | ☐ Flow cytometry |
| ☒ | ☐ MRI-based neuroimaging |

인간 연구 참가자

인간 연구 참여자를 대상으로 한 연구에 관한 정책 정보

Population characteristics

The mean age of the 5,262 participants at time of enrollment was 44 (range, 18–88); 55.3% were women. However, out of the 32 individuals analysed, 25 (78.1%) were women. The self-reported ethnic distribution of the full cohort was 74.9% European, 3.9% East Asian, 2.9% African American, 19.2% Mixed/Other/Undeclared. The most common self-reported health conditions at entry were respiratory lung disease, high blood pressure, high cholesterol, and allergy/immune disease.

Recruitment

Participants were recruited by social media, word of mouth, and through Stanford Healthcare. Our inclusion criteria screened for people who either had a COVID-19 infection or were at high risk through living situation or employment, and were wearing fitness trackers. Since social media was one of the recruitment methods used, there could be a bias towards people

who use social media. The use of wearable devices likely biases our study cohort towards individuals of higher socioeconomic strata, who are more likely to be able to afford the devices. It is also possible that individuals who own wearables devices are more interested in using wearable devices to monitor both activity and health. However, we do not think that the results of our algorithm are affected by interest in wearables devices.

Ethics oversight

Stanford University Institutional Review Board (IRB 55577, IRB 23602).

Note that full information on the approval of the study protocol must also be provided in the manuscript.

소셜 미디어를 사용하는 사람. 웨어러블 기기의 사용은 기기를 구입할 수 있는 가능성이 더 높은 사회 경제적 계층의 개인에게 우리 연구 집단을 편향시킬 가능성이 높습니다. 웨어러블 장치를 소유한 개인은 웨어러블 장치를 사용하여 활동과 건강을 모두 모니터링하는 데 더 관심이 있을 수도 있습니다. 하지만 우리의 알고리즘 결과가 웨어러블 기기에 대한 관심도에 영향을 받지 않는다고 생각합니다.

Ethics oversight

스탠포드 대학 기관 검토 위원회(IRB 55577, IRB 23602).

Note that full information on the approval of the study protocol must also be provided in the manuscript.