



Wearable sensor data and self-reported symptoms for COVID-19 detection

Giorgio Quer^{1,3}✉, Jennifer M. Radin^{1,3}, Matteo Gadaleta^{1,3}, Katie Baca-Motes¹, Lauren Ariniello¹, Edward Ramos^{1,2}, Vik Kheterpal^{1,2}, Eric J. Topol¹ and Steven R. Steinhubl¹

Traditional screening for COVID-19 typically includes survey questions about symptoms and travel history, as well as temperature measurements. Here, we explore whether personal sensor data collected over time may help identify subtle changes indicating an infection, such as in patients with COVID-19. We have developed a smartphone app that collects smartwatch and activity tracker data, as well as self-reported symptoms and diagnostic testing results, from individuals in the United States, and have assessed whether symptom and sensor data can differentiate COVID-19 positive versus negative cases in symptomatic individuals. We enrolled 30,529 participants between 25 March and 7 June 2020, of whom 3,811 reported symptoms. Of these symptomatic individuals, 54 reported testing positive and 279 negative for COVID-19. We found that a combination of symptom and sensor data resulted in an area under the curve (AUC) of 0.80 (interquartile range (IQR): 0.73–0.86) for discriminating between symptomatic individuals who were positive or negative for COVID-19, a performance that is significantly better ($P < 0.01$) than a model¹ that considers symptoms alone (AUC = 0.71; IQR: 0.63–0.79). Such continuous, passively captured data may be complementary to virus testing, which is generally a one-off or infrequent sampling assay.

Owing to the current lack of fast and reliable testing, one of the greatest challenges for preventing transmission of SARS-CoV-2 is the ability to quickly identify, trace and isolate cases before they can further spread the infection to susceptible individuals. As regions across the United States start implementing measures to reopen businesses, schools and other activities, many rely on current screening practices for COVID-19, which typically include a combination of symptom and travel-related survey questions and temperature measurements. However, this method is likely to miss pre-symptomatic or asymptomatic cases, which make up ~40–45% of those infected with SARS-CoV-2, and who can still be infectious^{1,2}. An elevated temperature ($>100^{\circ}\text{F}$ ($>37.8^{\circ}\text{C}$)) is not as common as frequently believed, being present in only 12% of individuals who tested positive for COVID-19³ and just 31% of patients hospitalized with COVID-19 (at the time of admission)⁴.

Smartwatches and activity trackers, which are now worn by one in five Americans⁵, can improve our ability to objectively characterize each individual's unique baseline for resting heart rate⁶, sleep⁷ and activity and can therefore be used to identify subtle changes in that user's data that may indicate that they are coming down with a viral illness. Previous research from our group has shown that this method, when aggregated at the population level, can

significantly improve real-time predictions for influenza-like illness⁸. Consequently, we created a prospective app-based research platform, called DETECT (Digital Engagement and Tracking for Early Control and Treatment), where individuals can share their sensor data, self-reported symptoms, diagnoses and electronic health record data with the aim of improving our ability to identify and track individual- and population-level viral illnesses, including COVID-19.

A previously reported study that captured symptom data in over 18,000 SARS-CoV-2-tested individuals via a smartphone-based app found that symptoms were able to help distinguish between individuals with and without COVID-19¹. The aim of this study is to investigate if the addition of individual changes in sensor data to symptom data can be used to improve our ability to identify COVID-19-positive versus COVID-19-negative cases among participants who self-reported symptoms.

Between 25 March and 7 June 2020, our research study enrolled 30,529 individuals, with representation from every state in the United States. Among the consented individuals, 62.0% are female and 12.8% are 65 or more years old. Of the participants, 78.4% connected their Fitbit devices to the study app, 31.2% connected the data from the Apple HealthKit, while 8.1% connected data from Google Fit (note that an individual can connect to multiple platforms). In addition, 3,811 reported at least one symptom (12.5%); of those, 54 also reported testing positive for COVID-19 and 279 reported testing negative. The numbers of days per different data type and data aggregator system are reported in Table 1, while the symptoms distribution for symptomatic individuals tested for COVID-19, or not tested, is shown in Fig. 1.

A minority of symptomatic participants (30.3%) who tested for COVID-19 had a resting heart rate (RHR) greater than two standard deviations above the average baseline value during symptoms. The change in RHR on its own (Table 1) did not allow significant discrimination between COVID-19-positive and COVID-19-negative participants using the RHRMetric (area under the curve (AUC) of 0.52 (interquartile range (IQR): 0.41–0.64)) (Fig. 2a).

Sleep and activity did show a significant difference among the two groups (Table 1), with an AUC of 0.68 (0.57–0.79) for the SleepMetric (Fig. 2b) and 0.69 (0.61–0.77) for the ActivityMetric (Fig. 2c), supporting that the sleep and activity of COVID-19 positive participants were impacted significantly more than COVID-19-negative participants. Sleep and activity are slightly correlated, with a negative correlation coefficient of -0.28 , $P < 0.01$.

To evaluate the contribution of all the data types commonly available through personal devices, we combined the RHR, sleep and activity metrics in a single metric (SensorMetric, Fig. 2d). This

¹Scripps Research Translational Institute, La Jolla, CA, USA. ²CareEvolution, Ann Arbor, MI, USA. ³These authors contributed equally: Giorgio Quer, Jennifer M. Radin, Matteo Gadaleta. ✉e-mail: gquer@scripps.edu



코로나19 감지를 위한 웨어러블 센서 데이터 및 자가 보고 증상

Giorgio Quer^{1,3}, Jennifer M. Radin^{1,3}, Matteo Gadaleta^{1,3}, Katie Baca-Motes¹, Lauren Arinello¹, Edward Ramos^{1,2}, Vik Kheterpal², Eric J. Topol¹ 및 Steven R. Steinhubl¹

전통적인 코로나19 검사에는 일반적으로 증상, 여행 이력, 체온 측정에 대한 설문조사가 포함됩니다. 여기에서는 시간이 지남에 따라 수집된 개인 센서 데이터가 코로나19 환자와 같이 감염을 나타내는 미묘한 변화를 식별하는 데 도움이 될 수 있는지 살펴봅니다. 우리는 미국 내 개인으로부터 스마트워치 및 활동 추적기 데이터는 물론 자가 보고된 증상 및 진단 테스트 결과를 수집하는 스마트폰 앱을 개발했으며, 증상 및 센서 데이터가 증상이 있는 개인의 코로나19 양성 사례와 음성 사례를 구별할 수 있는지 평가했습니다. 2020년 3월 25일부터 6월 7일까지 30,529명의 참가자를 등록했으며 그 중 3,811명이 증상을 보고했습니다. 이들 유증상자 중 54명이 코로나19 양성 판정을 받았고 279명이 음성 판정을 받았다고 보고했습니다. 우리는 증상과 센서 데이터의 조합으로 인해 코로나19 양성 또는 음성 증상이 있는 개인을 구별하기 위한 곡선 아래 면적(AUC)이 0.80(사분위수 범위(IQR): 0.73–0.86)이라는 것을 발견했습니다. 이는 증상만 고려하는 모델(AUC=0.71; IQR: 0.63–0.79). 이러한 연속적이고 수동적으로 캡처된 데이터는 일반적으로 일회성이거나 드물게 샘플링되는 바이러스 테스트를 보완할 수 있습니다.

현재 빠르고 신뢰할 수 있는 테스트가 부족하기 때문에 SARS-CoV-2 전파를 예방하기 위한 가장 큰 과제 중 하나는 감염이 취약한 개인에게 추가로 확산되기 전에 사례를 신속하게 식별, 추적 및 격리하는 능력입니다. 미국 전역의 지역에서 기업, 학교 및 기타 활동을 재개하기 위한 조치를 시행하기 시작하면서 많은 사람들이 일반적으로 증상 및 여행 관련 설문 조사 질문과 체온 측정을 결합한 현재의 COVID-19 검사 관행에 의존하고 있습니다. 그러나 이 방법은 SARS-CoV-2에 감염된 사람의 ~40~45%를 차지하고 여전히 감염 가능성이 있는^{1,2} 사전 증상 또는 무증상 사례를 놓칠 가능성이 높습니다. 발열(>100 °F(>37.8 °C))은 흔히 생각하는 것만큼 일반적이지 않습니다. 이는 코로나19 양성 반응을 보인 개인의 12%에서만 나타나며³ 코로나19로 입원한 환자의 31%(입원 당시)⁴에 불과합니다.

현재 미국인 5명 중 1명이 착용하고 있는 스마트워치와 활동 추적기는⁵ 안정시 심박수⁶, 수면⁷ 및 활동에 대한 각 개인의 고유한 기준을 객관적으로 특성화하는 능력을 향상시킬 수 있으므로 바이러스성 질병에 걸렸음을 나타낼 수 있는 사용자 데이터의 미묘한 변화를 식별하는 데 사용할 수 있습니다. 우리 그룹의 이전 연구에서는 이 방법을 인구 수준에서 집계할 때 다음이 가능하다는 것을 보여주었습니다.

인플루엔자 유사 질병에 대한 실시간 예측을 크게 향상시킵니다.⁸ 결과적으로 우리는 DETECT(조기 통제 및 치료를 위한 디지털 참여 및 추적)라는 유망한 앱 기반 연구 플랫폼을 만들었습니다. 이 플랫폼에서는 개인이 코로나19를 포함한 개인 및 인구 수준의 바이러스 질병을 식별하고 추적하는 능력을 향상시키기 위해 센서 데이터, 자가 보고 증상, 진단 및 전자 건강 기록 데이터를 공유할 수 있습니다.

스마트폰 기반 앱을 통해 SARS-CoV-2 검사를 받은 18,000명 이상의 개인의 증상 데이터를 수집한 이전에 보고된 연구에서는 증상이 COVID-19가 있는 개인과 없는 개인을 구별하는 데 도움이 될 수 있음을 발견했습니다.¹ 이 연구의 목적은 증상 데이터에 센서 데이터의 개별 변경 사항을 추가하여 증상을 자가 보고한 참가자 중에서 코로나19 양성 사례와 코로나19 음성 사례를 식별하는 능력을 향상시키는 데 사용될 수 있는지 조사하는 것입니다.

2020년 3월 25일부터 6월 7일 사이에 우리의 연구 조사에는 미국의 모든 주에서 대표되는 30,529명의 개인이 등록되었습니다. 동의한 개인 중 62.0%가 여성이고, 12.8%가 65세 이상입니다. 참가자 중 78.4%는 Fitbit 장치를 연구 앱에 연결했고, 31.2%는 Apple HealthKit의 데이터를 연결했으며, 8.1%는 Google Fit의 데이터를 연결했습니다(개인은 여러 플랫폼에 연결할 수 있음). 또한 3,811명(12.5%)이 하나 이상의 증상을 보고했습니다. 그 중 54명은 코로나19 양성 반응을 보였으며 279명은 음성 반응을 보였습니다. 다양한 데이터 유형 및 데이터 수집 시스템별 일수는 표 1에 보고되어 있으며, 코로나19 검사를 받은 유증상자 또는 검사를 받지 않은 개인의 증상 분포는 그림 1에 나와 있습니다.

코로나19 검사를 받은 증상이 있는 참가자 중 소수(30.3%)는 증상이 있는 동안 안정시 심박수(RHR)가 평균 기준치보다 2 표준편차 이상 높았습니다. RHR 자체의 변화(표 1)는 RHRMetric(곡선 아래 면적(AUC) 0.52(사분위간 범위(IQR): 0.41~0.64))을 사용하여 코로나19 양성 참가자와 코로나19 음성 참가자 사이에 유의미한 차별을 허용하지 않았습니다(그림 2a).

수면과 활동은 SleepMetric(그림 2b)의 AUC가 0.68(0.57–0.79), ActivityMetric(그림 2c)의 AUC가 0.69(0.61–0.77)로 두 그룹(표 1) 간에 유의미한 차이를 보여주었는데, 이는 코로나19 양성 참가자의 수면과 활동이 코로나19 음성 참가자보다 훨씬 더 큰 영향을 받았다는 것을 뒷받침합니다. 수면과 활동은 음의 상관관계 수 -0.28, $P < 0.01$ 로 약간의 상관관계가 있습니다.

개인 장치를 통해 일반적으로 사용할 수 있는 모든 데이터 유형의 기여도를 평가하기 위해 RHR, 수면 및 활동 측정 항목을 단일 측정 항목으로 결합했습니다(SensorMetric, 그림 2d). 이것

¹Scripps Research Translational Institute, La Jolla, CA, USA. ²CareEvolution, Ann Arbor, MI, USA. ³These authors contributed equally: Giorgio Quer, Jennifer M. Radin, Matteo Gadaleta. [✉]e-mail: gquer@scripps.edu

Table 1 | Participants' characteristics and device data

	Total	Any symptom	COVID-19 positive	COVID-19 negative	P value
Demographic data					
Number of participants	30,529	3,811	54	279	–
Female	18,922 (62.0%)	2,828 (74.2%)	43 (79.6%)	199 (71.3%)	0.65
Age group (years)					
Under 35	7,052 (23.1%)	1,184 (31.1%)	17 (31.5%)	71 (25.4%)	0.52
35 to 50	10,357 (33.9%)	1,522 (39.9%)	23 (42.6%)	121 (43.4%)	1.00
51 to 65	9,038 (29.6%)	857 (22.5%)	12 (22.2%)	64 (22.9%)	1.00
Over 65	3,899 (12.8%)	219 (5.7%)	1 (1.9%)	21 (7.5%)	0.22
Fitbit users	23,922 (78.4%)	3,306 (86.7%)	46 (85.2%)	237 (84.9%)	1.00
Apple users	9,522 (31.2%)	1,219 (32.0%)	21 (38.9%)	94 (33.7%)	0.66
Sensor data					
Available days (IQR)					
RHR	322 (131–387)	325 (153–396)	312 (98–377)	300 (119–392)	0.70
Sleep	249 (48–373)	273 (105–383)	283 (52–362)	246 (70–375)	0.56
Activity	394 (370–412)	407 (379–415)	404 (375–410)	401 (374–413)	0.57
Mean change (s.d.)					
RHR (b.p.m.)	0.0 (2.84)	0.40 (3.18)	1.15 (4.83)	0.61 (3.68)	0.33
Sleep (min)	0 (54)	3 (59)	57 (92)	4 (68)	<0.01
Activity (steps)	52 (2,659)	–323 (2,771)	–3,533 (4,418)	–208 (3,086)	<0.01

Summary of the collected data and demographic information about the cohort. Available days are specified for each data type, with median and interquartile range (IQR) values. Mean changes (and s.d.) in resting heart rate (RHR), steps and sleep from baseline (–21 to –7 days) to symptomatic period (0 to 7 days) are reported; for individuals with no symptoms we consider 6 March 2020 as day 0. P values of a two-sided Fisher's exact test applied to COVID-19-positive and COVID-19-negative participants are also reported.

improved the overall performance from the three sensor metrics to an AUC of 0.72 (0.64–0.80).

We also considered a model based only on self-reported symptoms (SymptomMetric, Fig. 2e), along with age and sex. With respect to the previously published model¹, we measure a slightly lower AUC of 0.71 (0.63–0.79).

When participant-reported symptoms and sensor metrics are jointly considered in the analysis (OverallMetric, Fig. 2f), the achieved performance was significantly improved ($P < 0.01$) relative to either alone, with an AUC of 0.80 (0.73–0.86).

Discussion

Our results show that individual changes in physiological measures captured by most smartwatches and activity trackers are able to significantly improve the distinction between symptomatic individuals with and without a diagnosis of COVID-19 beyond symptoms alone. Although encouraging, these results are based on a relatively small sample of participants.

This work builds on our earlier retrospective analysis demonstrating the potential for consumer sensors to identify individuals with influenza-like illness, which has subsequently been replicated in a similar analysis of over 1.3 million wearable users in China for predicting COVID-19^{8,9}. In response to the COVID-19 pandemic, a number of prospective studies, led by device manufacturers and/or academic institutions, including DETECT, have accelerated deployment to allow interested individuals to voluntarily share their sensor and clinical data to help address the global crisis^{10–14}. The largest of these efforts, Corona-Datenspende, was developed by the Robert Koch Institut in Germany and has enrolled over 500,000 volunteers¹⁵.

As different individuals experience a wide range of symptomatic and biological responses to infection with SARS-CoV-2, it is likely that their measurable physiological changes will also vary^{16–18}. For that reason, it is possible that biometric changes may be more

valuable in identifying those at highest risk for decompensation rather than just a dichotomous distinction in infection status. Because of the limited testing in the United States, especially early in the spread of the COVID-19 pandemic, individuals with more severe symptoms may have been more likely to be tested. In fact, the majority of symptomatic participants in our study did not undergo testing. However, using the optimal tradeoff of sensitivity and specificity on the ROC, we would predict that, of the 3,478 symptomatic participants who did not undergo diagnostic testing, 1,061 would have tested positive. Consequently, the ability to differentiate between COVID-19-positive and COVID-19-negative cases based on symptoms and sensor data may change over time as testing increases, and as other upper respiratory illnesses such as seasonal influenza increase this fall.

The early identification of symptomatic and pre-symptomatic infected individuals would be especially valuable as transmission is common and people may potentially be even more infectious during this period^{19–21}. Even when individuals have no symptoms, there is evidence that the majority have lung injury (according to computed tomography (CT) scans), and a large number have abnormalities in inflammatory markers, blood cell counts and liver enzymes^{18,22–24}. As the depth and diversity of data types from personal sensors continue to expand—such as heart rate variability (HRV), respiratory rate, temperature, oxygen saturation and even continuous blood pressure, cardiac output and systemic vascular resistance—the ability to detect subtle individual changes in response to early infectious insults will potentially improve and enable the identification of individuals without symptoms.

In the past, the normality of a specific biometric parameter, such as RHR, duration of nightly sleep or daily activity, was based on population norms. For example, a normal RHR is generally considered anything between ~60–100 b.p.m. However, recent work looking at individual daily RHRs over two years found that each person has a

표 1 | 참가자의 특성 및 장치 데이터

	Total	Any symptom	COVID-19 positive	COVID-19 negative	P value
Demographic data					
Number of participants	30,529	3,811	54	279	-
Female	18,922 (62.0%)	2,828 (74.2%)	43 (79.6%)	199 (71.3%)	0.65
Age group (years)					
Under 35	7,052 (23.1%)	1,184 (31.1%)	17 (31.5%)	71 (25.4%)	0.52
35 to 50	10,357 (33.9%)	1,522 (39.9%)	23 (42.6%)	121 (43.4%)	1.00
51 to 65	9,038 (29.6%)	857 (22.5%)	12 (22.2%)	64 (22.9%)	1.00
Over 65	3,899 (12.8%)	219 (5.7%)	1 (1.9%)	21 (7.5%)	0.22
Fitbit users	23,922 (78.4%)	3,306 (86.7%)	46 (85.2%)	237 (84.9%)	1.00
Apple users	9,522 (31.2%)	1,219 (32.0%)	21 (38.9%)	94 (33.7%)	0.66
Sensor data					
Available days (IQR)					
RHR	322 (131-387)	325 (153-396)	312 (98-377)	300 (119-392)	0.70
Sleep	249 (48-373)	273 (105-383)	283 (52-362)	246 (70-375)	0.56
Activity	394 (370-412)	407 (379-415)	404 (375-410)	401 (374-413)	0.57
Mean change (s.d.)					
RHR (b.p.m.)	0.0 (2.84)	0.40 (3.18)	1.15 (4.83)	0.61 (3.68)	0.33
Sleep (min)	0 (54)	3 (59)	57 (92)	4 (68)	<0.01
Activity (steps)	52 (2,659)	-323 (2,771)	-3,533 (4,418)	-208 (3,086)	<0.01

코호트에 대해 수집된 데이터 및 인구통계학적 정보의 요약입니다. 사용 가능한 날짜는 중앙값 및 IQR(사분위수 범위) 값과 함께 각 데이터 유형에 대해 지정됩니다. 평균 변화(및 s.d.)에 대한 자세한 내용은 표 2를 참조하십시오. 기중선(-21~-7일)부터 증상 기간(0~7일)까지 안정시 심박수(RHR), 걸음 수 및 수면이 보고됩니다. 증상이 없는 개인의 경우 2020년 3월 6일을 0일로 간주합니다. P val 코로나19 양성 참가자와 코로나19 음성 참가자에게 적용된 양면 피셔의 정확한 테스트 결과도 보고되었습니다.

세 가지 센서 지표에서 전반적인 성능을 AUC 0.72(0.64–0.80).

우리는 또한 나이와 성별과 함께 자가 보고된 증상(Symptom Metric, 그림 2e)에만 기초한 모델을 고려했습니다. 이전에 게시된 모델과 관련하여 우리는 0.71(0.63–0.79)의 약간 낮은 AUC를 측정합니다.

참가자가 보고한 증상과 센서 메트릭을 분석(OverallMetric, 그림 2f)에서 공동으로 고려할 때 달성된 성능은 AUC 0.80(0.73–0.86)으로 단독에 비해 크게 향상되었습니다($P < 0.01$).

논의

우리의 결과는 대부분의 스마트워치와 활동 추적기에 의해 포착된 생리적 측정의 개별적인 변화가 증상만을 넘어 코로나19 진단 유무에 따른 증상이 있는 개인 간의 구별을 크게 향상시킬 수 있음을 보여줍니다. 고무적이긴 하지만, 이러한 결과는 상대적으로 적은 참여자 표본을 기반으로 한 것입니다.

이 작업은 소비자 센서가 인플루엔자 유사 질병을 앓고 있는 개인을 식별할 수 있는 가능성을 보여주는 이전 회고적 분석을 기반으로 하며, 이는 이후 코로나19^{8,9}를 예측하기 위해 중국의 130만 명 이상의 웨어러블 사용자를 대상으로 한 유사한 분석에서 복제되었습니다. 코로나19 팬데믹에 대응하여 장치 제조업체 및/또는 DETECT를 포함한 학술 기관이 주도하는 다수의 전향적 연구에서는 관심 있는 개인이 글로벌 위기 해결에 도움이 되도록 센서 및 임상 데이터를 자발적으로 공유할 수 있도록 배포를 가속화했습니다^{10–14}. 이러한 노력 중 가장 큰 노력인 Corona-Datenspende는 독일의 Robert Koch Institut에서 개발되었으며 500,000명 이상의 자원봉사자가 등록했습니다¹⁵.

다양한 개인이 SARS-CoV-2 감염에 대해 광범위한 증상 및 생물학적 반응을 경험하므로 측정 가능한 생리적 변화도 다양할 가능성이 높습니다^{16–18}. 그렇기 때문에 생체인식 변화가 더 많을 수도 있습니다.

이는 감염 상태를 이분법적으로 구분하는 것보다 보상 부전의 위험이 가장 높은 사람들을 식별하는 데 유용합니다. 미국에서는 특히 코로나19 팬데믹 확산 초기에 검사가 제한되어 있기 때문에 증상이 더 심각한 개인은 검사를 받을 가능성이 더 높았을 수 있습니다. 실제로 우리 연구에 참여한 대부분의 증상이 있는 참가자는 검사를 받지 않았습니다. 그러나 ROC에 대한 민감도와 특이성의 최적의 균형을 사용하여 진단 테스트를 받지 않은 3,478명의 증상 참가자 중 1,061명이 양성 반응을 보였을 것이라고 예측할 수 있습니다. 결과적으로, 증상과 센서 데이터를 기반으로 코로나19 양성 사례와 음성 사례를 구별하는 능력은 검사가 증가하고 올 가을 계절성 인플루엔자와 같은 기타 상부 호흡기 질환이 증가함에 따라 시간이 지남에 따라 변할 수 있습니다.

전염이 흔하고 이 기간 동안 사람들이 잠재적으로 훨씬 더 전염성이 있을 수 있기 때문에 증상이 있는 감염자와 증상이 나타나기 전의 감염자를 조기에 식별하는 것은 특히 중요합니다^{19–21}. 개인에게 증상이 없더라도 대다수가 컴퓨터 단층촬영(CT) 검사에 따르면 폐 손상이 있다는 증거가 있으며, 상당수는 염증 표지자, 혈구 수 및 간 효소에 이상이 있습니다^{18,22–24}. 심박수 변이도(HRV), 호흡수, 온도, 산소 포화도, 지속적인 혈압, 심박출량, 전신 혈관 저항 등 개인용 센서를 통해 수집되는 데이터 유형의 깊이와 다양성이 계속해서 확장됨에 따라 초기 감염 질환에 대한 개인의 미묘한 변화를 감지하는 능력이 잠재적으로 향상되어 증상 없이 개인을 식별할 수 있게 될 것입니다.

과거에는 RHR, 야간 수면 시간, 일일 활동 등 특정 생체인식 매개변수의 정상성이 인구 기준을 기반으로 했습니다. 예를 들어, 정상적인 RHR은 일반적으로 ~60~100b.p.m. 사이로 간주됩니다. 그러나 2년에 걸쳐 개인의 일일 RHR을 조사한 최근 연구에 따르면 각 개인은




Fig. 1 | Frequency of symptoms among participants. Participants who reported at least one symptom were divided into three groups: participants who tested negative for COVID-19 or positive for COVID-19 and participants who were not tested. The frequencies of the indicated symptoms in each of these three groups are shown. *P* values of a two-sided Fisher's exact test applied to COVID-19-positive (54 individual subjects) and COVID-19-negative (279 individual subjects) participants are reported. Symptoms with a significant difference ($P < 0.05$) are marked with an asterisk.

relatively consistent RHR, for them, that fluctuates by a median of only 3 b.p.m. weekly⁶. On the other hand, what would be considered a normal RHR for an individual can vary by as much as 70 b.p.m. (between 40 and 109 b.p.m.) between individuals. The potential value in identifying important changes in an individual's RHR as an early marker for COVID-19 infection is suggested by the description of 5,700 patients hospitalized with COVID-19⁴: at the time of admission, a greater percentage of individuals had a heart rate of >100 b.p.m. (43.1%) than had a fever (30.7%). Similarly, work in primate models of other viral and bacterial infections found that a significant increase in heart rate can be detected ~2 days before a fever²⁵.

Just as individuals have heart rate patterns that are unique to them, the same is true for sleep patterns. Although population norms for sleep duration have been defined by one-time survey data²⁶, longitudinal analysis of daily sleep over several years supports much greater variation in what is normal for a specific individual⁷. Recognizing what is normal for an individual enables much earlier detection of deviations from that normal.

A strategy of test, trace and isolate has played a central role in helping control the spread of COVID-19. However, testing comes with many challenges, including the enormous logistical and cost hurdles of recurrently testing asymptomatic individuals. In addition, testing in a population with very low prevalence can lead to a high proportion of false positive cases. A refined predictive model, based on personal sensors, could enable an early, individualized testing strategy to improve performance and lower costs. Early testing may make the use of a contact tracing app more effective by identifying positive cases in advance and allowing for early isolation.

DETECT (and similar studies) also represent the transitioning of research from a dependence on brick and mortar research centers to a remote, direct-to-participant approach now possible through a range of digital technologies, including an ever expanding collection of sensors, applications of machine learning to massive datasets, and the ubiquitous connectivity that enables rapid two-way communications 24/7^{27,28}. The promise of digital technologies is that their evolution will continue to bring us closer to identifying the best combination of measures and associated algorithms that identify infection with SARS-CoV-2 or other pathogens. However, it is equally critical to develop and continuously improve on an engaging digital platform that provides value to participants and researchers. This has proven to be extremely challenging, with a recent analysis of eight different digital research programs involving 100,000 participants having a median duration of retention of only 5.5 days²⁹. Digital trials such as DETECT also do come with unique challenges to assure privacy and security, which can only be dealt with by effectively informing participants before consent, storing the data with the appropriate level of security and providing access to the data only for research purposes³⁰. App-based contact tracing, which is not part of DETECT, is an especially sensitive and ethically complicated use of digital technology that can be used to address the pandemic³¹.

Our analyses are dependent entirely on participant-reported symptoms and testing results, as well as the biometric data from their personal devices. Although this is not consistent with the historically more common direct collection of information in a controlled laboratory setting or via electronic health records, previous




그림 1 | 참가자들 사이의 증상 빈도. 최소한 한 가지 이상의 증상을 보고한 참가자는 세 그룹으로 나뉘었습니다. 즉, 코로나19 음성 판정을 받은 참가자나 코로나19 양성 판정을 받은 참가자와 테스트를 받지 않은 참가자였습니다. 이 세 그룹 각각에 표시된 증상의 빈도가 표시됩니다. 코로나19 양성(54명의 개별 피험자) 및 코로나19 음성(279명의 개별 피험자) 참가자에게 적용된 양면 Fisher 정확 검정의 P 값이 보고됩니다. 유의미한 차이($P < 0.05$)가 있는 증상에는 별표가 표시됩니다.

상대적으로 일관된 RHR은 중앙값이 3b.p.m에 불과합니다. 매주 6. 반면에, 개인의 정상적인 RHR로 간주되는 것은 최대 70b.p.m까지 다양할 수 있습니다. (40~109b.p.m.) 개인 간. 개인의 RHR의 중요한 변화를 코로나19 감염의 초기 지표로 식별하는 잠재적 가치는 코로나19로 입원한 5,700명의 환자에 대한 설명에서 제시됩니다. 입원 당시 더 많은 비율의 개인이 >100 b.p.m. 발열(30.7%)이 43.1%보다 많았다. 마찬가지로, 다른 바이러스 및 박테리아 감염에 대한 영양류 모델 연구에서는 심박수의 상당한 증가가 ~열이 나기 2일 전²⁵에서 감지될 수 있음을 발견했습니다.

개인마다 고유한 심박수 패턴이 있듯이 수면 패턴도 마찬가지로입니다. 수면 시간에 대한 인구 기준은 일회성 조사 데이터²⁶에 의해 정의되었지만, 수년에 걸친 일일 수면의 종단적 분석은 특정 개인의 정상 상태에서 훨씬 더 큰 변화를 지원합니다⁷. 개인의 정상성이 무엇인지 인식하면 해당 정상으로부터의 편차를 훨씬 더 일찍 감지할 수 있습니다.

테스트, 추적, 격리 전략은 코로나19 확산을 통제하는 데 핵심적인 역할을 했습니다. 그러나 테스트에는 무증상자를 반복적으로 테스트하는 데 따른 막대한 물류 및 비용 장애물을 포함하여 많은 어려움이 따릅니다. 또한 유병률이 매우 낮은 인구 집단을 대상으로 테스트하면 위양성 사례의 비율이 높아질 수 있습니다. 개인 센서를 기반으로 한 정교한 예측 모델을 통해 조기에 개별화된 테스트 전략을 수립하여 성능을 향상하고 비용을 절감할 수 있습니다. 조기 테스트를 통해 양성 사례를 미리 식별하고 조기 격리를 허용함으로써 접촉자 추적 앱을 더욱 효과적으로 사용할 수 있습니다.

DETECT(및 유사 연구)는 또한 연구가 계속 확장되는 센서 컬렉션, 대규모 데이터 세트에 대한 기계 학습 적용, 연중무휴 24시간 빠른 양방향 통신을 가능하게 하는 유비쿼터스 연결 등 다양한 디지털 기술을 통해 현재 가능한 오프라인 연구 센터에 대한 의존성에서 원격, 참가자에게 직접 접근 방식으로의 전환을 나타냅니다. 디지털 기술의 약속은 디지털 기술의 진화를 통해 SARS-CoV-2 또는 기타 병원체 감염을 식별하는 측정 방법 및 관련 알고리즘의 최상의 조합을 식별하는 데 계속해서 더 가까워질 것이라는 것입니다. 그러나 참가자와 연구자에게 가치를 제공하는 매력적인 디지털 플랫폼을 개발하고 지속적으로 개선하는 것도 똑같이 중요합니다. 이는 100,000명의 참가자가 포함된 8개의 서로 다른 디지털 연구 프로그램에 대한 최근 분석에서 평균 보존 기간이 5.5일에 불과하여 매우 어려운 것으로 입증되었습니다²⁹. DETECT와 같은 디지털 시험에는 개인 정보 보호 및 보안을 보장해야 하는 고유한 과제도 있습니다. 이는 참가자에게 동의 전에 효과적으로 알리고, 적절한 보안 수준으로 데이터를 저장하고, 연구 목적으로만 데이터에 대한 액세스를 제공함으로써만 처리될 수 있습니다³⁰. DETECT의 일부가 아닌 앱 기반 접촉자 추적은 팬데믹을 해결하는 데 사용할 수 있는 디지털 기술의 특히 민감하고 윤리적으로 복잡한 사용입니다³¹.

우리의 분석은 참가자가 보고한 증상과 테스트 결과는 물론 개인 장치의 생체 인식 데이터에 전적으로 의존합니다. 이는 통제된 실험실 환경이나 전자 건강 기록을 통해 역사적으로 보다 일반적으로 직접적으로 정보를 수집하는 것과 일치하지 않지만,




Fig. 2 | Prediction of COVID-19 from self-reported symptoms and sensor data. **a–f**, Receiver operating characteristic curves (ROCs) for the discrimination between COVID-19-positive (54 individuals) and COVID-19-negative (279 individuals) cases based on the available data: RHR data (**a**); sleep data (**b**); activity data (**c**); all available sensor data (**d**); symptoms only (**e**); symptoms with sensor data (**f**). Models are based on a single decision threshold. Median values and 95% confidence intervals (CIs) for sensitivity (SE), specificity (SP), positive predictive value (PPV) and negative predictive value (NPV) are reported, considering the point on the ROC with the highest average value of sensitivity and specificity. Error bars represent 95% CIs. *P* values from a one-sided Mann-Whitney *U* test are reported.

work has confirmed their value and their accuracy beyond data routinely captured during routine care^{32–34}. Additionally, individuals owning a smartwatch or activity tracker and having access to COVID-19 diagnostic testing are unlikely to be representative of the general population and may exclude those most affected by COVID. Although a recent survey found no racial or ethnic variation in smartwatch or activity tracker usage (23%, 26% and 21% for Black, Hispanic and White individuals, respectively), the lowest percentage of users were identified in those with the lowest annual earnings (12%), the lowest educational attainment (15%) and in those over age 50 (17%)⁵. In the future, if the value of wearable devices to improve individual health is confirmed, this gap in usage will need to be proactively addressed to assure health equity. The decreasing cost of these devices, some now less than US\$35, will help decrease the financial barriers to accomplishing this. Finally, in the early version of the DETECT app we were not able to track the duration or trajectory of individual symptoms, care received and eventual outcomes.

These results suggest that sensor data can incrementally improve symptom-only-based models to differentiate between COVID-19-positive and COVID-19-negative symptomatic individuals, with the potential to enhance our ability to identify a cluster before more spread occurs. Such a passive monitoring strategy may be complementary to virus testing, which is generally a one-off, or infrequent, sampling assay.

Online content

Any methods, additional references, Nature Research reporting summaries, source data, extended data, supplementary information, acknowledgements, peer review information; details of author contributions and competing interests; and statements of data and code availability are available at <https://doi.org/10.1038/s41591-020-1123-x>.

Received: 30 June 2020; Accepted: 7 October 2020;
Published online: 29 October 2020

References

- Menni, C. et al. Real-time tracking of self-reported symptoms to predict potential COVID-19. *Nat. Med.* **26**, 1037–1040 (2020).
- Oran, D. P. & Topol, E. J. Prevalence of asymptomatic SARS-CoV-2 infection. *Ann. Intern. Med.* <https://doi.org/10.7326/M20-3012> (2020).
- New COVID-19 Test Data (Color Genomics, 2020); <https://www.color.com/new-covid-19-test-data-majority-of-people-who-test-positive-for-covid-19-have-mild-symptoms-or-are-asymptomatic>
- Richardson, S. et al. Presenting characteristics, comorbidities and outcomes among 5,700 patients hospitalized with COVID-19 in the New York City area. *JAMA* **323**, 2052–2059 (2020).
- Vogels, E. A. About One-in-Five Americans Use a Smart Watch or Fitness Tracker (Pew Research Center, 2020); <https://www.pewresearch.org/fact-tank/2020/01/09/about-one-in-five-americans-use-a-smart-watch-or-fitness-tracker/>




그림 2 | 자가 보고 증상 및 센서 데이터를 통한 코로나19 예측. a–f, 이용 가능한 데이터를 기반으로 한 코로나19 양성(54명)과 코로나19 음성(279명) 사례를 구별하기 위한 수신자 작동 특성 곡선(ROC): RHR 데이터(a); 수면 데이터(b); 활동 데이터(c); 사용 가능한 모든 센서 데이터(d) 증상만(e); 센서 데이터의 증상(f). 모델은 단일 결정 임계값을 기반으로 합니다. 민감도와 특이도의 평균값이 가장 높은 ROC 지점을 고려하여 민감도(SE), 특이도(SP), 양성 예측도(PPV), 음성 예측도(NPV)에 대한 중앙값과 95% 신뢰 구간(CI)이 보고됩니다. 오류 막대는 95% CI를 나타냅니다. 일측 Mann-Whitney U 테스트의 P 값이 보고됩니다.

작업을 통해 일상적인 진료 중에 일상적으로 수집된 데이터 이상의 가치와 정확성이 확인되었습니다^{32–34}. 또한, 스마트워치나 활동 추적기를 소유하고 코로나19 진단 테스트에 접근할 수 있는 개인은 일반 인구를 대표할 가능성이 낮으며 코로나19로 가장 큰 영향을 받는 사람들을 제외할 수 있습니다. 최근 조사에 따르면 스마트워치 또는 활동 추적기 사용에 있어 인종적 또는 민족적 차이는 발견되지 않았지만(흑인, 히스패닉 및 백인 각각 23%, 26%, 21%), 사용자의 가장 낮은 비율은 연간 소득이 가장 낮은 사용자(12%), 교육 수준이 가장 낮은 사용자(15%) 및 50세 이상 사용자(17%)에서 확인되었습니다⁵. 향후 웨어러블 디바이스가 개인의 건강을 향상시킬 수 있는 가치가 확인된다면, 이러한 활용 격차를 적극적으로 해소하여 건강 형평성을 보장해야 할 것입니다. 일부 장치의 가격이 현재 미화 35달러 미만으로 낮아지면 이를 달성하는 데 있어 재정적 장벽을 줄이는 데 도움이 될 것입니다. 마지막으로, DETECT 앱의 초기 버전에서는 개별 증상, 받은 치료 및 최종 결과의 기간이나 궤적을 추적할 수 없었습니다.

이러한 결과는 센서 데이터가 증상 기반 모델을 점진적으로 개선하여 코로나19 양성 및 코로나19 음성 유증상자를 구별할 수 있으며 더 많은 확산이 발생하기 전에 클러스터를 식별하는 능력을 향상시킬 수 있음을 시사합니다. 이러한 수동적 모니터링 전략은 일반적으로 일회성 또는 빈도가 낮은 샘플링 분석인 바이러스 테스트를 보완할 수 있습니다.

온라인 콘텐츠

모든 방법, 추가 참조, Nature Research 보고 요약, 소스 데이터, 확장 데이터, 보충 정보, 감사의 말, 동료 검토 정보; 저자 기여 및 경쟁 이해관계에 대한 세부정보 데이터 및 코드 가용성에 대한 설명은 <https://doi.org/10.1038/s41591-020-1123-x>에서 확인할 수 있습니다.

접수일: 2020년 6월 30일; 승인: 2020년 10월 7일;
온라인 게시: 2020년 10월 29일

참고자료

1. Menni, C. et al. 자가 보고 증상을 실시간으로 추적하여 잠재적인 코로나19를 예측합니다. *Nat. Commun.* 11, 1037–1040 (2020).
2. Oran, D. P. & Topol, E. J. 무증상 SARS-CoV-2 감염의 유행률. *엔. 인턴. 메드.* <https://doi.org/10.7326/M20-3012> (2020).
3. 새로운 코로나19 테스트 데이터(Color Genomics, 2020); <https://www.color.com/new-covid-19-test-data-majority-of-people-who-test-positive-for-covid-19-have-mild-symptoms-or-are-asymptomatic>
4. Richardson, S. et al. 뉴욕시 지역에 있는 COVID-19로 입원한 5,700명의 환자의 특성, 동반질환 및 결과를 제시합니다. *JAMA* 323, 2052–2059 (2020).
5. Vogels, E. A. 미국인 5명 중 1명 정도가 스마트 시계나 피트니스 트래커를 사용합니다(Pew Research Center, 2020). <https://www.pewresearch.org/fact-tank/2020/01/09/about-one-in-five-americans-use-a-smart-watch-or-fitness-tracker/>

6. Quer, G., Gouda, P., Galarnyk, M., Topol, E. J. & Steinhobl, S. R. Inter- and intraindividual variability in daily resting heart rate and its associations with age, sex, sleep, BMI and time of year: retrospective, longitudinal cohort study of 92,457 adults. *PLoS ONE* **15**, e0227709 (2020).
7. Jaiswal, S. J. et al. Association of sleep duration and variability with body mass index: Sleep measurements in a large US population of wearable sensor users. *JAMA Intern. Med.* <https://doi.org/10.1001/jamainternmed.2020.2834> (2020).
8. Radin, J. M., Wineinger, N. E., Topol, E. J. & Steinhobl, S. R. Harnessing wearable device data to improve state-level real-time surveillance of influenza-like illness in the USA: a population-based study. *Lancet Digit. Health* **2**, e85–e93 (2020).
9. Zhu, G. et al. Learning from large-scale wearable device data for predicting epidemics trend of COVID-19. *Discrete Dynamics Nat. Soc.* **2020**, 6152041 (2020).
10. Mishra, T. et al. Early detection of COVID-19 using a smartwatch. Preprint at medRxiv <https://doi.org/10.1101/2020.07.06.20147512> (2020).
11. Natarajan, A., Su, H.-W. & Heneghan, C. Assessment of physiological signs associated with COVID-19 measured using wearable devices. Preprint at <https://doi.org/10.1101/2020.08.14.20175265> (2020).
12. Evidation Health and BARDA Partner on Early Warning System for COVID-19 (Evidation, 2020); <https://evidation.com/news/evidationhealthandbardapartner/>
13. Tempredict Study (Our Health, 2020); <https://ouraring.com/ucsf-tempredict-study>
14. Covididentify (Duke University, 2020); <https://covididentify.covid19.duke.edu/>
15. Corona Datenspende (Robert Koch Institut, 2020); <https://corona-datenspende.de/science/en>
16. Shen, B. et al. Proteomic and metabolomic characterization of COVID-19 patient sera. *Cell* **182**, 59–72 (2020).
17. Sharma, R., Agarwal, M., Gupta, M., Somendra, S. & Saxena, S. K. in *Coronavirus Disease 2019 (COVID-19)* (ed. Saxena, S.) 55–70 (Springer, 2020).
18. Tabata, S. et al. Clinical characteristics of COVID-19 in 104 people with SARS-CoV-2 infection on the Diamond Princess cruise ship: a retrospective analysis. *Lancet Infect. Dis.* **20**, 1043–1050 (2020).
19. Ferretti, L. et al. Quantifying SARS-CoV-2 transmission suggests epidemic control with digital contact tracing. *Science* **368**, eabb6936 (2020).
20. Chau, N. V. V. et al. The natural history and transmission potential of asymptomatic SARS-CoV-2 infection. *Clin. Infect. Dis.* <https://doi.org/10.1093/cid/ciaa711> (2020).
21. Jing, Q. L. et al. Household secondary attack rate of COVID-19 and associated determinants in Guangzhou, China: a retrospective cohort study. *Lancet Infect. Dis.* **20**, 1141–1150 (2020).
22. Meng, H. et al. CT imaging and clinical course of asymptomatic cases with COVID-19 pneumonia at admission in Wuhan, China. *J. Infect.* **81**, e33–e39 (2020).
23. Inui, S. et al. Chest CT findings in cases from the cruise ship ‘Diamond Princess’ with coronavirus disease 2019 (COVID-19). *Radiol. Cardiothorac. Imaging* **2**, e200110 (2020).
24. Long, Q. X. et al. Clinical and immunological assessment of asymptomatic SARS-CoV-2 infections. *Nat. Med.* **26**, 1200–1204 (2020).
25. Milechin, L. et al. Detecting pathogen exposure during the non-symptomatic incubation period using physiological data. Preprint at bioRxiv <https://doi.org/10.1101/218818> (2017).
26. *Sleep and Sleep Disorders* (Center for Disease Control and Prevention, 2020); https://www.cdc.gov/sleep/data_statistics.html
27. Steinhobl, S. R., Wolff-Hughes, D. L., Nilsen, W., Iturriaga, E. & Califf, R. M. Digital clinical trials: creating a vision for the future. *NPJ Digit. Med.* **2**, 126 (2019).
28. Steinhobl, S. R., McGovern, P., Dylan, J. & Topol, E. J. The digitised clinical trial. *Lancet* **390**, 2135 (2017).
29. Pratap, A. et al. Indicators of retention in remote digital health studies: a cross-study evaluation of 100,000 participants. *NPJ Digit. Med.* **3**, 21 (2020).
30. Coravos, A. et al. Modernizing and designing evaluation frameworks for connected sensor technologies in medicine. *NPJ Digit. Med.* **3**, 37 (2020).
31. Bradford, L. R., Aboy, M. & Liddell, K. COVID-19 contact tracing Apps: a stress test for privacy, the GDPR and data protection regimes. *J. Law Biosci.* <https://doi.org/10.1093/jlb/lsaa034> (2020).
32. Rivera, S. C. et al. The impact of patient-reported outcome (PRO) data from clinical trials: a systematic review and critical analysis. *Health Qual. Life Outcomes* **17**, 156 (2019).
33. Basch, E. et al. Overall survival results of a trial assessing patient-reported outcomes for symptom monitoring during routine cancer treatment. *JAMA* **318**, 197–198 (2017).
34. Bell, S. K. et al. Frequency and types of patient-reported errors in electronic health record ambulatory care notes. *JAMA Netw. Open* **3**, e205867 (2020).

Publisher's note Springer Nature remains neutral with regard to jurisdictional claims in published maps and institutional affiliations.

© The Author(s), under exclusive licence to Springer Nature America, Inc. 2020

6. Quer, G., Gouda, P., Galamyk, M., Topol, E. J. & Steinhubl, S. R. 일일 휴식 심박수의 개인 간 및 개인 내 변동성과 연령, 성별, 수면, BMI 및 시간과의 연관성: 92,457명의 성인을 대상으로 한 후향적, 종단적 코호트 연구. *PLoS ONE* 15, e0227709(2020). 7. Jaiswal, S.J. 외. 수면 시간 및 변동성과 체질량 지수의 연관성: 미국의 대규모 웨어러블 센서 사용자 인구를 대상으로 한 수면 측정입니다. *JAMA* 인터넷. 메드. <https://doi.org/10.1001/jamainternmed.2020.2834> (2020). 8. Radin, J. M., Wineinger, N. E., Topol, E. J. & Steinhubl, S. R. 미국에서 인플루엔자 유사 질병에 대한 주 차원의 실시간 감시를 개선하기 위해 웨어러블 장치 데이터 활용: 인구 기반 연구. *랜셋 디지털 건강* 2, e85–e93(2020). 9. Zhu, G. et al. 대규모 웨어러블 디바이스 데이터를 통해 코로나19 전염병 동향을 예측합니다. *이산 역학 Nat. Soc.* 2020, 6152041(2020). 10. Mishra, T. 외. 스마트워치를 활용한 코로나19 조기 발견. *사전 인쇄 세간*:

[medRxiv https://doi.org/10.1101/2020.07.06.20147512](https://doi.org/10.1101/2020.07.06.20147512) (2020). 11. 나탈라잔, A., 수, H.-W. & Heneghan, C. 웨어러블 장치를 사용하여 측정된 코로나19와 관련된 생리적 징후 평가. <https://doi.org/10.1101/2020.08.14.20175265> (2020)에서 사전 인쇄하세요. 12. Evidation Health와 BARDA의 코로나19 조기 경보 시스템 파트너

(증거, 2020); <https://evidation.com/news/evidationhealthandbardapartner/> 13. Tempredict 연구(Oura Health, 2020); <https://ouraring.com/ucsf-tempredict->

연구 14. Covididentify(듀크 대학교, 2020); <https://covididentify.covid19.duke.edu/> 15. 코로나 데이터스펜데(Robert Koch Institut, 2020); <https://corona-daten.spende.de/science/en> 16. Shen, B. et al. 코로나19 환자 혈청의 단백질체학 및 대사체 특성 분석. *셀* 182, 59–72(2020). 17. Sharma, R., Agarwal, M., Gupta, M., Somendra, S. & Saxena, S. K. in *코로나바이러스 질병 2019(COVID-19)* (e d. Saxena, S.) 55–70 (Springer, 2020). 18. Tabata, S. et al. 다이아몬드 프린세스 크루즈선에서 SARS-CoV-2 감염자 104명을 대상으로 한 COVID-19의 임상적 특성: 후향적 분석. *랜셋 감염. 디스.* 20, 1043–1050(2020). 19. Ferretti, L. 외. SARS-CoV-2 전염을 정량화하면 디지털 접촉 추적을 통한 전염병 통제가 가능해집니다. *과학* 368, eabb6936(2020). 20. Chau, N.V.V. 외. 무증상 SARS-CoV-2 감염의 자연사 및 전염 가능성. *클린. 감염. 디스.* <https://doi.org/10.1093/cid/ciaa711> (2020).

21. Jing, Q. L. 외. 중국 광저우의 COVID-19 가구 2차 발병률 및 관련 결정 요인: 후향적 코호트 연구. *랜셋 감염. 디스.* 20, 1141–1150(2020). 22. Meng, H. et al. 중국 우한 입원 시 무증상 코로나19 폐렴 사례에 대한 CT 영상 및 임상 경과. *J. 감염.* 81, e33–e39(2020). 23. Inui, S. et al. 2019년 코로나바이러스감염증-19(COVID-19) 크루즈선 '다이아몬드 프린세스호'의 흉부 CT 소견. *라디올. 심장 흉부. 이미징* 2, e200110(2020). 24. Long, Q. X. 외. 무증상 SARS-CoV-2 감염에 대한 임상 및 면역학적 평가. *Nat. Med* 26, 1200–1204(2020). 25. Milecchin, L. 외. 무증상 기간 동안 병원체 노출 감지

생리학적 데이터를 이용한 잠복기. *bioRxiv* <https://doi.org/10.1101/218818> (2017). 26. 수면 및 수면 장애(질병통제예방센터, 2020); https://www.cdc.gov/sleep/data_statistics.html 27. Steinhubl, S. R., Wolff-Hughes, D. L., Nilsen, W., Iturriaga, E. & Califf, R. M. 디지털 임상 시험: 미래를 위한 비전 창출. *NPJ 숫자. 메드.* 2, 126(2019). 28. Steinhubl, S. R., McGovern, P., Dylan, J. & Topol, E. J. 디지털화된 임상 시험. *랜셋* 390, 2135(2017). 29. Pratap, A. et al. 원격 디지털 건강 연구의 유지 지표: 100,000명의 참가자를 대상으로 한 연구 간 평가. *NPJ 숫자. 메드.* 3, 21(2020). 30. Coravos, A. et al. 의학 분야의 연결된 센서 기술을 위한 평가 프레임워크를 현대화하고 설계합니다. *NPJ 숫자. 메드.* 3, 37(2020). 31. Bradford, L. R., Aboy, M. & Liddell, K. 코로나19 접촉자 추적 앱: 개인 정보 보호, GDPR 및 데이터 보호 체제에 대한 스트레스 테스트. *J. Law Biosci.* <https://doi.org/10.1093/jlb/lsaa034> (2020). 32. Rivera, S. C. 외. 임상 시험에서 환자가 보고한 결과(PRO) 데이터의 영향: 체계적인 검토 및 비판적 분석. *건강 자격. 인생의 결과* 17, 156(2019). 33. Basch, E. et al. 일상적인 암 치료 중 증상 모니터링에 대한 환자 보고 결과를 평가하는 시험의 전체 생존 결과입니다. *JAMA* 318, 197–198(2017). 34. Bell, S.K. 외. 전자 건강 기록 외래 진료 기록에서 환자가 보고한 오류의 빈도 및 유형. *JAMA Netw.* 3, e205867(2020)을 엽니다.

Publisher's note Springer Nature remains neutral with regard to jurisdictional claims in published maps and institutional affiliations.

© The Author(s), under exclusive licence to Springer Nature America, Inc. 2020

Methods

Study population. Any person living in the United States over the age of 18 years old is eligible to participate in the DETECT study by downloading the iOS or Android research app, MyDataHelps. After consenting into the study, participants are asked to share their personal device data (including historical data collected prior to enrollment), report symptoms and diagnostic test results, and connect their electronic health records. Participants can opt to share as much or as little data as they like. Data can be pulled in via direct application programming interface (API) with Fitbit devices, and any device connected through Apple HealthKit or Google Fit data aggregators. Participants were recruited via the study website (www.detectstudy.org), media reports and outreach from our partners at Fitbit, Walgreens, CVS/Aetna and others.

Ethical considerations. The protocol for this study was reviewed and approved by the Scripps Office for the Protection of Research Subjects (IRB 20–7531). All individuals participating in the study provided informed consent electronically.

Statistical analysis. Only participants with self-reported symptoms and COVID-19 test results were considered in this analysis. For each participant, two sets of data were extracted: the baseline data, which included signals spanning from 21 to 7 days before the reported start date of symptoms, and the test data, which included signals beginning at the first date of symptoms to seven days after symptoms. Three types of data were considered from personal sensors: daily resting heart rate (DailyRHR), sleep duration in minutes (DailySleep) and activity based on daily total step count (DailyActivity). The daily resting heart rate is calculated by the specific device³⁵. The total amount of sleep for a given day was based on the total period of sleep between 12 noon of the current day to 12 noon of the next day. When multiple devices from the same individual provided the same information, Fitbit device data were prioritized, for consistency. Overlapping data were combined minute by minute, before aggregating for the whole day.

A single baseline value per individual was extracted for each data type by considering the median value over the individual's baseline data. This value is representative of a participant's 'normal' before the reported symptoms. The baseline value was compared to the test data as follows:

$$\text{RHRMetric} = \frac{\max(\text{DailyRHR}[\text{test data}]) - \text{median}(\text{DailyRHR}[\text{baseline data}])}{4.00}$$

$$\text{SleepMetric} = \frac{\text{mean}(\text{DailySleep}[\text{test data}]) - \text{median}(\text{DailySleep}[\text{baseline data}])}{56.06}$$

$$\text{ActivityMetric} = \frac{\text{mean}(\text{DailyActivity}[\text{test data}]) - \text{median}(\text{DailyActivity}[\text{baseline data}])}{2,489.85}$$

Values were normalized to have a unitary IQR using normalization parameters calculated on all data recorded. For all these metrics, values close to zero indicate small variations from baseline values. This allows us to focus on intra-individual changes, which are minimally affected by the inter-individual variability due to the specific sensor's hardware and estimation algorithms. For the metric based on symptoms only, we adapted the results from the study by Menni et al.¹ to our available data:

$$\text{SymptomMetric} = -1.32 - (0.01 \times \text{age}) + (0.44 \times \text{gender}(\text{male} = 1; \text{female} = 0)) + (1.75 \times \text{DecreaseInTasteSmell}) + (0.31 \times \text{Cough}) + (0.49 \times \text{Fatigue})$$

The multivariate logistic regression model from Menni et al. combined symptoms, age and gender to predict an infection. The parameters were optimized by the authors on a large dataset including over 2 million people, 18,401 of which had undergone a COVID-19 test.

A simple manual metric aggregation strategy without optimization was used to enable a clear understanding of the benefits provided when data from multiple sources were considered together. The aggregated metrics were

$$\text{SensorMetric} = \text{RHRMetric}/10 + \text{SleepMetric} - \text{ActivityMetric}$$

$$\text{OverallMetric} = \text{SensorMetric} + \text{SymptomMetric}$$

The main outcomes are ROC curves for each of the proposed metrics. The curves are obtained by considering a binary classification task between participants self-reported as COVID-19-positive and COVID-19-negative. The models are based on a single decision threshold, which is directly compared to the metric values, with the aim of minimizing overfitting issues while providing a fair comparison. Confidence intervals, reported with a confidence level of 95%, are estimated using a bootstrap method by repeatedly sampling the dataset with replacement. The sampling is performed in a stratified manner; that is, the balance of the classes is maintained over all experiments. Values for sensitivity (SE), specificity (SP), positive predictive value (PPV) and negative predictive value (NPV) were also calculated (Fig. 2). SE and SP are defined as the fraction of positive and negative individuals correctly classified, respectively, while PPV and NPV are the fraction of individuals predicted as positive and negative that are correctly classified, respectively. These values are based on the point in the ROC with the optimal tradeoff between sensitivity and specificity, which may vary depending on the shape of the curve. For each metric analyzed, we applied the one-sided Mann–Whitney *U* test with the alternate hypothesis that the underlying model of the positive class is stochastically greater than the negative class. All statistical tests were evaluated using the Python package *scipy* version 1.5.2. The comparison metric to assess the overall performance was the AUC of the ROC.

Reporting Summary. Further information on research design is available in the Nature Research Reporting Summary linked to this article.

Data availability

All interested investigators will be allowed access to the analysis dataset following registration and pledging to not re-identify individuals or share the data with a third party. All data inquiries should be addressed to the corresponding author.

References

35. Heneghan, C., Venkatraman, S. & Russell, A. Investigation of an estimate of daily resting heart rate using a consumer wearable device. Preprint at *medRxiv* <https://doi.org/10.1101/19008771> (2019).

Acknowledgements

This work was funded by grant no. UL1TR002550 from the National Center for Advancing Translational Sciences (NCATS) at the National Institutes of Health (NIH; E.J.T. and S.R.S.). We thank N. Dalton for his support of DETECT. We also thank D. Oran, T. Peters, R. Kanyar and C. Nowak for their contributions to DETECT.

Author contributions

G.Q., J.M.R., K.B.-M., V.K., E.J.T. and S.R.S. made substantial contributions to the study conception and design. K.B.-M., L.A., E.R., V.K. and S.R.S. made substantial contributions to the acquisition of data. G.Q. and M.G. conducted statistical analysis. G.Q., J.M.R., M.G. and S.R.S. made substantial contributions to the interpretation of data. G.Q., J.M.R. and S.R.S. drafted the first version of the manuscript. G.Q., J.M.R., M.G., K.B.-M., L.A., E.R., V.K., E.J.T. and S.R.S. contributed to critical revisions and approved the final version of the manuscript. G.Q., J.M.R. and S.R.S. take responsibility for the integrity of the work.

Competing interests

S.R.S. reports grants from Janssen and personal fees from Otsuka and Livongo, outside the submitted work. The other authors declare no competing interests.

Additional information

Supplementary information is available for this paper at <https://doi.org/10.1038/s41591-020-1123-x>.

Correspondence and requests for materials should be addressed to G.Q.

Reprints and permissions information is available at www.nature.com/reprints.

Editor recognition statement Michael Basson was the primary editor on this article and managed its editorial process and peer review in collaboration with the rest of the editorial team.

행동 양식

연구 인구. 미국에 거주하는 18세 이상의 모든 사람은 iOS 또는 Android 연구 앱인 MyDataHelps를 다운로드하여 DETECT 연구에 참여할 수 있습니다. 연구에 동의한 후 참가자는 개인 장치 데이터(등록 전에 수집된 기록 데이터 포함)를 공유하고 증상 및 진단 테스트 결과를 보고하고 전자 건강 기록을 연결하도록 요청받습니다. 참가자는 원하는 만큼 데이터를 공유하도록 선택할 수 있습니다. Fitbit 기기 및 Apple HealthKit 또는 Google Fit 데이터 수집기를 통해 연결된 모든 기기에서 직접 API(애플리케이션 프로그래밍 인터페이스)를 통해 데이터를 가져올 수 있습니다. 참가자는 연구 웹사이트(www.Detectstudy.org), 언론 보도, Fitbit, Walgreens, CVS/Aetna 등 파트너의 지원 활동을 통해 모집되었습니다.

윤리적 고려 사항. 이 연구의 프로토콜은 Scripps Office for the Protection of Research Subjects(IRB 20-7531)에서 검토 및 승인되었습니다. 연구에 참여한 모든 개인은 사전 동의를 전자적으로 제공했습니다.

통계 분석. 이 분석에는 자가 보고된 증상과 코로나19 검사 결과가 있는 참가자만 고려되었습니다. 각 참가자에 대해 두 세트의 데이터가 추출되었습니다. 즉, 보고된 증상 시작일로부터 21~7일 전의 신호를 포함하는 기준 데이터와 증상의 첫 번째 날짜부터 증상 후 7일까지의 신호를 포함하는 테스트 데이터입니다. 개인 센서에서 세 가지 유형의 데이터가 고려되었습니다: 일일 안정시 심박수(DailyRHR), 수면 시간(DailySleep), 일일 총 걸을 수 기반 활동(DailyActivity). 일일 안정시 심박수는 특정 기기³⁶에 의해 계산됩니다. 하루 총 수면량은 당일 낮 12시부터 당일 낮 12시까지의 총 수면시간을 기준으로 하였습니다.

이튿날. 동일한 개인의 여러 장치가 동일한 정보를 제공하는 경우 일관성을 위해 Fitbit 장치 데이터가 우선시되었습니다. 중복되는 데이터는 분 단위로 결합되어 하루 종일 집계되었습니다.

개인의 기준 데이터에 대한 중앙값을 고려하여 각 데이터 유형에 대해 개인별 단일 기준 값을 추출했습니다. 이 값은 보고된 증상 이전의 참가자의 '정상'을 나타냅니다. 기준값은 다음과 같이 테스트 데이터와 비교되었습니다.

$$\text{RHRMetric} = \frac{\max(\text{DailyRHR}[\text{test data}]) - \text{median}(\text{DailyRHR}[\text{baseline data}])}{4.00}$$

$$\text{SleepMetric} = \frac{\text{mean}(\text{DailySleep}[\text{test data}]) - \text{median}(\text{DailySleep}[\text{baseline data}])}{56.06}$$

$$\text{ActivityMetric} = \frac{\text{mean}(\text{DailyActivity}[\text{test data}]) - \text{median}(\text{DailyActivity}[\text{baseline data}])}{2,489.85}$$

기록된 모든 데이터에 대해 계산된 정규화 매개변수를 사용하여 단일 IQR을 갖도록 값을 정규화했습니다. 이러한 모든 측정항목에서 0에 가까운 값은 기준값과의 작은 차이를 나타냅니다. 이를 통해 특정 센서의 하드웨어 및 추정 알고리즘으로 인한 개인간 변동성의 영향을 최소화하는 개인 내 변화에 집중할 수 있습니다. 증상만을 기반으로 한 측정항목의 경우 Menni et al.¹의 연구 결과를 사용 가능한 데이터에 적용했습니다.

SymptomMetric = $-1.32 - 0.01 \times \text{연령 (년)} + 0.44 \times \text{성별 남성} = 1; \text{여성} = 0$ () + $1.75 \times \text{DecreaseInTasteSmell}$ () + $0.31 \times \text{기침}$ () + $0.49 \times \text{피로}$ () Menni 등의 다변량 로지스틱 회귀 모델, 증상, 연령, 성별을 결합하여 감염을 예측합니다. 매개변수는 200만 명이 넘는 사람들을 포함하는 대규모 데이터 세트에서 저자에 의해 최적화되었으며, 그 중 18,401명은 코로나19 테스트를 거쳤습니다.

여러 소스의 데이터를 함께 고려할 때 제공되는 이점을 명확하게 이해하기 위해 최적화 없이 간단한 수동 지표 집계 전략을 사용했습니다. 집계된 측정항목은 다음과 같습니다.

$$\text{SensorMetric} = \text{RHRMetric}/10 + \text{SleepMetric} - \text{ActivityMetric}$$

$$\text{OverallMetric} = \text{SensorMetric} + \text{SymptomMetric}$$

주요 결과는 제안된 각 지표에 대한 ROC 곡선입니다. 곡선은 코로나19 양성 결과와 코로나19 음성으로 자체 보고된 참가자 간의 이진 분류 작업을 고려하여 얻은 것입니다. 모델은 공정한 비교를 제공하면서 과적합 문제를 최소화하는 것을 목표로 측정값과 직접 비교되는 단일 결정 임계값을 기반으로 합니다. 95%의 신뢰도 수준으로 보고된 신뢰 구간은 데이터 세트를 교차로 반복적으로 샘플링하여 부트스트랩 방법을 사용하여 추정됩니다. 샘플링은 계층화된 방식으로 수행됩니다. 즉, 모든 실험에서 클래스의 균형이 유지됩니다. 민감도(SE), 특이도(SP), 양성 예측값(PPV) 및 음성 예측값(NPV)에 대한 값도 계산되었습니다(그림 2). SE와 SP는 각각 올바르게 분류된 양성 및 음성 개인의 비율로 정의되는 반면, PPV 및 NPV는 각각 올바르게 분류된 양성 및 음성으로 예측된 개인의 비율로 정의됩니다. 이러한 값은 민감도와 특이도 사이의 최적 절충점을 갖는 ROC의 지점을 기반으로 하며 이는 곡선의 모양에 따라 달라질 수 있습니다. 분석된 각 메트릭에 대해 양성 클래스의 기본 모델이 음성 클래스보다 확률적으로 더 크다는 대체 가설을 사용하여 단측 Mann-Whitney U 테스트를 적용했습니다. 모든 통계 테스트는 Python 패키지 scipy 버전 1.5.2를 사용하여 평가되었습니다. 전반적인 성과를 평가하기 위한 비교 지표는 ROC의 AUC였습니다.

보고 요약. 연구 설계에 대한 추가 정보는 이 기사에 링크된 Nature Research Reporting Summary에서 확인할 수 있습니다.

데이터 가용성

관심 있는 모든 조사자는 등록 후 분석 데이터 세트에 액세스할 수 있으며 개인을 재식별하거나 데이터를 제3자와 공유하지 않을 것을 약속합니다. 모든 데이터 문의는 해당 작성자에게 문의해야 합니다.

참고자료

35. Heneghan, C., Venkatraman, S. & Russell, A. 소비자 웨어러블 장치를 사용하여 일일 안정시 심박수 추정치 조사. medRxiv <https://doi.org/10.1101/190087> 71 (2019)에서 사전 인쇄하세요.

감사의 말

이 작품은 보조금 번호로 자금을 지원 받았습니다. 국립보건원(NIH, E.J.T. 및 S.R.S.) 산하 국립중개과학진흥센터(NCATS)의 UL1TR002550. DETECT를 지원해준 N. Dalton에게 감사드립니다. 또한 DETECT에 기여한 D. Oran, T. Peters, R. Kamyar 및 C. Nowak에게도 감사드립니다.

저자 기여

G.Q., J.M.R., K.B.-M., V.K., E.J.T. 그리고 S.R.S. 연구 개념과 설계에 상당한 기여를 했습니다. K.B.-M., L.A., E.R., V.K. 그리고 S.R.S. 데이터 획득에 큰 기여를 했습니다. G.Q. 그리고 M.G. 통계분석을 실시했습니다. G.Q., J.M.R., M.G. 그리고 S.R.S. 데이터 해석에 많은 기여를 했습니다. G.Q., J.M.R. 그리고 S.R.S. 원고의 첫 번째 버전 초안을 작성했습니다. G.Q., J.M.R., M.G., K.B.-M., L.A., E.R., V.K., E.J.T. 그리고 S.R.S. 중요한 수정에 기여하고 원고의 최종 버전을 승인했습니다. G.Q., J.M.R. 그리고 S.R.S. 업무의 무결성에 대한 책임을 집니다.

이해관계 경쟁

S.R.S. 제출된 작업 외에 Janssen의 보조금과 Otsuka 및 Livongo의 개인 수수료를 보고합니다. 다른 저자는 경쟁 관계를 선언하지 않습니다.

추가 정보

이 문서에 대한 추가 정보는 <https://doi.org/10.1038/s41591-020-1123-x>에서 확인할 수 있습니다.

자료에 대한 서신 및 요청은 G.Q로 전달되어야 합니다.

재인쇄 및 허가 정보는 www.nature.com/reprints에서 확인할 수 있습니다.

편집자 표창문 Michael Basson은 이 기사의 주요 편집자였으며 나머지 편집 팀과 협력하여 편집 프로세스와 동료 검토를 관리했습니다.

Reporting Summary

Nature Research wishes to improve the reproducibility of the work that we publish. This form provides structure for consistency and transparency in reporting. For further information on Nature Research policies, see our [Editorial Policies](#) and the [Editorial Policy Checklist](#).

Statistics

For all statistical analyses, confirm that the following items are present in the figure legend, table legend, main text, or Methods section.

n/a Confirmed

- | | | |
|-------------------------------------|-------------------------------------|--|
| ☐ | ☒ | The exact sample size (n) for each experimental group/condition, given as a discrete number and unit of measurement |
| ☐ | ☒ | A statement on whether measurements were taken from distinct samples or whether the same sample was measured repeatedly |
| ☐ | ☒ | The statistical test(s) used AND whether they are one- or two-sided
<i>Only common tests should be described solely by name; describe more complex techniques in the Methods section.</i> |
| ☐ | ☒ | A description of all covariates tested |
| ☐ | ☒ | A description of any assumptions or corrections, such as tests of normality and adjustment for multiple comparisons |
| ☐ | ☒ | A full description of the statistical parameters including central tendency (e.g. means) or other basic estimates (e.g. regression coefficient) AND variation (e.g. standard deviation) or associated estimates of uncertainty (e.g. confidence intervals) |
| ☐ | ☒ | For null hypothesis testing, the test statistic (e.g. F , t , r) with confidence intervals, effect sizes, degrees of freedom and P value noted
<i>Give P values as exact values whenever suitable.</i> |
| ☒ | ☐ | For Bayesian analysis, information on the choice of priors and Markov chain Monte Carlo settings |
| ☒ | ☐ | For hierarchical and complex designs, identification of the appropriate level for tests and full reporting of outcomes |
| ☒ | ☐ | Estimates of effect sizes (e.g. Cohen's d , Pearson's r), indicating how they were calculated |

Our web collection on [statistics for biologists](#) contains articles on many of the points above.

Software and code

Policy information about [availability of computer code](#)

Data collection

The MyDataHelps smartphone based app was developed by CareEvolution, and it includes the DETECT study since March 25, 2020. The participants have agreed to share the historical data collected by their eligible devices, including heartrate, sleep and activity measures. On first use, the app records self-reported age, gender and location. With continued use the users are encouraged to share additional information through the completion of targeted surveys, including manifestation of symptoms and COVID-19 test outcomes. Data from the participants is automatically uploaded to a protected server.

Data analysis

Analyses were carried out using Python version 3.8.5. The Python packages pandas version 1.1.2 and numpy version 1.19.1 have been used for data processing. Receiver operating characteristic (ROC) curves were computed using the Python package scikit-learn version 0.23.2. Statistical tests and p-values have been evaluated using the Python package scipy version 1.5.2.

For manuscripts utilizing custom algorithms or software that are central to the research but not yet described in published literature, software must be made available to editors and reviewers. We strongly encourage code deposition in a community repository (e.g. GitHub). See the Nature Research [guidelines for submitting code & software](#) for further information.

Data

Policy information about [availability of data](#)

All manuscripts must include a [data availability statement](#). This statement should provide the following information, where applicable:

- Accession codes, unique identifiers, or web links for publicly available datasets
- A list of figures that have associated raw data
- A description of any restrictions on data availability

All interested investigators will be allowed access to the analysis data set following registration and pledging to not re-identify individuals or share the data with a third party. All data inquiries should be addressed to the corresponding author.

Reporting Summary

Nature Research wishes to improve the reproducibility of the work that we publish. This form provides structure for consistency and transparency in reporting. For further information on Nature Research policies, see our [Editorial Policies](#) and the [Editorial Policy Checklist](#).

Statistics

For all statistical analyses, confirm that the following items are present in the figure legend, table legend, main text, or Methods section.

n/a Confirmed

- | | | |
|-------------------------------------|-------------------------------------|--|
| ☐ | ☒ | The exact sample size (n) for each experimental group/condition, given as a discrete number and unit of measurement |
| ☐ | ☒ | A statement on whether measurements were taken from distinct samples or whether the same sample was measured repeatedly |
| ☐ | ☒ | The statistical test(s) used AND whether they are one- or two-sided
<i>Only common tests should be described solely by name; describe more complex techniques in the Methods section.</i> |
| ☐ | ☒ | A description of all covariates tested |
| ☐ | ☒ | A description of any assumptions or corrections, such as tests of normality and adjustment for multiple comparisons |
| ☐ | ☒ | A full description of the statistical parameters including central tendency (e.g. means) or other basic estimates (e.g. regression coefficient) AND variation (e.g. standard deviation) or associated estimates of uncertainty (e.g. confidence intervals) |
| ☐ | ☒ | For null hypothesis testing, the test statistic (e.g. F , t , r) with confidence intervals, effect sizes, degrees of freedom and P value noted
<i>Give P values as exact values whenever suitable.</i> |
| ☒ | ☐ | For Bayesian analysis, information on the choice of priors and Markov chain Monte Carlo settings |
| ☒ | ☐ | For hierarchical and complex designs, identification of the appropriate level for tests and full reporting of outcomes |
| ☒ | ☐ | Estimates of effect sizes (e.g. Cohen's d , Pearson's r), indicating how they were calculated |

Our web collection on [statistics for biologists](#) contains articles on many of the points above.

Software and code

Policy information about [availability of computer code](#)

Data collection

The MyDataHelps smartphone based app was developed by CareEvolution, and it includes the DETECT study since March 25, 2020. The participants have agreed to share the historical data collected by their eligible devices, including heartrate, sleep and activity measures. On first use, the app records self-reported age, gender and location. With continued use the users are encouraged to share additional information through the completion of targeted surveys, including manifestation of symptoms and COVID-19 test outcomes. Data from the participants is automatically uploaded to a protected server.

Data analysis

Analyses were carried out using Python version 3.8.5. The Python packages pandas version 1.1.2 and numpy version 1.19.1 have been used for data processing. Receiver operating characteristic (ROC) curves were computed using the Python package scikit-learn version 0.23.2. Statistical tests and p-values have been evaluated using the Python package scipy version 1.5.2.

For manuscripts utilizing custom algorithms or software that are central to the research but not yet described in published literature, software must be made available to editors and reviewers. We strongly encourage code deposition in a community repository (e.g. GitHub). See the Nature Research [guidelines for submitting code & software](#) for further information.

Data

Policy information about [availability of data](#)

All manuscripts must include a [data availability statement](#). This statement should provide the following information, where applicable:

- Accession codes, unique identifiers, or web links for publicly available datasets
- A list of figures that have associated raw data
- A description of any restrictions on data availability

All interested investigators will be allowed access to the analysis data set following registration and pledging to not re-identify individuals or share the data with a third party. All data inquiries should be addressed to the corresponding author.

Field-specific reporting

Please select the one below that is the best fit for your research. If you are not sure, read the appropriate sections before making your selection.

☒ Life sciences ☐ Behavioural & social sciences ☐ Ecological, evolutionary & environmental sciences

For a reference copy of the document with all sections, see [nature.com/documents/nr-reporting-summary-flat.pdf](https://www.nature.com/documents/nr-reporting-summary-flat.pdf)

Life sciences study design

All studies must disclose on these points even when the disclosure is negative.

Sample size	Between March 25, 2020 and June 7, 2020, 30,529 US individuals were enrolled in the DETECT study. During the study, 3,811 individuals reported symptoms through the DETECT smartphone app. 480 individuals reported having had a SARS-CoV-2 test, 333 of which having received the outcome (54 individuals tested positive; 279 tested negative). We applied bootstrap resampling method with 10,000 independent iterations to estimate the uncertainty of the outcomes due to the sample size. Due to the observational nature of the study, we did not perform any statistical analysis to predetermine the sample size, which was enforced by the number of active participants enrolled.
Data exclusions	The 3,811 individuals who completed the report for symptoms in the DETECT app were included in the analysis of frequency of symptoms. All the 333 individuals who had received the outcome of the SARS-CoV-2 test were included in the analysis of the proposed models. The data exclusion criteria for the analysis were pre-established. Due to the nature of the study, only individuals owning a smartwatch or activity tracker device were able to be enrolled. No data samples that were eligible for the analysis has been excluded.
Replication	The study has not been replicated, due to the nature of the data collection process, requiring the enrollment of thousands of individuals. The methods have been described in detail in the paper with all the software packages adopted, so it is possible to replicate the study by accessing a similar but independent dataset.
Randomization	Randomization was not relevant for this study, as participants have not been divided in two or more cohorts at the beginning of the study. The study focuses on the discrimination between individuals who tested positive or negative to COVID-19, so no randomization is needed.
Blinding	The group allocation was solely related to the data shared by the participants. Due to the observational nature of the study, the investigators were not involved in any arbitrary group allocation.

Reporting for specific materials, systems and methods

We require information from authors about some types of materials, experimental systems and methods used in many studies. Here, indicate whether each material, system or method listed is relevant to your study. If you are not sure if a list item applies to your research, read the appropriate section before selecting a response.

Materials & experimental systems

n/a	Involved in the study
☒	☐ Antibodies
☒	☐ Eukaryotic cell lines
☒	☐ Palaeontology and archaeology
☒	☐ Animals and other organisms
☐	☒ Human research participants
☒	☐ Clinical data
☒	☐ Dual use research of concern

Methods

n/a	Involved in the study
☒	☐ ChIP-seq
☒	☐ Flow cytometry
☒	☐ MRI-based neuroimaging

Human research participants

Policy information about [studies involving human research participants](#)

Population characteristics	Between March 25, 2020 and June 7, 2020, our research study enrolled 30,529 individuals with representation from every state in the United States. Among the consented individuals, 62.0% are female and 12.8% are 65 or more years old. 78.4% of participants connected their Fitbit device to the study-app, 31.2% connected the data from Apple Health Kit while 8.1% connected data from Google Fit (note that one individual can connect to multiple platforms). The most important covariates available at the time of analysis are sex, age and device used by each participants. We did not observe any statistically significant difference among subjects with reported positive and negative COVID-19 test.
Recruitment	Any person living in the United States over the age of 18 years old is eligible to participate in the DETECT study by downloading the iOS or Android research app, MyDataHelps. Scripps Research, along with outreach partners, conducted a multi-faceted outreach campaign including social media, educational web-based content, email outreach and in-app notifications to recruit participants for the DETECT Study. The study was also featured in several national media outlets, which increased visibility to larger section of the U.S. population.

Field-specific reporting

Please select the one below that is the best fit for your research. If you are not sure, read the appropriate sections before making your selection.

☒ Life sciences ☐ Behavioural & social sciences ☐ Ecological, evolutionary & environmental sciences

For a reference copy of the document with all sections, see [nature.com/documents/nr-reporting-summary-flat.pdf](https://www.nature.com/documents/nr-reporting-summary-flat.pdf)

Life sciences study design

All studies must disclose on these points even when the disclosure is negative.

Sample size	Between March 25, 2020 and June 7, 2020, 30,529 US individuals were enrolled in the DETECT study. During the study, 3,811 individuals reported symptoms through the DETECT smartphone app. 480 individuals reported having had a SARS-CoV-2 test, 333 of which having received the outcome (54 individuals tested positive; 279 tested negative). We applied bootstrap resampling method with 10,000 independent iterations to estimate the uncertainty of the outcomes due to the sample size. Due to the observational nature of the study, we did not perform any statistical analysis to predetermine the sample size, which was enforced by the number of active participants enrolled.
Data exclusions	The 3,811 individuals who completed the report for symptoms in the DETECT app were included in the analysis of frequency of symptoms. All the 333 individuals who had received the outcome of the SARS-CoV-2 test were included in the analysis of the proposed models. The data exclusion criteria for the analysis were pre-established. Due to the nature of the study, only individuals owning a smartwatch or activity tracker device were able to be enrolled. No data samples that were eligible for the analysis has been excluded.
Replication	The study has not been replicated, due to the nature of the data collection process, requiring the enrollment of thousands of individuals. The methods have been described in detail in the paper with all the software packages adopted, so it is possible to replicate the study by accessing a similar but independent dataset.
Randomization	Randomization was not relevant for this study, as participants have not been divided in two or more cohorts at the beginning of the study. The study focuses on the discrimination between individuals who tested positive or negative to COVID-19, so no randomization is needed.
Blinding	The group allocation was solely related to the data shared by the participants. Due to the observational nature of the study, the investigators were not involved in any arbitrary group allocation.

Reporting for specific materials, systems and methods

We require information from authors about some types of materials, experimental systems and methods used in many studies. Here, indicate whether each material, system or method listed is relevant to your study. If you are not sure if a list item applies to your research, read the appropriate section before selecting a response.

Materials & experimental systems

n/a	Involved in the study
☒	☐ Antibodies
☒	☐ Eukaryotic cell lines
☒	☐ Palaeontology and archaeology
☒	☐ Animals and other organisms
☐	☒ Human research participants
☒	☐ Clinical data
☒	☐ Dual use research of concern

Methods

n/a	Involved in the study
☒	☐ ChIP-seq
☒	☐ Flow cytometry
☒	☐ MRI-based neuroimaging

Human research participants

Policy information about [studies involving human research participants](#)

Population characteristics	Between March 25, 2020 and June 7, 2020, our research study enrolled 30,529 individuals with representation from every state in the United States. Among the consented individuals, 62.0% are female and 12.8% are 65 or more years old. 78.4% of participants connected their Fitbit device to the study-app, 31.2% connected the data from Apple Health Kit while 8.1% connected data from Google Fit (note that one individual can connect to multiple platforms). The most important covariates available at the time of analysis are sex, age and device used by each participants. We did not observe any statistically significant difference among subjects with reported positive and negative COVID-19 test.
Recruitment	Any person living in the United States over the age of 18 years old is eligible to participate in the DETECT study by downloading the iOS or Android research app, MyDataHelps. Scripps Research, along with outreach partners, conducted a multi-faceted outreach campaign including social media, educational web-based content, email outreach and in-app notifications to recruit participants for the DETECT Study. The study was also featured in several national media outlets, which increased visibility to larger section of the U.S. population.

Individuals owning a smartwatch or activity tracker and having access to COVID-19 diagnostic testing may not be fully representative of the general population.

Ethics oversight

The protocol for this study was reviewed and approved by the Scripps Office for the Protection of Research Subjects (IRB 20-7531). All individuals participating in the study provided informed consent electronically.

Note that full information on the approval of the study protocol must also be provided in the manuscript.

Individuals owning a smartwatch or activity tracker and having access to COVID-19 diagnostic testing may not be fully representative of the general population.

Ethics oversight

The protocol for this study was reviewed and approved by the Scripps Office for the Protection of Research Subjects (IRB 20-7531). All individuals participating in the study provided informed consent electronically.

Note that full information on the approval of the study protocol must also be provided in the manuscript.