

^{1,2}✉, Facundo ^{2,3} & María Paula ³, Lara Eleonora ³, José Manuel Ferrández ^{4,5}

In this work, a novel dataset containing physiological signals recorded non invasively during structured acute stress induction, as well as aerobic and anaerobic exercise sessions is presented. The physiological data were collected using the Empatica E4, a wearable device that measures electrodermal activity, skin temperature, three-axis accelerometry and blood volume pulse, from which heart rate and heart rate variability features can be derived. A stress induction protocol was designed using mathematical and emotional tasks to elicit physiological responses. For aerobic and anaerobic exercise, a stationary bike routine was developed to distinguish between the two types of activity. The dataset includes records from 36 healthy individuals during the stress protocol, 30 during aerobic exercise, and 31 during anaerobic exercise. Several machine learning algorithms were applied to validate the dataset, with XGBoost achieving an accuracy of 93% in classifying stress versus rest, 91% in distinguishing between aerobic and anaerobic exercise, and 84% in a four-label classification task involving stress, rest, aerobic, and anaerobic activities. The dataset is publicly available for further research.

Motivation. Type 1 diabetes mellitus (T1DM) is an autoimmune disease that leads to the destruction of insulin-producing pancreatic beta cells. As a result, patients require lifelong exogenous insulin administration and continuous blood glucose monitoring to prevent hypo- and hyperglycemia episodes^{1,2}. The most advanced technology for diabetes management today is the artificial pancreas (AP) system, which automates the delivery of basal insulin via continuous subcutaneous infusion. This system uses a control algorithm that receives data from interstitial glucose sensors to regulate an insulin pump¹. However, varied factors, such as food intake, physical activity (PA), stress, and illness, can cause significant fluctuations in blood glucose levels. These fluctuations often require user intervention due to rapid and sometimes unpredictable changes in insulin requirements². The current challenge is to improve the performance and autonomy of AP systems by incorporating biometric measurements of these disturbances. The first step toward this goal is the accurate detection of physical activity and acute stress using non-invasive physiological signals³.

Stress is a natural human response, defined by the World Health Organization (WHO) as a state of worry or mental tension triggered by a difficult situation. Stressful events can elicit cognitive, emotional, and biological reactions, which can be assessed through self-report measures, behavioral coding, or physiological measurements⁴. Indicators such as heart rate (HR), heart rate variability (HRV), blood volume pulse (BVP), electrodermal activity (EDA), skin temperature (ST), and motion activity are widely recognized as markers of acute stress. These physiological responses are of particular interest because they can be measured in real-time using wearable sensors like photoplethysmography (PPG), accelerometers (ACC), and temperature sensors, enabling continuous stress monitoring in daily life—a critical requirement for integration into the AP system⁵.

Physical activity is defined by WHO as any bodily movement produced by skeletal muscles that requires energy expenditure. PA includes both structured exercise-activities characterized by specific types, intensities,

¹

²

³

⁴

⁵European Culture and Technology Laboratory - ECT Lab+
✉e-mail:

급성 스트레스와 운동에 따른 웨어러블 생리적 신호 정황

andrea Hongn^{1,2}, Facundo Bosch³, Lara Eleonora Prado³, Jose Manuel Ferrández^{4,5} 및 María Paula Bonomini^{2,3}

이 연구에서는 구조화된 급성 스트레스 유도는 물론 유산소 및 무산소 운동 세션 동안 비침습적으로 기록된 생리적 신호가 포함된 새로운 데이터 세트가 제시됩니다. 생리학적인 데이터는 피부 전기 활동, 피부 온도, 3축 가속도 측정 및 혈액량 펄스를 측정하는 웨어러블 장치인 Empatica E4를 사용하여 수집되었으며, 이를 통해 심박수 및 심박수 변화 특성을 파생할 수 있습니다. 스트레스 유도 프로토콜은 생리적 반응을 이끌어내기 위해 수학적, 감정적 작업을 사용하여 설계되었습니다. 유산소 운동과 무산소 운동의 경우 두 가지 유형의 활동을 구별하기 위해 고정식 자전거 루틴이 개발되었습니다. 데이터 세트에는 스트레스 프로토콜 중 36명의 건강한 개인, 유산소 운동 중 30명, 무산소 운동 중 31명의 기록이 포함되어 있습니다. 데이터 세트를 검증하기 위해 여러 기계 학습 알고리즘이 적용되었으며, XGBoost는 스트레스와 휴식을 분류하는 데 93%, 유산소 운동과 무산소 운동을 구별하는 데 91%, 스트레스, 휴식, 유산소, 무산소 활동과 관련된 4개 라벨 분류 작업에서 84%의 정확도를 달성했습니다. 데이터 세트는 추가 연구를 위해 공개적으로 제공됩니다.

배경 및 요약

동기 부여. 제1형 당뇨병(T1DM)은 인슐린을 생산하는 췌장 베타 세포가 파괴되는 자가면역 질환입니다. 결과적으로 환자는 저혈당증 및 고혈당증을 예방하기 위해 평생 외인성 인슐린 투여와 지속적인 혈당 모니터링이 필요합니다^{1,2}. 오늘날 당뇨병 관리를 위한 가장 진보된 기술은 지속적인 피하 주입을 통해 기저 인슐린 전달을 자동화하는 인공 췌장(AP) 시스템입니다. 이 시스템은 인슐린 펌프를 조절하기 위해 간질 포도당 센서로부터 데이터를 수신하는 제어 알고리즘을 사용합니다. 그러나 음식 섭취, 신체 활동(PA), 스트레스, 질병 등 다양한 요인으로 인해 혈당 수치가 크게 변동될 수 있습니다. 이러한 변동은 인슐린 요구량의 빠르고 때로는 예측할 수 없는 변화로 인해 사용자 개입이 필요한 경우가 많습니다. 현재 과제는 이러한 장애에 대한 생체 인식 측정을 통합하여 AP 시스템의 성능과 자율성을 향상시키는 것입니다. 이 목표를 향한 첫 번째 단계는 비침습적 생리학적 신호³를 사용하여 신체 활동과 급성 스트레스를 정확하게 감지하는 것입니다.

스트레스는 인간의 자연스러운 반응으로, 세계보건기구(WHO)는 어려운 상황으로 인해 촉발된 걱정이나 정신적 긴장 상태로 정의합니다. 스트레스가 많은 사건은 인지적, 정서적, 생물학적 반응을 유발할 수 있으며, 이는 자가 보고 측정, 행동 코딩 또는 생리학적 측정을 통해 평가할 수 있습니다⁴. 심박수(HR), 심박 변이도(HRV), 혈액량 맥박(BVP), 피부 전기 활동(EDA), 피부 온도(ST) 및 운동 활동과 같은 지표는 급성 스트레스의 지표로 널리 인식됩니다. 이러한 생리적 반응은 광용적맥파측정(PPG), 가속도계(ACC), 온도 센서와 같은 웨어러블 센서를 사용하여 실시간으로 측정할 수 있어 일상 생활에서 지속적인 스트레스 모니터링이 가능하기 때문에 특히 중요합니다. 이는 AP 시스템에 통합하기 위한 중요한 요구 사항입니다⁵.

WHO에서는 신체 활동을 에너지 소비가 필요한 골격근에 의해 생성되는 신체 움직임으로 정의합니다. PA에는 특정 유형, 강도,

1Universidad de Buenos Aires. 아르헨티나 부에노스아이레스의 생물 의학 연구소(iiBM)의 공학 교수진. 2Instituto Argentino de Matemática “Alberto P. Calderón”(iAM), 코니세트, 아르헨티나 부에노스아이레스. 3Departamento de ciencias de la Vida, 부에노스아이레스 기술연구소(iiBA), 아르헨티나 부에노스아이레스. 4Departamento de Electrónica, tecnología de computadoras y Proyectos, Universidad Politécnica de Cartagena, 카르타헤나, 스페인. 5유럽 문화 및 기술 연구소 - ECT Lab+, 유럽 기술 대학교, 스페인 카르타헤나. 이메일: ahongn.ext@fi.uba.ar

and durations-and non-exercise activities related to daily living. Aerobic, sprint, and resistance training can lead to significant variations in blood glucose levels, making it crucial to detect not only the presence of physical activity but also its type, intensity, and duration. Although wearable devices may not achieve the accuracy of laboratory techniques in quantifying exercise, they offer the advantage of continuous monitoring in real-world settings. Among the biomarkers related to PA intensity, HR provides the best estimation of energy expenditure. Other variables measurable by wearable devices that can serve as indicators of exercise include ST, near-body ambient temperature, skin electrical conductance, breathing rates/frequencies, heat flux, sweat rate, and accelerations in triaxial planes².

Although the physiological responses to exercise and acute stress can be described using the same indicators, a key objective of this work is to analyze the best features for detecting each condition. In pursuing this goal, we observed that, despite several research groups working on this topic-including efforts on simultaneous detection of physical activity and stress⁶⁻⁸ and the integration of glucose prediction models⁹ -, there is a notable lack of open datasets containing wearable data collected during structured sessions of acute stress and aerobic and anaerobic exercise.

Public datasets. We conducted an extensive search for open datasets on platforms such as PhysioNet and Kaggle, as well as popular scientific repositories, focusing on wearable data collected under acute stress and structured physical activity conditions. However, none of the datasets we found met the specific needs of our research. As a result, we decided to carry out our data collection, to make this dataset publicly available in the future.

Several publicly available datasets focus on stress detection and emotional research using wearable data¹⁰⁻¹². We excluded datasets from non-wearable devices, as they do not align with our research objectives. However, some datasets also include data from non-wearable sensors such as ECG, EEG, respiration, and SpO2¹³⁻¹⁵. Additionally, certain datasets feature multimodal recordings, including voice and video¹⁵.

The measurement devices, stressors, and self-reported emotional/stress assessments vary across these datasets. Common stress-inducing tasks include the Stroop test, arithmetic tasks, the Trier Social Stress Test, and stressful videos. Most of these datasets were collected in controlled environments, though some were recorded in specific contexts, such as during exams¹⁶ and while driving¹⁷.

A few datasets include continuous monitoring in daily life, capturing spontaneous stress events and unstructured physical activities like chores, walking, and climbing stairs. For example, the Multilevel Monitoring of Activity and Sleep in Healthy people (MMASH) dataset provides psychophysiological data of individuals in daily life, but the activities related to physical activity are grouped into 13 categories, introducing inter-participant variability (n=22)¹⁸.

In terms of physical activity monitoring, Poon *et al.* developed a PPG dataset from wearable devices as participants engaged in sitting, stationary walking, and running¹⁹. The dataset presented by Urbanek *et al.* focuses on ACC data collected during semi-structured outdoor activities, such as walking, stair climbing, and driving²⁰. Similarly, the REALDISP dataset includes a wide range of physical activities (e.g., warm-up, cool-down, and fitness exercises), sensor modalities (including acceleration, rate of turn, magnetic field, and quaternions), and participants (n=17)²¹.

There are also several open datasets focused on Human Activity Recognition, which involve participants performing various activities, including exercise²².

The datasets developed by Birjandtalab *et al.* and Falk *et al.*, which include acute stress and exercise, are the most closely related to our work^{23,24}. The first one explores neurological status assessments and includes a 5-minute exercise routine as a physical stressor measured with a wearable device. In the second one, participants performed tasks of varying stress levels at three different activity levels on a stationary bike (0 km/h, 18 km/h, 24 km/h) and provided quantitative ratings of their perceived stress and fatigue levels. However, to the best of our knowledge, no publicly available dataset captures wearable data during structured, well-defined, induced stress sessions alongside long-duration aerobic and anaerobic exercise protocols.

Key contribution. We are sharing a dataset of healthy young men and women (n=36), which includes physiological signals from a wearable device. These signals were collected during structured sessions of induced acute stress, as well as during exercise sessions. In addition, self-reported stress levels are provided. All activities followed standardized and reproducible protocols.

The main contributions of this work are as follows:

- To the best of our knowledge, this dataset fills the gap between stress and structured physical activity assessment, unifying both in a single database. This enables the analysis of variables influenced by stress, as well as aerobic and anaerobic exercise, improving the accurate detection of these states. This is essential, for example, to incorporate biometric measurements into an AP control algorithm due to different effects of these disturbances on glycemic dynamic in T1DM patients.
- For stress research, we provide an efficient and reproducible protocol for stress inducement, supported by self-reported stress levels throughout the protocol. This protocol alternates periods of acute induced stress with rest periods, providing a comprehensive view of physiological responses.
- Exercise sessions were conducted on different days to ensure that the effects do not overlap. Aerobic and anaerobic exercise sessions are of considerable length (20-30 minutes), reflecting typical exercise routines in daily life, focusing on differentiating between aerobic and anaerobic activities.
- Protocols are well-documented, and signals are labeled to accurately identify and segment each phase. Additionally, we provide a script to open, read, and visualize the data.
- This work also presents machine learning classification results to validate the potential of the presented data.

일상 생활과 관련된 기간 및 비운동 활동. 유산소 운동, 단거리 달리기, 저항력 훈련은 혈당 수치에 큰 변화를 가져올 수 있으므로 신체 활동의 존재 여부뿐만 아니라 그 유형, 강도 및 기간도 감지하는 것이 중요합니다. 웨어러블 장치는 운동을 정량화하는 데 있어서 실험실 기술의 정확성을 달성할 수 없지만 실제 환경에서 지속적인 모니터링의 이점을 제공합니다. PA 강도와 관련된 바이오마커 중에서 HR은 에너지 소비에 대한 최상의 추정치를 제공합니다. 운동 지표 역할을 할 수 있는 웨어러블 장치로 측정할 수 있는 다른 변수로는 ST, 신체 근처 주변 온도, 피부 전기 전도도, 호흡률/빈도, 열유속, 땀 속도 및 삼축 평면의 가속도가 있습니다².

운동과 급성 스트레스에 대한 생리적 반응은 동일한 지표를 사용하여 설명할 수 있지만, 이 연구의 주요 목적은 각 상태를 감지하기 위한 최상의 특징을 분석하는 것입니다. 이 목표를 추구하면서 우리는 신체 활동과 스트레스의 동시 감지⁶⁻⁸ 및 포도당 예측 모델의 통합⁹을 포함하여 이 주제에 대해 작업하는 여러 연구 그룹에도 불구하고 급성 스트레스와 유산소 및 무산소 운동의 구조화된 세션 동안 수집된 웨어러블 데이터를 포함하는 공개 데이터 세트가 눈에 띄게 부족하다는 것을 관찰했습니다.

공개 데이터 세트. 우리는 급성 스트레스 및 구조화된 신체 활동 조건에서 수집된 웨어러블 데이터에 중점을 두고 PhysioNet 및 Kaggle과 같은 플랫폼과 인기 있는 과학 저장소에서 공개 데이터 세트에 대한 광범위한 검색을 수행했습니다. 그러나 우리가 찾은 데이터 세트 중 어느 것도 우리 연구의 특정 요구 사항을 충족하지 못했습니다. 결과적으로 우리는 데이터 수집을 수행하여 **항상 이 데이터 세트를 공개적으로 사용할 수 있도록 하기로 결정했습니다** 스트레스 감지 및 감정 연구에 중점을 둡니다. 비웨어러블 기기의 데이터 세트는 연구 목표와 일치하지 않으므로 제외했습니다. 그러나 일부 데이터 세트에는 ECG, EEG, 호흡 및 SpO₂¹³⁻¹⁵와 같은 비착용형 센서의 데이터도 포함됩니다. 또한 특정 데이터 세트에는 음성 및 영상을 포함한 다중 모드 녹음 기능이 있습니다¹⁵.

측정 장치, 스트레스 요인 및 자체 보고된 감정/스트레스 평가는 이러한 데이터 세트에 따라 다릅니다. 일반적인 스트레스 유발 작업에는 Stroop 테스트, 산술 작업, Trier Social Stress Test 및 스트레스가 많은 비디오가 포함됩니다. 이러한 데이터 세트의 대부분은 통제된 환경에서 수집되었지만 일부는 시험 중¹⁶ 및 운전 중¹⁷과 같은 특정 상황에서 기록되었습니다.

몇 가지 데이터 세트에는 일상 생활에서의 지속적인 모니터링, 자발적인 스트레스 이벤트 캡처, 집안 일, 걷기, 계단 오르기와 같은 구조화되지 않은 신체 활동이 포함됩니다. 예를 들어 MMASH(Multilevel Monitoring of Activity and Sleep in Healthy people) 데이터 세트는 일상 생활에서 개인의 정신생리학적 데이터를 제공하지만 신체 활동과 관련된 활동은 13개 카테고리로 그룹화되어 참가자 간 변동성이 발생합니다(n=22)¹⁸.

신체 활동 모니터링 측면에서 Poon et al. 앉기, 정지 걷기 및 달리기 참여하는 참가자로서 웨어러블 장치에서 PPG 데이터 세트를 개발했습니다¹⁹. Urbanek et al.이 제시한 데이터 세트 걷기, 계단 오르기, 운전 등 반구조화된 야외 활동 중에 수집된 ACC 데이터에 중점을 둡니다.²⁰ 마찬가지로 REALDISP 데이터 세트에는 광범위한 신체 활동(예: 준비 운동, 정리 운동, 피트니스 운동), 센서 양식(가속도, 회전 속도, 자기장 및 쿼터니언 포함) 및 참가자(n=17)²¹가 포함됩니다.

또한 참가자가 운동을 포함한 다양한 활동을 수행하는 인간 활동 인식에 초점을 맞춘 여러 공개 데이터 세트가 있습니다²².

Birjandtalab et al.이 개발한 데이터 세트 급성 스트레스와 운동을 포함하는 Falk et al.은 우리 작업과 가장 밀접한 관련이 있습니다^{23,24}. 첫 번째는 신경학적 상태 평가를 탐색하고 웨어러블 장치로 측정된 신체적 스트레스 요인으로 5분 운동 루틴을 포함합니다. 두 번째 실험에서 참가자들은 고정식 자전거(0km/h, 18km/h, 24km/h)에서 세 가지 다른 활동 수준에서 다양한 스트레스 수준의 작업을 수행하고 인지된 스트레스 및 피로 수준에 대한 정량적 평가를 제공했습니다. 그러나 우리가 아는 한, 공개적으로 사용 가능한 데이터 세트는 장기간의 유산소 및 무산소 운동 프로토콜과 함께 구조화되고 잘 정의되어 유도된 스트레스 세션 동안 웨어러블 데이터를 캡처하지 않습니다.

주요 기여. 우리는 웨어러블 기기의 생리적 신호가 포함된 건강한 젊은 남성과 여성(n=36)의 데이터 세트를 공유하고 있습니다. 이러한 신호는 유발된 급성 스트레스의 구조화된 세션과 운동 세션 중에 수집되었습니다. 또한, 자가 보고된 스트레스 수준도 제공됩니다. 모든 활동은 표준화되고 재현 가능한 프로토콜을 따랐습니다.

이 작업의 주요 기여는 다음과 같습니다.

- 우리가 아는 한, 이 데이터 세트는 스트레스와 구조화된 신체 활동 평가 사이의 격차를 메우고 두 가지를 단일 데이터베이스에 통합합니다. 이를 통해 스트레스, 유산소 및 무산소 운동의 영향을 받는 변수를 분석할 수 있어 이러한 상태를 정확하게 감지할 수 있습니다. 예를 들어 T1DM 환자의 혈당 역학에 대한 이러한 장애의 다양한 영향으로 인해 생체 인식 측정을 AP 제어 알고리즘에 통합하는 것이 필수적입니다.
- 스트레스 연구를 위해 우리는 프로토콜 전반에 걸쳐 자체 보고된 스트레스 수준을 통해 지원되는 스트레스 유도를 위한 효율적이고 재현 가능한 프로토콜을 제공합니다. 이 프로토콜은 급성 유발 스트레스 기간과 휴식 기간을 번갈아 사용하여 생리적 반응에 대한 포괄적인 보기를 제공합니다.
- 효과가 중복되지 않도록 운동 세션을 다른 날에 실시했습니다. 유산소 및 무산소 운동 세션은 상당한 길이(20~30분)로 일상 생활의 일반적인 운동 루틴을 반영합니다. 유산소 활동과 무산소 활동을 구별하는 데 중점을 둡니다.
- 프로토콜은 잘 문서화되어 있으며 각 단계를 정확하게 식별하고 분할하기 위해 신호에 라벨이 지정되어 있습니다. 또한 데이터를 열고, 읽고, 시각화하는 스크립트를 제공합니다.
- 이 작업은 또한 제시된 데이터의 잠재력을 검증하기 위해 기계 학습 분류 결과를 제시합니다.

ID	Gender [m][f]	Age [years]	Height [cm]	Weight [kg]	Trains	Protocol version	Stress Inducement	Aerobic Exercise	Anaerobic Exercise
S01	m	21	192	84	Y	v1	Y	Y	Y****
S02	m	20	185	95	N	v1	Y****	Y	Y
S03	m	20	175	62	Y	v1	Y	Y***	Y
S04	m	21	174	70	Y	v1	Y	Y	Y
S05	m	21	173	72	Y	v1	Y	Y	Y
S06	m	21	172	70	Y	v1	Y	Y	Y***
S07	m	19	184	88	Y	v1	Y	Y***	Y
S08	m	20	174	67	Y	v1	Y	Y	Y
S09	m	19	174	63	Y	v1	Y	Y	Y
S10	m	21	180	80	Y	v1	Y	Y	Y
S11	m	21	183	64	Y	v1	Y	Y**	Y
S12	m	18	176	79	Y	v1	Y	-	Y
S13	m	21	175	65	Y	v1	Y	Y	Y
S14	m	19	182	85	Y	v1	Y	Y	Y
S15	m	21	176	77	Y	v1	Y	Y	Y
S16	m	20	168	61	Y	v1	Y	Y	Y**
S17	m	22	173	78	Y	v1	Y	Y	Y
S18	m	21	183	80	Y	v1	Y	Y	Y
f01	f	25	152	61	N	v2	Y	Y	Y
f02	f	29	164	80	N	v2	Y	Y	Y
f03	f	26	160	61	Y	v2	Y	Y	Y
f04	f	29	168	56	N	v2	Y	Y	Y
f05	f	21	165	55	Y	v2	Y	Y	Y
f06	f	21	169	58	N	v2	Y	Y	Y
f07	f	21	163	47	N	v2	Y*	Y	Y
f08	f	22	158	50	N	v2	Y	Y	Y
f09	f	21	170	56	Y	v2	Y	Y	Y
f10	f	21	172	65	Y	v2	Y	Y	Y
f11	f	31	170	84	N	v2	Y	Y	Y
f12	f	30	158	97	N	v2	Y	Y	Y
f13	f	29	154	56	N	v2	Y	Y	Y
f14	f	—	—	—	—	v2	Y**	—	—
f15	f	—	—	—	—	v2	Y	—	—
f16	f	—	—	—	—	v2	Y	—	—
f17	f	—	—	—	—	v2	Y	—	—
f18	m	—	—	—	—	v2	Y	—	—

Table 1. Demographic participants data. References: *m*(male); *f*(female); Y(Yes); N(No); v1(First Stage); v2(Second Stage); * Wrong wristband placement; ** Connection Loss; *** Protocol was not fully completed; **** Files with Constraints

Methods

Measurement device. The Empatica E4 wristband, a class IIa Medical Device in the EU, is a wearable wireless device designed for comfortable, continuous, real-time data acquisition in daily life. This wristband is intended for use in research settings. The E4 contains four sensors, each with its own sampling frequency: (1) Photoplethysmography to provide blood volume pulse, from which HR, HRV, and other cardiovascular features may be derived; (2) Electrodermal activity, used to measure sympathetic nervous system arousal; (3) 3-axis accelerometer, to capture motion-based activity; (4) Infrared thermopile, reading skin temperature.

Data collection. The data collection process was conducted in two stages. Initially, a group of 18 volunteers (v1) followed the protocol. A few months later, a second group of 18 volunteers (v2) participated using an improved protocol based on initial experience. We will outline these modifications below. For all protocols, the E4 device was placed on the subject's non-dominant hand to minimize motion artifacts during the tests.

Population. Participants were males and females between 19 and 30 years. Out of the 36 volunteers participating in the study, all 36 completed the stress protocol, 31 completed the anaerobic session, and 30 completed the aerobic session. Some participants were unable to finish the exercise sessions. Demographic information is presented on Table 1.

ID	Gender [m][f]	Age [years]	Height [cm]	Weight [kg]	Trains	Protocol version	Stress Inducement	Aerobic Exercise	Anaerobic Exercise
S01	m	21	192	84	Y	v1	Y	Y	Y****
S02	m	20	185	95	N	v1	Y****	Y	Y
S03	m	20	175	62	Y	v1	Y	Y****	Y
S04	m	21	174	70	Y	v1	Y	Y	Y
S05	m	21	173	72	Y	v1	Y	Y	Y
S06	m	21	172	70	Y	v1	Y	Y	Y***
S07	m	19	184	88	Y	v1	Y	Y***	Y
S08	m	20	174	67	Y	v1	Y	Y	Y
S09	m	19	174	63	Y	v1	Y	Y	Y
S10	m	21	180	80	Y	v1	Y	Y	Y
S11	m	21	183	64	Y	v1	Y	Y**	Y
S12	m	18	176	79	Y	v1	Y	-	Y
S13	m	21	175	65	Y	v1	Y	Y	Y
S14	m	19	182	85	Y	v1	Y	Y	Y
S15	m	21	176	77	Y	v1	Y	Y	Y
S16	m	20	168	61	Y	v1	Y	Y	Y**
S17	m	22	173	78	Y	v1	Y	Y	Y
S18	m	21	183	80	Y	v1	Y	Y	Y
f01	f	25	152	61	N	v2	Y	Y	Y
f02	f	29	164	80	N	v2	Y	Y	Y
f03	f	26	160	61	Y	v2	Y	Y	Y
f04	f	29	168	56	N	v2	Y	Y	Y
f05	f	21	165	55	Y	v2	Y	Y	Y
f06	f	21	169	58	N	v2	Y	Y	Y
f07	f	21	163	47	N	v2	Y*	Y	Y
f08	f	22	158	50	N	v2	Y	Y	Y
f09	f	21	170	56	Y	v2	Y	Y	Y
f10	f	21	172	65	Y	v2	Y	Y	Y
f11	f	31	170	84	N	v2	Y	Y	Y
f12	f	30	158	97	N	v2	Y	Y	Y
f13	f	29	154	56	N	v2	Y	Y	Y
f14	f	—	—	—	—	v2	Y**	—	—
f15	f	—	—	—	—	v2	Y	—	—
f16	f	—	—	—	—	v2	Y	—	—
f17	f	—	—	—	—	v2	Y	—	—
f18	m	—	—	—	—	v2	Y	—	—

표 1. 인구통계학적 참가자 데이터. 참고문헌: m(남성); f(여성); 예(예); N(아니오); v1(첫 번째 단계); v2(2단계); * 잘못된 손목 밴드 배치; ** 연결 손실; *** 프로토콜이 완전히 완료되지 않았습니다. **** 제약 조건이 있는 파일

행동 양식

측정 장치. EU의 클래스 IIa 의료 기기인 Empatica E4 손목 밴드는 일상 생활에서 편안하고 지속적인 실시간 데이터 수집을 위해 설계된 웨어러블 무선 장치입니다. 이 손목 밴드는 연구 환경에서 사용하기 위한 것입니다. E4에는 각각 고유한 샘플링 주파수를 갖는 4개의 센서가 포함되어 있습니다. (1) HR, HRV 및 기타 심혈관 기능을 파생할 수 있는 혈액량 펄스를 제공하는 광용적맥파 측정기; (2) 교감 신경계 각성을 측정하는 데 사용되는 피부 전기 활동; (3) 모션 기반 활동을 포착하기 위한 3축 가속도계; (4) 적외선 열전퇴, 피부 온도 판독.

데이터 수집. 데이터 수집 과정은 두 단계로 진행됐다. 처음에는 18명의 자원봉사자 그룹(v1)이 프로토콜을 따랐습니다. 몇 달 후, 18명의 자원봉사자로 구성된 두 번째 그룹(v2)이 초기 경험을 바탕으로 개선된 프로토콜을 사용하여 참여했습니다. 아래에서 이러한 수정 사항을 간략하게 설명하겠습니다. 모든 프로토콜에 대해 E4 장치는 테스트 중에 모션 아티팩트를 최소화하기 위해 피험자의 자주 사용하지 않는 손에 배치되었습니다.

인구. 참가자는 19세에서 30세 사이의 남성과 여성이었습니다. 연구에 참여한 36명의 자원봉사자 중 36명 모두 스트레스 프로토콜을 완료했고, 31명은 무산소 세션을 완료했으며, 30명은 유산소 세션을 완료했습니다. 일부 참가자는 운동 세션을 완료하지 못했습니다. 인구통계 정보는 표 1에 나와 있습니다.




Fig. 1 Stress Induction Original Protocol (v1). SL (Stress Level).

Data was collected under the supervision of the Ciencias de la Vida Department at the Instituto Tecnológico de Buenos Aires (ITBA) following institutional ethical standards. This project was approved on April 27, 2023. Enrollment in the study was facilitated through an online form. The exclusion criteria included individuals with chronic illnesses and those with a family history of sudden death during exercise, as well as participants undergoing psychiatric treatment or taking medications that could potentially affect physiological responses. Before conducting the tests, each participant signed an informed consent form. This document was sent to participants in advance, allowing them sufficient time to review the information and ask any questions they might have. Participation in the trial was completely voluntary, and participants were informed that they could withdraw at any time without providing justification. Participants consented to the anonymous sharing of their demographic information, including age, weight, height, clinical status, and data collected during the trials.

Protocols. **Stress inducement.** The participant was welcomed by the researcher and led to a quiet room where the protocol was conducted. The room contained two computers: one displaying a guide outlining all the steps, and another where the interactive tasks were performed. The participants wore earphones to cancel out environmental noise and to enhance the sound stimuli during a specific task. The researcher guided the procedure but left the participant alone during rest periods to promote relaxation. The original protocol(v1) started with a 3-minute baseline recording, to be used as a reference. The first stress test was an adaptation of the widely used Stroop Test^{25,26}, adapted from PsyToolkit^{27,28}. Afterwards, a 5-minute-rest period was imposed, followed by a modified version of the Trier Mental Challenge Test²⁹, obtained through Millisecond Software, LLC. This test involved a series of mathematical tasks within a 5 seconds time limit while an annoying sound stimulus was played in the background. Participants were also instructed to vocalize their responses aloud, which further added to the cognitive load and performance demands of the task. Once again, a 5-minute-period came before the final block. In the latter, participants were asked to express their opinion about controversial topics and suddenly were instructed to defend the opposite opinion over the same subject. Finally, participants were tasked with counting backward from 1022 in decrements of 13, providing the answers aloud. Each of these tests had a time limit of 30 seconds.

Before and after every task and rest period, participants were required to verbally express their self-perception stress level (SL) on a scale ranging from 1 to 10. A summary of the protocol is shown in Fig. 1.

Anaerobic activity. The anaerobic exercise protocol was adapted from the Wingate Anaerobic Test³⁰. It began with a 3-minute baseline recording during which the subject pedaled without resistance to warm up. This was followed by three cycles, each consisting of 30 seconds of maximal effort, where the subject pedaled at their highest intensity against high resistance, followed by a 4-minute cool-down period without resistance. Finally, a 2-minute recording was made while the subject remained still.

Aerobic activity. The aerobic exercise test was adapted from the Storer-Davis Maximal Bicycle Protocol and involved continuous stationary cycling for approximately 35 minutes³¹. First, we determined the maximum resistance for each participant by identifying the point at which they could no longer pedal at maximum effort. The protocol began with a 3-minute baseline recording during which the subject pedaled without resistance to warm up. After completing the baseline, the subject cycled in sync with a metronome, with each beat corresponding to one foot down (or one knee up), meaning one revolution was completed every two beats.

Starting with low resistance (20% of maximum), the subject went through three 3-minute periods at increasing paces of 60, 70, and 75 revolutions per minute (rpm), gradually raising the resistance up to a medium level (30% of maximum). This was followed by four periods, the first two lasting 3 minutes each and the second two lasting 2 minutes each, at paces of 80, 85, 90, and 95 rpm, respectively, with a gradual increase in resistance (5% per stage). With a final fixed medium-high resistance (50% of maximum), the last three periods consisted of 2 minutes each, at paces of 100, 105, and 110 rpm, respectively.

Once completed, a 4-minute cool down period without resistance was conducted, followed by 2 minutes of remaining still.

Protocol improvements. The second version of the protocol incorporated several modifications based on previous experience. For stress induction, the Stroop Test was removed, and the second rest period was relocated




그림 1 스트레스 유도 원래 프로토콜(v1). SL(스트레스 수준).

데이터는 기관 윤리 기준에 따라 ITBA(Instituto Tecnológico de Buenos Aires)의 Ciencias de la Vida 부서의 감독하에 수집되었습니다. 이 프로젝트는 2023년 4월 27일에 승인되었습니다. 연구 등록은 온라인 양식을 통해 촉진되었습니다. 제외 기준에는 만성 질환이 있는 사람, 운동 중 급사 가족력이 있는 사람, 정신과 치료를 받고 있거나 잠재적으로 생리적 반응에 영향을 미칠 수 있는 약물을 복용 중인 참가자가 포함되었습니다. 테스트를 수행하기 전에 각 참가자는 사전 동의서에 서명했습니다. 이 문서는 참가자들에게 미리 전송되어 참가자들이 정보를 검토하고 질문할 수 있는 충분한 시간을 제공했습니다. 임상시험 참여는 전적으로 자발적으로 이루어졌으며, 참가자에게는 정당한 사유 없이 언제든지 철회할 수 있다는 안내가 제공되었습니다. 참가자들은 나이, 체중, 키, 임상 상태, 임상시험 기간 동안 수집된 데이터 등 인구통계학적 정보를 익명으로 공유하는 데 동의했습니다.

프로토콜. 스트레스 유발. 참가자는 연구원의 환영을 받고 프로토콜이 진행되는 조용한 방으로 안내되었습니다. 방에는 두 대의 컴퓨터가 있었습니다. 하나는 모든 단계의 개요를 설명하는 가이드를 표시하고 다른 하나는 대화형 작업을 수행했습니다. 참가자들은 특정 작업 중에 환경 소음을 제거하고 소리 자극을 강화하기 위해 이어폰을 착용했습니다. 연구자는 절차를 안내했지만 이완을 촉진하기 위해 휴식 시간 동안 참가자를 혼자 두었습니다. 원래 프로토콜(v1)은 참조로 사용하기 위해 3분 기준 기록으로 시작되었습니다. 첫 번째 스트레스 테스트는 널리 사용되는 Stroop Test^{25,26}를 PsyToolkit^{27,28}에서 수정한 것입니다. 그 후 5분의 휴식 시간을 부여한 후 Millisecond Software, LLC를 통해 얻은 Trier Mental Challenge Test²⁹의 수정된 버전을 받았습니다. 이 테스트에는 귀찮은 소리 자극이 배경에서 재생되는 동안 5초 제한 시간 내에 일련의 수학 작업이 포함되었습니다. 참가자들은 또한 자신의 반응을 큰 소리로 말하도록 지시받았으며, 이는 작업의 인지 부하와 수행 요구를 더욱 증가시켰습니다. 마지막 블록이 나오기 전에 다시 한 번 5분간의 시간이 왔습니다. 후자에서는 참가자들에게 논쟁의 여지가 있는 주제에 대해 자신의 의견을 표현하도록 요청하고 갑자기 동일한 주제에 대해 반대 의견을 옹호하라는 지시를 받았습니다. 마지막으로 참가자들은 1022부터 13씩 거꾸로 세어 큰 소리로 답변을 제공하라는 임무를 받았습니다. 각 테스트에는 30초의 시간 제한이 있었습니다.

모든 작업과 휴식 시간 전후에 참가자들은 자신의 자기 인식 스트레스 수준(SL)을 1에서 10까지의 범위로 구두로 표현해야 했습니다. 프로토콜 요약은 그림 1에 나와 있습니다.

무산소 활동. 무산소 운동 프로토콜은 Wingate Anaerobic Test³⁰에서 채택되었습니다. 피험자가 워밍업에 저항하지 않고 페달을 밟는 3분간의 기본 기록으로 시작되었습니다. 그 다음에는 각각 30초의 최대 노력으로 구성된 3개의 사이클이 이어졌습니다. 여기서 피험자는 높은 저항에 대해 가장 높은 강도로 페달을 밟았고, 저항 없이 4분간의 냉각 기간이 이어졌습니다. 마지막으로 피험자가 가만히 있는 동안 2분간 녹음이 이루어졌다.

유산소 활동. 유산소 운동 테스트는 Storer-Davis Maximal Bicycle Protocol에서 채택되었으며 약 35분 동안 연속 고정 사이클링을 포함했습니다³¹. 먼저, 우리는 참가자들이 더 이상 최대한의 노력으로 페달을 밟을 수 없는 지점을 식별하여 각 참가자의 최대 저항을 결정했습니다. 프로토콜은 피험자가 워밍업에 저항하지 않고 페달을 밟는 3분간의 기본 기록으로 시작되었습니다. 기준선을 완료한 후 피험자는 메트로놈에 맞춰 순환했습니다. 각 박자는 한 발 아래로(또는 한 무릎 위로) 해당하며, 이는 두 박자마다 한 바퀴가 완료되었음을 의미합니다.

낮은 저항(최대의 20%)에서 시작하여 피험자는 분당 회전수(rpm)가 60, 70, 75회 증가하는 속도로 3분의 3분 기간을 거쳐 점차적으로 저항을 중간 수준(최대의 30%)까지 높였습니다. 그 후 4개의 기간이 이어졌습니다. 첫 번째 두 기간은 각각 3분, 두 번째 두 기간은 각각 2분 동안 각각 80, 85, 90 및 95rpm의 속도로 저항이 점진적으로 증가했습니다(단계당 5%). 최종적으로 고정된 중간-높은 저항(최대의 50%)을 사용하여 마지막 세 기간은 각각 100, 105 및 110rpm의 속도로 각각 2분으로 구성되었습니다.

완료되면 저항 없이 4분간의 냉각 기간을 수행한 후 2분간 정지 상태를 유지했습니다.

프로토콜 개선. 프로토콜의 두 번째 버전은 이전 경험을 바탕으로 몇 가지 수정 사항을 통합했습니다. 스트레스 유도를 위해 Stroop Test를 삭제하고 2차 휴식시간을 재배치하였습니다.

between the opinion tasks and the subtraction test. Rest periods were extended, and a relaxing video was shown. Additionally, the protocol was conducted remotely, creating a more relaxed environment during rest times.

In the updated exercise protocols, participants attended in groups to a spinning room. The aerobic protocol was modified as follows: a baseline was introduced, followed by a 2:15-minute warm-up. This was succeeded by three 1:30-minute intervals at 70, 75, and 80 rpm, respectively. An 11:15-minute session at 85 rpm was conducted, leading into a final 4:30-minute period at 90/95 rpm (depending on the participant's condition). The session concluded with a 3-minute cool down, followed by a rest period where participants sat on the bike without movement.

For the anaerobic protocol, a fourth maximum power sprint was added, with the sprints extended to 45 seconds each, followed by a corresponding cool down period.

All raw data recorded during the experiment are publicly available for further research and analysis. The Jupyter Notebook containing the source code for data visualization, along with complementary files such as stress levels and demographic data, is provided alongside the raw signal files. Data can be downloaded from PhysioNet³² (<https://doi.org/10.13026/zzf8-xv61>), Repositorio Institucional CONICET Digital³³ (<http://hdl.handle.net/11336/245570>) and from Zenodo³⁴ (<https://doi.org/10.5281/zenodo.13993658>).

The dataset is organized into three main categories: STRESS, AEROBIC exercise, and ANAEROBIC exercise. Each category contains subfolders specific to individual subjects, where raw sensor reading .csv files downloaded from the Empatica E4 Connect are stored. The exceptions are the *IBI.csv* and *HR.csv* files, which are generated by Empatica's algorithm. Tags related to unintentionally pressed buttons have been deleted from the tags file to improve protocol understanding. These tags mark the beginning and end of protocol segments, which facilitates signal segmentation.

In accordance with HIPAA Safe Harbor De-Identification guidelines, each participant is assigned a unique ID. The session dates and event marks during the protocols (in tags.csv) have been modified by a random number of days, with the resulting shift exceeding one year. Time samples have been shifted consistently across all records to maintain signal alignment. Empatica provides time in Unix timestamp format, but files are already converted to UTC. Participants from the first stage are labeled as "Sxx" while those from the second stage are labeled as "fxx".

Each subject folder contains the raw signal .csv files provided by Empatica. These files follow this format: the first row is the initial time of the session expressed in UTC (Empatica provides time in Unix timestamp format, but files are already converted to UTC). The second row is the sample rate expressed in Hz.

- TEMP.csv: Data from temperature sensor expressed degrees on the Celsius (°C) scale.
- EDA.csv: Data from the electrodermal activity sensor expressed as microsiemens (μS).
- BVP.csv: Data from photoplethysmography sensor.
- ACC.csv: Data from 3-axis accelerometer sensor. The accelerometer is configured to measure acceleration in the range [-2g, 2g]. Therefore the unit in this file is 1/64g. Data from x, y, and z axis are respectively in first, second, and third column.
- IBI.csv: Time between individuals heart beats extracted from the BVP signal. No sample rate is needed for this file. The first column is the time (respect to the initial time) of the detected inter-beat interval expressed in seconds (s). The second column is the duration in seconds (s) of the detected inter-beat interval (i.e., the distance in seconds from the previous beat).
- HR.csv: Average heart rate values computed in spans of 10 seconds extracted from the BVP signal. The first row is the initial time of the session expressed in UTC. The second row is the sample rate expressed in Hz.
- tags.csv: Event mark times. Each row corresponds to a physical button press on the device; the same time as the status LED is first illuminated. The time is expressed in UTC and it is synchronized with initial time of the session indicated in the related data files from the corresponding session

Activities performed and demographic data such as age, weight, and height are provided in the *subject-info.csv* file.

Additionally, a file containing all self-reported stress levels for each stage is provided (*Stress_level_v1.csv* and *Stress_level_v2.csv*).

Some participants experienced issues such as incorrect wristband placements, incomplete protocols, and connection problems. Details about these issues can be found in the *data_constraints.txt* file. These register have not taken in count for ML classifications but are provided in the dataset for research purpose.

We assessed the technical validity of the dataset through two key approaches: (1) analyzing self-reported stress levels to evaluate the effectiveness of the stress induction protocols, and (2) performing both binary and four-state classifications to demonstrate the potential of physiological signals in distinguishing between different conditions.

Self Reported Stress-Level Analysis. The stress induction protocol proved to be effective in generating stress during the tasks and relaxation during the rest periods. This is supported by the self-reported perceived stress levels shown in Fig. 2 (v1) and Fig. 3 (v2). To control for individual differences in stress perception, we normalized the reported stress levels for each participant. For all statistical tests, a p-value (*p*) threshold of 0.05 was used to determine significance. Tests yielding $p < 0.05$ were considered statistically significant.

의견 과제와 뺄셈 시험 사이, 휴식시간도 연장되었고, 편안한 영상도 상영되었습니다. 또한, 프로토콜은 원격으로 진행되어 휴식 시간 동안 더욱 편안한 환경을 조성했습니다.

업데이트된 운동 프로토콜에서 참가자들은 그룹으로 회전실에 참석했습니다. 유산소 프로토콜은 다음과 같이 수정되었습니다. 기준선을 도입한 후 2분 15초의 워밍업을 실시했습니다. 이는 각각 70, 75, 80rpm에서 3번의 1:30분 간격으로 이어졌습니다. 85rpm에서 11분 15초 세션이 진행되었으며, 마지막 4분 30초는 90/95rpm에서 진행되었습니다(참가자의 상태에 따라 다름). 세션은 3분간의 정리 시간으로 마무리되었으며, 참가자들은 움직이지 않고 자전거에 앉아 휴식 시간을 가졌습니다.

무산소 프로토콜의 경우 네 번째 최대 파워 스프린트가 추가되었으며, 스프린트는 각각 45초로 연장되고 그에 상응하는 냉각 기간이 이어졌습니다.

데이터 기록

실험 중에 기록된 모든 원시 데이터는 추가 연구 및 분석을 위해 공개적으로 제공됩니다. 스트레스 수준, 인구 통계 데이터 등의 보완 파일과 함께 데이터 시각화를 위한 소스 코드가 포함된 Jupyter Notebook이 원시 신호 파일과 함께 제공됩니다. 데이터는 PhysioNet³²(<https://doi.org/10.13026/zzf8-xv61>), Repositorio Institucional CONICET Digital³³(<http://hdl.handle.net/11336/245570>) 및 Zenodo³⁴에서 다운로드할 수 있습니다. (<https://doi.org/10.5281/zenodo.13993658>).

데이터 세트는 STRESS, AEROBIC 운동, ANAEROBIC 운동의 세 가지 주요 카테고리로 구성됩니다. 각 카테고리에는 Empatica E4 Connect에서 다운로드한 원시 센서 판독 .csv 파일이 저장되는 개별 주제별 하위 폴더가 포함되어 있습니다. Empatica의 알고리즘에 의해 생성된 IBL.csv 및 HR.csv 파일은 예외입니다. 프로토콜 이해도를 높이기 위해 의도하지 않은 버튼과 관련된 태그를 태그 파일에서 삭제했습니다. 이러한 태그는 프로토콜 세그먼트의 시작과 끝을 표시하여 신호 분할을 용이하게 합니다.

HIPAA Safe Harbor 익명화 지침에 따라 각 참가자에게는 고유한 ID가 할당됩니다. 프로토콜(tags.csv) 중 세션 날짜와 이벤트 표시는 임의의 일수만큼 수정되었으며 결과적으로 1년이 넘는 변화가 발생했습니다. 신호 정렬을 유지하기 위해 모든 레코드에서 시간 샘플이 일관되게 이동되었습니다. Empatica는 Unix 타임스탬프 형식으로 시간을 제공하지만 파일은 이미 UTC로 변환되어 있습니다. 첫 번째 단계의 참가자는 "Sxx"로 표시되고 두 번째 단계의 참가자는 "fxx"로 표시됩니다.

각 주제 폴더에는 Empatica에서 제공하는 원시 신호 .csv 파일이 포함되어 있습니다. 이러한 파일은 다음 형식을 따릅니다. 첫 번째 행은 UTC로 표현된 세션의 초기 시간입니다(Empatica는 Unix 타임스탬프 형식으로 시간을 제공하지만 파일은 이미 UTC로 변환되었습니다). 두 번째 행은 Hz로 표현된 샘플링 속도입니다.

- TEMP.csv: 온도 센서의 데이터는 섭씨(°C) 단위로 온도를 표시합니다.
- EDA.csv: 마이크로시멘스(μ S)로 표시되는 피부전극 활동 센서의 데이터입니다.
- BVP.csv: 광용적맥파 센서의 데이터.
- ACC.csv: 3축 가속도계 센서의 데이터입니다. 가속도계는 [-2g, 2g] 범위의 가속도를 측정하도록 구성됩니다. 따라서 이 파일의 단위는 1/64g입니다. x, y 및 z 축의 데이터는 각각 첫 번째, 두 번째 및 세 번째 열에 있습니다.
- IBL.csv: BVP 신호에서 추출된 개인 심장 박동 사이의 시간입니다. 이 파일에는 샘플링 속도가 필요하지 않습니다. 첫 번째 열은 초(s)로 표시되는 감지된 비트 간 간격의 시간(초기 시간에 대한)입니다. 두 번째 열은 감지된 비트 간 간격(즉, 이전 비트로부터의 거리(초))의 지속 시간(초)입니다.
- HR.csv: BVP 신호에서 추출된 10초 동안 계산된 평균 심박수 값입니다. 첫 번째 행은 UTC로 표현된 세션의 초기 시간입니다. 두 번째 행은 Hz로 표현된 샘플링 속도입니다.
- Tags.csv: 이벤트 표시 시간. 각 행은 장치의 물리적 버튼 누르기에 해당합니다. 상태 LED가 처음으로 켜지는 것과 동시에. 시간은 UTC로 표시되며 해당 세션의 관련 데이터 파일에 표시된 세션의 초기 시간과 동기화됩니다.

수행한 활동과 연령, 체중, 키 등의 인구통계학적 데이터가 주제 정보에 제공됩니다. csv 파일.

또한 각 단계에 대해 자체 보고된 모든 스트레스 수준이 포함된 파일이 제공됩니다(Stress_level_v1.csv 및 Stress_level_v2.csv).

일부 참가자는 잘못된 손목밴드 배치, 불완전한 프로토콜, 연결 문제 등의 문제를 경험했습니다. 이러한 문제에 대한 세부정보는 data_constraints.txt 파일에서 확인할 수 있습니다. 이러한 레지스터는 ML 분류에 포함되지 않지만 연구 목적으로 데이터세트에 제공됩니다.

기술 검증

우리는 두 가지 주요 접근법을 통해 데이터세트의 기술적 타당성을 평가했습니다. (1) 스트레스 유도 프로토콜의 효과를 평가하기 위해 자체 보고된 스트레스 수준을 분석하고, (2) 서로 다른 조건을 구별하는데 생리학적 신호의 잠재력을 입증하기 위해 이진 및 4가지 상태 분류를 모두 수행합니다.

자가 보고된 스트레스 수준 분석. 스트레스 유도 프로토콜은 작업 중 스트레스를 생성하고 휴식 시간 동안 휴식을 취하는 데 효과적인 것으로 입증되었습니다. 이는 그림 2(v1) 및 그림 3(v2)에 표시된 자체 보고된 인지된 스트레스 수준에 의해 뒷받침됩니다. 스트레스 인식의 개인차를 통제하기 위해 우리는 각 참가자에 대해 보고된 스트레스 수준을 정규화했습니다. 모든 통계 테스트의 경우 p값(p) 임계값 0.05를 사용하여 유의성을 결정했습니다. $p < 0.05$ 를 산출하는 테스트는 통계적으로 유의미한 것으로 간주되었습니다.




Fig. 2 Normalized Stress Auto Reported Level - First Stage (v1).




Fig. 3 Normalized Stress Auto Reported Level - Second Stage (v2).

	v1	v2
Baseline vs TMCT	$p=6.21e-4$	$p=7.00e-6$
First_Rest vs TMCT	$p=1.70e-5$	$p=9.53e-11$
Second_Rest vs TMCT	$p=7.82e-3$	$p=9.87e-14$
Real_Opinion vs TMCT		$p=5.20e-5$
Opposite_Opinion vs TMCT		$p=7.17e-3$
Second_Rest vs Real_Opinion		$p=3.76e-2$
First_Rest vs Opposite_Opinion		$p=1.78e-2$
Second_Rest vs Opposite_Opinion		$p=4.43e-4$
First_Rest vs Subtract Test	$p=6.23e-3$	$p=7.86e-4$
Second_Rest vs Subtract Test		$p=1.10e-5$

Table 2. Significance Differences of Normalized Stress Levels Between Blocks. (v1: First Stage; v2: Second Stage).

A Shapiro-Wilk test was used to assess the normality of the data for each block. Several blocks showed a non-normal distribution: Baseline ($p = 0.037$) and First_Rest ($p = 0.047$) in v1, and Real_Opinion ($p = 0.022$) in v2. Therefore, we applied the non-parametric Kruskal-Wallis test. Both stages demonstrated statistically significant differences between the blocks ($p = 6.24e-06$ for v1, and $p = 9.96e-16$ for v2).

Following this, Dunn's post-hoc test was applied to determine which groups were significantly different, as presented in Table 2. The Trier Mental Challenge Test resulted as the primary stress-inducing block in both data collection stages, followed by the Subtract Test, with both tasks involving mathematical challenges.

Signal Preprocessing and Feature Extraction. For signal filtering and preprocessing, we utilized Python libraries such as Pandas, SciPy and NumPy, along with open-source tools like NeuroKit2³⁵.

Tags were used to segment the signal according to the protocol. From each segment, we extracted relevant features to characterize the signals, aiming to distinguish between different conditions. These features were then used as input for training and evaluating different machine learning models.

The files we worked with included *BVP.csv*, *HR.csv*, *EDA.csv*, and *ACC.csv*, as well as the *tags.csv* file for segmentation purposes. In this work, we did not perform any temperature analysis. Additionally, we chose not to use the *IBI.csv* file provided by Empatica due to missing data, particularly for exercise recordings. A summary of the entire process, from data collection to classification, is illustrated in Fig. 4.

Signal preprocessing. Blood Volume Pulse refers to the variation in arterial blood volume under the skin resulting from the heart cycle. To remove noise, we applied a 4th-order Chebyshev Type II digital filter with a band-pass of 0.5-10 Hz.




그림 2 정규화된 스트레스 자동 보고 수준 - 첫 번째 단계(v1).




그림 3 정규화된 스트레스 자동 보고 수준 - 두 번째 단계(v2).

	v1	v2
Baseline vs TMCT	$p=6.21e-4$	$p=7.00e-6$
First_Rest vs TMCT	$p=1.70e-5$	$p=9.53e-11$
Second_Rest vs TMCT	$p=7.82e-3$	$p=9.87e-14$
Real_Opinion vs TMCT		$p=5.20e-5$
Opposite_Opinion vs TMCT		$p=7.17e-3$
Second_Rest vs Real_Opinion		$p=3.76e-2$
First_Rest vs Opposite_Opinion		$p=1.78e-2$
Second_Rest vs Opposite_Opinion		$p=4.43e-4$
First_Rest vs Subtract Test	$p=6.23e-3$	$p=7.86e-4$
Second_Rest vs Subtract Test		$p=1.10e-5$

표 2. 블록 간 정규화된 스트레스 수준의 유의미한 차이. (v1: 첫 번째 단계, v2: 두 번째 단계).

Shapiro-Wilk 테스트를 사용하여 각 블록에 대한 데이터의 정규성을 평가했습니다. 여러 블록은 v1의 Baseline($p = 0.037$) 및 First_Rest($p = 0.047$), v2의 Real_Opinion($p = 0.022$) 등 비정규 분포를 보여주었습니다. 따라서 우리는 비모수적 Kruskal-Wallis 테스트를 적용했습니다. 두 단계 모두 블록 간에 통계적으로 유의미한 차이를 보여주었습니다(v1의 경우 $p = 6.24e-06$, v2의 경우 $p = 9.96e-16$).

그 후, 표 2에 제시된 것처럼 어떤 그룹이 크게 다른지 확인하기 위해 Dunn의 사후 테스트가 적용되었습니다. Trier Mental Challenge Test는 두 데이터 수집 단계 모두에서 주요 스트레스 유발 블록으로 나타났으며, 그 다음에는 빼기 테스트(Subtract Test)가 있었으며 두 작업 모두 수학적 문제와 관련되어 있었습니다.

신호 전처리 및 특징 추출. 신호 필터링 및 전처리를 위해 NeuroKit³⁵와 같은 오픈 소스 도구와 함께 Pandas, SciPy 및 NumPy와 같은 Python 라이브러리를 활용했습니다.

태그는 프로토콜에 따라 신호를 분할하는 데 사용되었습니다. 각 세그먼트에서 다양한 조건을 구별하기 위해 신호를 특성화하기 위해 관련 기능을 추출했습니다. 그런 다음 이러한 기능은 다양한 기계 학습 모델을 훈련하고 평가하기 위한 입력으로 사용되었습니다.

우리가 작업한 파일에는 BVP.csv, HR.csv, EDA.csv 및 ACC.csv와 세분화 목적을 위한 tagged.csv 파일이 포함되었습니다. 본 연구에서는 온도 분석을 수행하지 않았습니다. 또한 특히 운동 기록의 경우 데이터 누락으로 인해 Empatica에서 제공하는 IBI.csv 파일을 사용하지 않기로 결정했습니다. 데이터 수집부터 분류까지 전체 과정을 요약하면 그림 4에 나와 있습니다.

신호 전처리. 혈액량 맥박은 심장 주기로 인해 피부 아래 동맥혈량의 변화를 나타냅니다. 잡음을 제거하기 위해 대역 통과율이 0.5~10Hz인 4차 Chebyshev Type II 디지털 필터를 적용했습니다.




Fig. 4 Feature extraction.

Electrodermal Activity measures the variation in skin conductance in response to sweat gland activity, which is controlled by the sympathetic nervous system. This signal includes both a tonic component (skin conductance level, SCL) and a rapid phasic component (skin conductance responses, SCRs), which result from sympathetic neuronal activity. The raw EDA signal was filtered using a 5th-order Butterworth low-pass filter with a cutoff frequency of 1.99 Hz. Once filtered, a Savitzky-Golay filter was applied to separate the tonic and phasic components.

Heart rate variability is considered an indicator of mental stress and physical fitness. The standard method of obtaining HRV is through ECG, using the time interval between two consecutive R-peaks (*Inter Beat Interval*, *IBI*). An alternative method is through Pulse Rate Variability, which measures the time interval between successive peaks in the PPG signal. BVP was filtered, and wave peaks were detected to obtain pulse intervals, equivalent to the RR intervals in ECG³⁶. We then obtained the normal pulse-to-pulse intervals, discarding ectopic and incorrectly detected beats. Once we got the clean interval series, time domain and frequency domain features were computed.

No filtering was applied to the 3-axis accelerometer signals or the heart rate data provided by Empatica.

Feature extraction. The features can be categorized into general statistical properties (mean and standard deviation), minimum and maximum change ratios (obtained from the 5% and 95% percentile of the first derivative, respectively), and specific signal characteristics.

- For the filtered BVP, the mean and standard deviation were calculated.
- For HR, the mean and standard deviation were obtained, along with the maximum and minimum change ratios.
- Statistical features were derived from the raw, phasic, and tonic EDA signals. The minimum and maximum change ratios was computed for the tonic component. For the phasic component, the Neurokit2 tool was used to extract information from Skin Conductance Responses (SCR) events, including SCR amplitude, the samples at which SCR onsets and peaks occurred, SCR rise time (time from onset to peak), SCR recovery time (time from peak to the midpoint of the fall), and SCR height (value from onset to peak). Additionally, SCR density was derived by dividing the number of SCR events by the segment length.
- Regarding HRV, time-domain features included mean, maximum and minimum IBI. The HR mean was computed from the IBI mean, which differs from the HR data provided for Empatica. Further features included SDNN (standard deviation of normal-to-normal intervals), RMSSD (root mean square of successive differences between normal beats), pNN50, and pNN20 (percentage of the difference associated with NN intervals differing by more than 50 ms and 20 ms, respectively) were calculated. In the frequency domain, the power and peaks of each frequency band - Very Low Frequency (VLF: 0-0.04 Hz), Low Frequency (LF: 0.04-0.15 Hz), High Frequency (HF: 0.15-0.4 Hz), and Very High Frequency (VHF: 0.4-2 Hz) - were calculated. Total power, normalized LF and HF, and the LF/HF ratio were also computed.




그림 4 특징 추출.

피부 전기 활동은 교감 신경계에 의해 제어되는 땀샘 활동에 대한 피부 전도도의 변화를 측정합니다. 이 신호에는 강장성 성분(피부 전도 수준, SCL)과 빠른 위상 성분(피부 전도 반응, SCR)이 모두 포함되며 이는 교감 신경 활동의 결과입니다. 원시 EDA 신호는 차단 주파수가 1.99Hz인 5차 버터워스 저역 통과 필터를 사용하여 필터링되었습니다. 일단 필터링되면 Savitzky-Golay 필터를 적용하여 강장제 성분과 위상 성분을 분리했습니다.

심박수 변이는 정신적 스트레스와 신체적 건강의 지표로 간주됩니다. HRV를 얻는 표준 방법은 두 개의 연속 R-피크 사이의 시간 간격(Inter Beat Interval, IBI)을 사용하는 ECG를 이용하는 것입니다. 또 다른 방법은 PPG 신호의 연속 피크 사이의 시간 간격을 측정하는 맥박수 가변성을 이용하는 것입니다. BVP를 필터링하고 파동 피크를 감지하여 ECG³⁶의 RR 간격과 동일한 펄스 간격을 얻었습니다. 그런 다음 이소성 및 잘못 감지된 비트를 버리고 정상적인 펄스 간 간격을 얻었습니다. 깨끗한 간격 계열을 얻은 후에는 시간 영역 및 주파수 영역 기능이 계산되었습니다.

필터링이 적용되지 않은 심박수 데이터 또는 제공된 심박수 데이터에 적용됩니다. 엠파티카.

특징 추출. 특징은 일반적인 통계 특성(평균 및 표준 편차), 최소 및 최대 변화 비율(각각 1차 도함수의 5 % 및 95% 백분위수에서 구함), 특정 신호 특성으로 분류할 수 있습니다.

- 필터링된 BVP에 대해 평균과 표준편차가 계산되었습니다.
- HR의 경우 최대 및 최소 변화율과 함께 평균 및 표준 편차를 얻었습니다.
- 통계적 특징은 원시, 위상 및 토닉 EDA 신호에서 파생되었습니다. 강장제 성분에 대해 최소 및 최대 변화 비율을 계산했습니다. 위상 구성 요소의 경우 Neurokit2 도구를 사용하여 SCR 진폭, SCR 시작 및 최고점이 발생한 샘플, SCR 상승 시간(시작부터 최고점까지의 시간), SCR 회복 시간(하강 최고점에서 중간점까지의 시간) 및 SCR 높이(시작부터 최고점까지의 값)를 포함하는 피부 전도 반응(SCR) 이벤트로부터 정보를 추출했습니다. 또한 SCR 밀도는 SCR 이벤트 수를 세그먼트 길이로 나누어 파생되었습니다.
- HRV와 관련하여 시간 영역 기능에는 평균, 최대 및 최소 IBI가 포함되었습니다. HR 평균은 IBI 평균으로부터 계산되었으며 이는 Empatica에 제공된 HR 데이터와 다릅니다. 추가 기능에는 SDNN(정상 간 간격의 표준 편차), RMSSD(정상 박동 간 연속 차이의 평균 제곱근), pNN50 및 pNN20(각각 50ms와 20ms 이상 차이가 나는 NN 간격과 관련된 차이의 백분율)이 계산되었습니다. 주파수 영역에서는 극저주파(VLF: 0~0.04Hz), 저주파(LF: 0.04~0.15Hz), 고주파수(HF: 0.15~0.4Hz), 초고주파(VHF: 0.4~2Hz) 등 각 주파수 대역의 전력 및 피크를 계산했습니다. 총 전력, 정규화된 LF 및 HF, LF/HF 비율도 계산되었습니다.

E4 Signal	Type	Features
BVP (2)	Statistical	<i>bvp_mean, bvp_std</i>
HR (4)	Statistical	<i>hr_mean, hr_std, hr_ratio_down, hr_ratio_up</i>
HRV (20)	Time Domain	<i>max_ibi, min_ibi, mean_ibi, hr_mean_ibi, pnn20, pnn50, rmssd, sdnm</i>
	Frequency Domain	<i>total_power, ratio, VLF_power, VLF_peak, LF_power, LF_peak, LH_n, HF_power, HF_peak, HF_n, VHF_power, VHF_peak</i>
EDA (13)	Statistical	<i>mean_raw_eda, std_raw_eda, mean_tonic_eda, std_tonic_eda, mean_phasic_eda, std_phasic_eda, tonic_ratio_down, tonic_ratio_up</i>
	SCR Events	<i>peaks_density, scr_mean_amp, scr_mean_height, scr_mean_risetime, scr_mean_recovertime</i>
ACC (10)	Statistical	<i>x_mean, x_std, y_mean, y_std, z_mean, z_std</i>
	Magnitude	<i>acc_mean, acc_std, acc_ratio_down, acc_ratio_up</i>

Table 3. Features extracted.

- For the accelerometer data, the mean and standard deviation of each axis, as well as the magnitude, were calculated. Additionally, the maximum and minimum change ratios derived from the acceleration magnitude were obtained.

For a better comprehension, all extracted features are presented in Table 3.

Classification. *Data preprocessing.* To reduce inter-subject variability, intra-participant normalization was applied to all blocks within the stress protocol. No normalization was applied for exercise sessions and multiple classification as they were conducted on different days.

Stress blocks (Stroop, TMCT, Real, and Opposite Opinion, Subtract) were labeled as 1, and rest blocks (Baseline, First Rest and Second Rest) were labeled as 0. We used the second half of both the First Rest and Second Rest blocks to minimize the influence of any residual stress effects from the previous stress blocks. The resulting data was imbalanced due to differences in protocol versions: 154 corresponding to stress blocks and 102 for rest periods.

For the exercise sessions, a binary classification between common aerobic slots and maximum power sprints was performed, due to variations in protocol versions. For aerobic protocols, a 1-minute middle segment from 70 rpm, 75 rpm, 80 rpm, and 85 rpm blocks was extracted for analysis. For anaerobic protocols, sprints were used. The resulting data was also imbalanced: 120 samples from aerobic blocks and 106 from high-intensity blocks.

Features selection. From an initial set of 49 features, we applied a high-correlation filter, discarding features with a Pearson correlation coefficient above 0.8. The Python open-source library *Sweetviz* was used for data exploration, providing insights into categorical associations, multicollinearity analysis and distribution of the data. This helped in selecting features that provided the most informative value for the target labels. Different sets of features were tested based on these criteria.

Machine Learning algorithms. For model training and testing, we used the Python Sklearn library.

For classification purposes, 2 stress records were discarded due to incorrect wearable device placement for participant f07 and bad fit of the wristband for participant f13. Despite some incomplete exercise sessions, all participants performed the stages selected for classification.

Although these stress records were excluded from the classification analysis, they are included in dataset with their corresponding comments and constraints.

Binary classification was performed between stress vs. rest states, and aerobic segments vs. sprints. Additionally, a multi-class classification task was conducted with four labels: rest, stress, aerobic, and maximum power states.

The data were imputed and scaled (subtracting the mean and dividing by the standard deviation), and several machine learning algorithms were tested, including K-Nearest Neighbors, Logistic Regression, Gaussian Naive Bayes, Support Vector Classifier, Random Forest, and XGBoost. These models were evaluated using 10-fold cross-validation, following an 80/20 train-test split. Since the data were imbalanced, different resampling techniques were applied. The performance of the models was assessed using metrics such as accuracy, precision, recall, and F1 score.

After the feature optimization process, the original 49 features were reduced to 13, 12, and 19 features for binary stress classification, binary exercise classification, and four-label classification, respectively.

XGBoost was the best-performing model across all tasks, achieving a maximum accuracy of 93% for the binary stress/rest classification using 10-fold cross-validation. In all cases, oversampling proved to be the most effective technique for handling the data imbalance. The classification performance metrics are detailed in Table 4.

This data can be used to develop ML models for stress and exercise detection and classification, as well as for signal processing and feature extraction. For information on expected signals and recommended tools for signal processing, visit the Empatica website.

E4 Signal	Type	Features
BVP (2)	Statistical	<i>bvp_mean, bvp_std</i>
HR (4)	Statistical	<i>hr_mean, hr_std, hr_ratio_down, hr_ratio_up</i>
HRV (20)	Time Domain	<i>max_ibi, min_ibi, mean_ibi, hr_mean_ibi, pnn20, pnn50, rmssd, sdn</i>
	Frequency Domain	<i>total_power, ratio, VLF_power, VLF_peak, LF_power, LF_peak, LH_n, HF_power, HF_peak, HF_n, VHF_power, VHF_peak</i>
EDA (13)	Statistical	<i>mean_raw_eda, std_raw_eda, mean_tonic_eda, std_tonic_eda, mean_phasic_eda, std_phasic_eda, tonic_ratio_down, tonic_ratio_up</i>
	SCR Events	<i>peaks_density, scr_mean_amp, scr_mean_height, scr_mean_risetime, scr_mean_recovertime</i>
ACC (10)	Statistical	<i>x_mean, x_std, y_mean, y_std, z_mean, z_std</i>
	Magnitude	<i>acc_mean, acc_std, acc_ratio_down, acc_ratio_up</i>

표 3. 추출된 특징

• 가속도계 데이터의 경우 각 축의 평균 및 표준편차와 크기를 계산했습니다. 또한 가속도 크기로부터 도출된 최대 및 최소 변화율을 구했습니다.

예쁘게 더 나은 이해를 돕기 위해 추출된 모든 기능이 탭에 표시됩니다.

분류, 데이터 전처리, 개체 간 변동성을 줄이기 위해 참가자 내 정규화가 스트레스 프로토콜 내의 모든 블록에 적용되었습니다. 운동 세션과 다중 분류는 서로 다른 날짜에 수행되었으므로 정규화가 적용되지 않았습니다.

스트레스 블록(Stroop, TMCT, Real 및 Opposite Opinion, Subtract)은 1로 표시되었고 나머지 블록(Base line, First Rest 및 Second Rest)은 0으로 표시되었습니다. 이전 스트레스 블록의 잔류 능력 영향을 최소화하기 위해 첫 번째 휴식 및 두 번째 휴식 블록의 후반부를 사용했습니다. 프로토콜 버전의 차이로 인해 결과 데이터가 불균형했습니다. 154개는 스트레스 블록에 해당하고 102개는 휴식 기간에 해당합니다.

운동 세션의 경우 프로토콜 버전의 변화로 인해 일반적인 유산소 슬롯과 최대 파워 스프린트 간의 이진 분류가 수행되었습니다. 유산소 프로토콜의 경우 분석을 위해 70rpm, 75rpm, 80rpm 및 85rpm 블록에서 1분 중간 세그먼트를 추출했습니다. 혐기성 프로토콜의 경우 스프린트가 사용되었습니다. 결과 데이터도 불균형했습니다. 유산소 블록에서 120개 샘플, 고강도 블록에서 106개 샘플.

기능 선택. 초기 49개 특성 세트에서 고상관 필터를 적용하여 Pearson 상관 계수가 0.8보다 큰 특성을 삭제했습니다. Python 오픈 소스 라이브러리 Sweetviz는 데이터 탐색에 사용되어 범주형 연관성, 다중 공선성 분석 및 데이터 배포에 대한 통찰력을 제공했습니다. 이는 대상 레이블에 가장 유익한 값을 제공하는 기능을 선택하는 데 도움이 되었습니다. 이러한 기준에 따라 다양한 기능 세트가 테스트되었습니다.

기계 학습 알고리즘. 모델 교육 및 테스트를 위해 Python Sklearn 라이브러리를 사용했습니다.

분류 목적을 위해 참가자 f07의 잘못된 웨어러블 장치 배치와 참가자 f13의 손목 밴드 착용 불량으로 인해 2개의 스트레스 기록이 삭제되었습니다. 일부 불완전한 운동 세션에도 불구하고 모든 참가자는 분류를 위해 선택된 단계를 수행했습니다.

이러한 스트레스 기록은 분류 분석에서 제외되었지만 해당 설명 및 제약 조건과 함께 데이터 세트에 포함되었습니다.

스트레스와 휴식 상태, 유산소 구간과 스프린트 사이에 이진 분류가 수행되었습니다. 또한 휴식, 스트레스, 유산소, 최대 파워 상태 등 4가지 라벨을 사용하여 다중 클래스 분류 작업을 수행했습니다.

데이터를 대치하고 크기를 조정했으며(평균을 빼고 표준 편차로 나눔) K-Nearest Neighbors, Logistic Regression, Gaussian Naive Bayes, Support Vector Classifier, Random Forest 및 XGBoost를 포함한 여러 기계 학습 알고리즘을 테스트했습니다. 이 모델은 80/20 열차 테스트 분할 후 10겹 교차 검증을 사용하여 평가되었습니다. 데이터가 불균형했기 때문에 다양한 리샘플링 기술이 적용되었습니다. 모델의 성능은 정확도, 정밀도, 재현율, F1 점수와 같은 지표를 사용하여 평가되었습니다.

기능 최적화 프로세스 후 원래 49개의 기능은 이진 스트레스 분류, 이진 운동 분류 및 4레이블 분류를 위해 각각 13, 12, 19개의 기능으로 축소되었습니다.

XGBoost는 모든 작업에서 가장 성능이 뛰어난 모델로, 10겹 교차 검증을 사용하여 이진 스트레스/휴식 분류에 대해 최대 93%의 정확도를 달성했습니다. 모든 경우에 오버샘플링은 데이터 불균형을 처리하는 가장 효과적인 기술임이 입증되었습니다. 분류 성능 측정항목은 표 4에 자세히 설명되어 있습니다.

사용법 참고 사항

이 데이터는 스트레스와 운동 감지 및 분류는 물론 신호 처리 및 특징 추출을 위한 ML 모델을 개발하는 데 사용될 수 있습니다. 예상되는 신호와 신호 처리를 위한 권장 도구에 대한 자세한 내용을 보려면 Empatica 웹사이트를 방문하세요.

	Feature Set	Accuracy	Precision	Recall	F1
Stress / Rest	hr_mean, mean_raw_eda, mean_tonic_eda, std_tonic_eda, mean_recoverytime, max_ibi, ibi_mean, rmssd, ratio, LF_peak, x_std, y_std, z_std	93%	93%	92%	92%
Aerobic / Sprints	hr_std, std_phasic_eda, tonic_ratio_down, peaks_density, mean_recoverytime, min_ibi, pnn50, VHF_power, LF_n, z_std, acc_mean, acc_ratio_down	91%	92%	92%	91%
Stress / Rest / Aerobic / Sprints	hr_mean, hr_std, mean_tonic_eda, std_tonic_eda, mean_recoverytime, std_phasic_eda, tonic_ratio_down, peaks_density, max_ibi, ibi_mean, rmssd, min_ibi, LF_peak, LF_n, x_std, y_std, z_std, acc_mean, acc_ratio_down	84%	85%	84%	84%

Table 4. XGBoost performance metrics with 10-fold cross validation.

Pilot results on binary stress classification and feature extraction from signals have been presented at conferences^{37,38}. The multimodal classification presented in this work extends classification to detect and differentiate among various physiological states, including aerobic and anaerobic exercise, based on the collected data.

Limitations (details about these issues can be found in the *data_constraints.txt*):

- Stress Session: S02 has duplicated data; f07 did not remove the wrist-band protection cover, so not all signals are valid; f14's data is split into two parts.
- Aerobic Session: S03 and S07 could not complete the procedure; S11's data is split into two parts; S12 did not perform this test.
- Anaerobic Session: S06 could not complete the procedure; S16's data is split into two parts.

Code availability

A Jupyter Notebook (*Wearable_Dataset.ipynb*) is provided to open, read, and visualize the data. This can be downloaded from PhysioNet³² (<https://doi.org/10.13026/zzf8-xv61>), Repositorio Institucional CONICET Digital³³ (<http://hdl.handle.net/11336/245570>) and from Zenodo³⁴ (<https://doi.org/10.5281/zenodo.13993658>). To execute the notebook, ensure that basic Python libraries such as pandas, os, numpy, time, and matplotlib are installed.

Received: 18 November 2024; Accepted: 17 March 2025;

Published: 28 March 2025

References

1. Tagougui, S. *et al.* Artificial Pancreas Systems and Physical Activity in Patients with Type 1 Diabetes: Challenges, Adopted Approaches, and Future Perspectives. *Journal of Diabetes Science and Technology* **13**, 1077–1090, <https://doi.org/10.1177/1932296819869310> (2019).
2. Riddell, M., Zaharieva, D., Yavelberg, L., Cinar, A. & Jamnik, V. Exercise and the Development of the Artificial Pancreas: One of the More Difficult Series of Hurdles. *Journal of Diabetes Science and Technology* **9** <https://doi.org/10.1177/1932296815609370> (2015).
3. Abdel-Latif, M. M. *et al.* Acute Psychological Stress Detection Using Explainable Artificial Intelligence for Automated Insulin Delivery. *Signals* **5**, 494–507, <https://doi.org/10.3390/signals5030026> (2024).
4. D Crosswell, A. & Lockwood, G. K. Best practices for stress measurement: How to measure psychological stress in health research. *Health Psychology Open* **7**(2), <https://doi.org/10.1177/2055102920933072> (2020).
5. Iqbal, T. *et al.* A Review of Biophysiological and Biochemical Indicators of Stress for Connected and Preventive Healthcare. *Diagnostics* **11**, <https://doi.org/10.3390/diagnostics11030556> (2021).
6. Abdel-Latif, M. *et al.* Multi-Task Classification of Physical Activity and Acute Psychological Stress for Advanced Diabetes Treatment. *Signals* **4**, 167–192, <https://doi.org/10.3390/signals4010009> (2023).
7. Askari, M. R., Abdel-Latif, M., Rashid, M., Sevil, M. & Cinar, A. Detection and Classification of Unannounced Physical Activities and Acute Psychological Stress Events for Interventions in Diabetes Treatment. *Algorithms* **15**(10), <https://doi.org/10.3390/a15100352> (2022).
8. Sevil, M. *et al.* Discrimination of simultaneous psychological and physical stressors using wristband biosignals. *Computer methods and programs in biomedicine* **199**, 105898, <https://doi.org/10.1016/j.cmpb.2020.105898> (2021).
9. Sevil, M. Physical Activity and Psychological Stress Detection and Assessment of Their Effects on Glucose Concentration Predictions in Diabetes Management. *IEEE Transactions on Bio-Medical Engineering* **68**, 2251–2260, <https://doi.org/10.1109/TBME.2020.3049109> (2021).
10. Schmidt, P., Reiss, A., Duerichen, R., Marberger, C. & Van Laerhoven, K. Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection. *Proceedings of the 20th ACM International Conference on Multimodal Interaction*. 400–408 <https://doi.org/10.1145/3242969.3242985> (2018).
11. Anwar, T. & Zakir, S. Machine Learning Based Real-Time Diagnosis of Mental Stress Using Photoplethysmography. *Journal of Biomimetics, Biomaterials and Biomedical Engineering* **55**, 154–167, <https://doi.org/10.4028/p-01r9mn> (2022).
12. Izzah, N., Sutarto, A. P. & Hariyadi, M. Machine Learning models for the Cognitive Stress Detection Using Heart Rate Variability Signals. *Jurnal Teknik Industri: Jurnal Keilmuan Dan Aplikasi Teknik Industri* **24**, 83–94, <https://doi.org/10.9744/jti.24.2.83-94> (2022).
13. Markova, V., Ganchev, T. & Kalinkov, K. CLAS: A Database for Cognitive Load, Affect and Stress Recognition. *2019 International Conference on Biomedical Innovations and Applications (BIA)*. 1–4, <https://doi.org/10.1109/BIA48344.2019.8967457> (2019).
14. Beh, W.-K., Wu, Y.-H., An-Yeu, & Wu. MAUS: A Dataset for Mental Workload Assessment on N-back Task Using Wearable Sensor. *IEEE Dataport*. <https://doi.org/10.21227/q4td-yd35> (2021).
15. Chaptoukaev, H. *et al.* StressID: a Multimodal Dataset for Stress Identification. *Advances in Neural Information Processing Systems* **36**, 29798–29811 (2023).
16. Amin, M. R., Wickramasuriya, D. S. & Faghih, R. T. A Wearable Exam Stress Dataset for Predicting Grades using Physiological Signals. *Healthcare Innovations and Point of Care Technologies Conference, HI-POCT 2022*. 30–36, <https://doi.org/10.1109/HI-POCT54491.2022.9744065> (2022).
17. Healey, J. A. & Picard, R. W. Detecting stress during real-world driving tasks using physiological sensors. *IEEE Transactions on Intelligent Transportation Systems* **6**, 156–166, <https://doi.org/10.1109/TITS.2005.848368> (2005).
18. Rossi, A. *et al.* A Public Dataset of 24-h Multi-Levels Psycho-Physiological Responses in Young Healthy Adults. *Data* **5**(4), <https://doi.org/10.3390/data5040091> (2020).

	Feature Set	Accuracy	Precision	Recall	F1
Stress / Rest	hr_mean, mean_raw_eda, mean_tonic_eda, std_tonic_eda, mean_recoverytime, max_ibi, ibi_mean, rmssd, ratio, LF_peak, x_std, y_std, z_std	93%	93%	92%	92%
Aerobic / Sprints	hr_std, std_phasic_eda, tonic_ratio_down, peaks_density, mean_recoverytime, min_ibi, pnn50, VHF_power, LF_n, z_std, acc_mean, acc_ratio_down	91%	92%	92%	91%
Stress / Rest / Aerobic / Sprints	hr_mean, hr_std, mean_tonic_eda, std_tonic_eda, mean_recoverytime, std_phasic_eda, tonic_ratio_down, peaks_density, max_ibi, ibi_mean, rmssd, min_ibi, LF_peak, LF_n, x_std, y_std, z_std, acc_mean, acc_ratio_down	84%	85%	84%	84%

표 4. 10겹 교차 검증을 통한 XGBoost 성능 지표

이진 스트레스 분류 및 신호로부터의 특징 추출에 대한 파일럿 결과가 회의에서 발표되었습니다^{37,38}. 이 연구에서 제시된 다중 모드 분류는 분류를 확장하여 수집된 데이터를 기반으로 유산소 운동과 무산소 운동을 비롯한 다양한 생리적 상태를 감지하고 구별합니다.

제한사항(이러한 문제에 대한 세부정보는 data_constraints.txt에서 확인할 수 있습니다):

- 스트레스 세션: S02에 중복된 데이터가 있습니다. f07이 손목 밴드 보호 커버를 제거하지 않았으므로 모든 신호가 유효하지는 않습니다. f14의 데이터는 두 부분으로 나뉩니다.
- 유산소 세션: S03 및 S07이 절차를 완료할 수 없습니다. S11의 데이터는 두 부분으로 나뉩니다. S12는 이 테스트를 수행하지 않았습니다.
- 무산소 세션: S06이 절차를 완료할 수 없습니다. S16의 데이터는 두 부분으로 나뉩니다.

코드 가용성

데이터를 열고, 읽고, 시각화할 수 있는 Jupyter Notebook(Wearable_Dataset.ipynb)이 제공됩니다. 이는 PhysioNet³²(<https://doi.org/10.13026/zzf8-xv61>), Repositorio Institucional CONICET Digital³³(<http://hdl.handle.net/11336/245570>) 및 Zenodo³⁴에서 다운로드할 수 있습니다. (<https://doi.org/10.5281/zenodo.13993658>). 노트북을 실행하려면 pandas, os, numpy, time, matplotlib 등 기본 Python 라이브러리가 설치되어 있는지 확인하세요.

접수일: 2024년 11월 18일; 승인: 2025년 3월 17일; 게시일: 2025년 3월 28일

참고자료

1. Tagougui, S. 외. 제1형 당뇨병 환자의 인공 웨장 시스템 및 신체 활동: 과제, 채택된 접근 방식 및 향후 전망. 당뇨병 과학 및 기술 저널 13, 1077–1090, <https://doi.org/10.1177/1932296819869310> (2019).
2. Riddell, M., Zaharieva, D., Yavelberg, L., Cinar, A. & Jamnik, V. 인공 웨장의 운동 및 개발: 더 어려운 일련의 장애물 중 하나. 당뇨병 과학 및 기술 저널. 9 <https://doi.org/10.1177/1932296815609370> (2015).
3. Abdel-Latif, M.M. 외. 자동화된 인슐린 전달을 위해 설명 가능한 인공지능을 사용한 급성 심리적 스트레스 감지. 신호 5, 494–507, <https://doi.org/10.3390/signals5030026> (2024).
4. D Crosswell, A. & Lockwood, G. K. 스트레스 측정 방법 사례: 건강 연구에서 심리적 스트레스를 측정하는 방법. 건강심리학 오픈. 7(2), <https://doi.org/10.1177/2055102920933072> (2020).
5. Iqbal, T. et al. 연결된 예방 의료에 대한 스트레스의 생물생리학적 및 생화학적 지표에 대한 검토. 진단. 11, <https://doi.org/10.3390/diagnostics11030556> (2021).
6. Abdel-Latif, M. 외. 고급 당뇨병 치료를 위한 신체 활동과 급성 심리적 스트레스의 다중 작업 분류. 신호 4, 167–192, <https://doi.org/10.3390/signals4010009> (2023).
7. Askari, M. R., Abdel-Latif, M., Rashid, M., Sevil, M. & Cinar, A. 당뇨병 치료 중재를 위한 예고되지 않은 신체 활동 및 급성 심리적 스트레스 사건의 감지 및 분류. 알고리즘. 15(10), <https://doi.org/10.3390/a15100352> (2022).
8. Sevil, M. et al. 손목밴드 생체신호를 이용한 심리적, 육체적 동시 스트레스 요인 식별. 생물 의학의 컴퓨터 방법 및 프로그램 199, 105898, <https://doi.org/10.1016/j.cmpb.2020.105898> (2021).
9. Sevil, M. 신체 활동 및 심리적 스트레스 감지 및 당뇨병 관리에서 포도당 농도 예측에 미치는 영향 평가. 생명 의공학 공학에 관한 IEEE 거래 68, 2251–2260, <https://doi.org/10.1109/TBME.2020.3049109> (2021).
10. Schmidt, P., Reiss, A., Duerichen, R., Marberger, C. & Van Laerhoven, K. 웨어러블 스트레스 및 영향 감지를 위한 다중 모드 데이터 세트인 WESAD를 소개합니다. 다중 모드 상호 작용에 관한 제20회 ACM 국제 컨퍼런스 진행. 400–408 <https://doi.org/10.1145/3242969.3242985> (2018).
11. Anwar, T. & Zakir, S. 광역적 맥락적 정보를 이용한 정신적 스트레스의 기계 학습 기반 실시간 진단. 생체모방학, 생체재료 및 생체의학 공학 저널. 55, 154–167, <https://doi.org/10.4028/p-01r9mn> (2022).
12. Izzah, N., Sutarto, A. P. & Hariyadi, M. 심박수 변이도 신호를 사용한 인지 스트레스 감지를 위한 기계 학습 모델. Jurnal Teknik Industri: Jurnal Keilmuan Dan Aplikasi Teknik Industri 24, 83–94, <https://doi.org/10.9744/jti.24.2.83-94> (2022).
13. Markova, V., Ganchev, T. & Kalinkov, K. CLAS: 인지 부하, 영향 및 스트레스 인식을 위한 데이터베이스. 2019 생물 의학 혁신 및 응용에 관한 국제 컨퍼런스(BIA). 1–4, <https://doi.org/10.1109/BIA48344.2019.8967457> (2019).
14. Beh, W.-K., Wu, Y.-H., An-Yeu, & Wu. MAUS: 웨어러블 센서를 이용한 N-back 작업에 대한 정신 작업 부하 평가를 위한 데이터 세트. IEEE 데이터포트. <https://doi.org/10.21227/q4td-yd35> (2021).
15. Chaptoukaev, H. 외. StressID: 스트레스 식별을 위한 다중 모드 데이터 세트입니다. 신경 정보 처리 시스템의 발전 36, 29798–29811(2023).
16. Amin, M. R., Wickramasuriya, D. S. & Faghieh, R. T. 생리학적 신호를 사용하여 등급을 예측하기 위한 웨어러블 시험 스트레스 데이터 세트. 의료 혁신 및 현장 진료 기술 컨퍼런스, HI-POCT 2022. 30–36, <https://doi.org/10.1109/HI-POCT54491.2022.9744065> (2022).
17. Healey, J. A. & Picard, R. W. 생리학적 센서를 사용하여 실제 운전 작업 중 스트레스를 감지합니다. 지능형 교통 시스템에 관한 IEEE 거래 6, 156–166, <https://doi.org/10.1109/TITS.2005.848368> (2005).
18. Rossi, A. et al 건강한 젊은 성인의 24시간 다단계 정신-생리학적 반응에 대한 공개 데이터세트. 데이터. 5(4), <https://doi.org/10.3390/data5040091> (2020).

19. Mehrgardt, P., Matloob, K., Poon, S. & Withana, A. Pulse Transit Time PPG Dataset (version 1.1.0). *PhysioNet*. <https://doi.org/10.13026/jpan-6n92> (2022).
20. Karas, M., Urbanek, J., Crainiceanu, C., Harezlak, J. & Fadel, W. Labeled raw accelerometry data captured during walking, stair climbing and driving (version 1.0.0). *PhysioNet*. <https://doi.org/10.13026/51h0-a262> (2021).
21. Banos, O., Toth, M. & Amft, O. REALDISP Activity Recognition Dataset. *UCI Machine Learning Repository*. <https://doi.org/10.24432/C5GP6D> (2012).
22. Cleland, I., Donnelly, M. P., Nugent, C. D., Hallberg, J., Espinilla, M. & Garcia-Constantino, M. Collection of a Diverse, Realistic and Annotated Dataset for Wearable Activity Recognition. *2018 IEEE International Conference on Pervasive Computing and Communications Workshops (PerCom Workshops)*. 555–560, <https://doi.org/10.1109/PERCOMW.2018.8480322> (2018).
23. Birjandtalab, J., Cogan, D., Pouyan, M. B. & Nourani, M. A Non-EEG Biosignals Dataset for Assessment and Visualization of Neurological Status. *2016 IEEE International Workshop on Signal Processing Systems (SiPS)*. 110–114, <https://doi.org/10.1109/SiPS.2016.27> (2016).
24. Parent, M. et al. PASS: A Multimodal Database of Physical Activity and Stress for Mobile Passive Body/ Brain-Computer Interface Research. *Frontiers in Neuroscience*. **14**, <https://doi.org/10.3389/fnins.2020.542934> (2020).
25. Stroop, J. Studies of Interference in Serial Verbal Reactions. *Journal of Experimental Psychology: General*. **121**, 15–23, <https://doi.org/10.1037/0096-3445.121.1.15> (1992).
26. Macleod, C. Half A Century of Research on the Stroop Effect - An Integrative Review. *Psychological Bulletin* **109**, 163–203, <https://doi.org/10.1037/0033-2909.109.2.163> (1991).
27. Stoet, G. PsyToolkit - A software package for programming psychological experiments using Linux. *Behavior Research Methods* **42**, 1096–1104, <https://doi.org/10.3758/BRM.42.4.1096> (2010).
28. Stoet, G. PsyToolkit: A novel web-based method for running online questionnaires and reaction-time experiments. *Teaching of Psychology* **44**, 24–31, <https://doi.org/10.1177/0098628316677643> (2017).
29. Pruessner, J. C., Hellhammer, D. H. & Kirschbaum, C. Low self-esteem, induced failure and the adrenocortical stress response. *Personality and Individual Differences* **27**, 477–489, [https://doi.org/10.1016/S0191-8869\(98\)00256-6](https://doi.org/10.1016/S0191-8869(98)00256-6) (1999).
30. Inbar, O., Bar-Or, O. & Skinner, J. S. *The Wingate Anaerobic Test*. (Human Kinetics, 1996)
31. Harris, G. D. in *Exercise Stress Testing for Primary Care and Sports Medicine* (ed. B.C.H. Evans & R.D. White) Ch. 3 (Springer, 2009)
32. Hongn, A., Bosch, F., Prado, L. & Bonomini, P. Wearable Device Dataset from Induced Stress and Structured Exercise Sessions (version 1.0.0). *PhysioNet*. <https://doi.org/10.13026/zzf8-xv61>. (2025).
33. Hongn, A., Bosch, F., Prado, L. E. & Bonomini, M. P. Wearable Device Dataset from Induced Stress and Structured Exercise Sessions. *Consejo Nacional de Investigaciones Científicas y Técnicas*. <http://hdl.handle.net/11336/245570>. (2024)
34. Hongn, A., Bosch, F., Prado, L. E. & Bonomini, M. P. Wearable Device Dataset from Induced Stress and Structured Exercise Sessions (Version 1.0.0) *Zenodo*. <https://doi.org/10.5281/zenodo.13993657>. (2024)
35. Makowski, D. et al. NeuroKit2: A Python toolbox for neurophysiological signal processing. *Behavior Research Methods* **53**, 1689–1696, <https://doi.org/10.3758/s13428-020-01516-y> (2021).
36. Kavsaoğlu, A., Polat, K. & Bozkurt, M. An innovative peak detection algorithm for photoplethysmography signals: An adaptive segmentation method. *Turkish Journal of Electrical Engineering and Computer Sciences* **24**, 1782–1796, <https://doi.org/10.3906/elk-1310-177> (2016).
37. Hongn, A., Prado, L. E., Bosch, F. & Bonomini, M. P. Wearable Device Dataset for Stress Detection. *Bioinspired Systems for Translational Applications: From Robotics to Social Engineering (Conference Proceedings)*. 518–527, https://doi.org/10.1007/978-3-031-61137-7_49 (2024).
38. Hongn, A., Bosch, F., Prado, L. E., Ferrández, J. M. & Bonomini, M. P. Non-invasive Recording of Physiological Variables Under Stress Conditions and Aerobic and Anaerobic Physical Activity. *Advances in Bioengineering and Clinical Engineering (Conference paper)*. 30–39, https://doi.org/10.1007/978-3-031-61973-1_4 (2024).

This research has been funded by European Commission HORIZON-MSCA-2022-SE-01 EPISTEAM and partially supported by Programa Iberoamericano de Ciencia y Tecnología para el Desarrollo (CYTED) (through Red 225RT0169).

All authors participated in the design of the study protocol. A.H., F.B. and L.E.P. conducted the data collection and performed the technical validation. A.H. made data publicly available and drafted the manuscript. J.M.F. and M.P.B. supervised the project and reviewed the manuscript.

Competing interests

The authors declare no competing interests.

Additional information

Correspondence and requests for materials should be addressed to A.H.

Reprints and permissions information is available at www.nature.com/reprints.

Publisher's note Springer Nature remains neutral with regard to jurisdictional claims in published maps and institutional affiliations.



Open Access This article is licensed under a Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License, which permits any non-commercial use, sharing, distribution and reproduction in any medium or format, as long as you give appropriate credit to the original author(s) and the source, provide a link to the Creative Commons licence, and indicate if you modified the licensed material. You do not have permission under this licence to share adapted material derived from this article or parts of it. The images or other third party material in this article are included in the article's Creative Commons licence, unless indicated otherwise in a credit line to the material. If material is not included in the article's Creative Commons licence and your intended use is not permitted by statutory regulation or exceeds the permitted use, you will need to obtain permission directly from the copyright holder. To view a copy of this licence, visit <http://creativecommons.org/licenses/by-nc-nd/4.0/>.

© The Author(s) 2025, corrected publication 2025

19. Mehrgardt, P., Matloob, K., Poon, S. & Withana, A. 펄스 전송 시간 PPG 데이터세트(버전 1.1.0). 피지오넷. <https://doi.org/10.13026/jpan-6n92> (2022).
20. Karas, M., Urbanek, J., Crainiceanu, C., Harezlak, J. & Fadel, W. 걷기, 계단 오르기 및 운전 중에 캡처된 라벨이 붙은 원시 가속도 측정 데이터(버전 1.0.0). 피지오넷. <https://doi.org/10.13026/51h0-a262> (2021).
21. Banos, O., Toth, M. & Amft, O. REALDISP 활동 인식 데이터세트. UCI 머신러닝 저장소. <https://doi.org/10.24432/C5GP6D> (2012).
22. Cleland, I., Donnelly, M. P., Nugent, C. D., Hallberg, J., Espinilla, M. & Garcia-Constantino, M. 웨어러블 활동 인식을 위한 다양하고 현실적이며 주석이 달린 데이터 세트 컬렉션. 퍼베이시브 컴퓨팅 및 통신 워크숍에 관한 2018 IEEE 국제 회의(PerCom 워크숍). 555–560, <https://doi.org/10.1109/PERCOMW.2018.8480322> (2018).
23. Birjandtalab, J., Cogan, D., Pouyan, M. B. & Nourani, M. A. 신경학적 상태 평가 및 시각화를 위한 비EEG 생체 신호 데이터세트. 신호 처리 시스템(SiPS)에 관한 2016 IEEE 국제 워크숍. 110–114, <https://doi.org/10.1109/SiPS.2016.27> (2016).
24. 부모, M. 외. PASS: 이동식 수동 신체/뇌-컴퓨터 인터페이스 연구를 위한 신체 활동 및 스트레스의 다중 모드 데이터베이스. 신경과학의 개척지. 14, <https://doi.org/10.3389/fnins.2020.542934> (2020).
25. Stroop, J. 연속 언어 반응의 간섭 연구. 실험 심리학 저널: 일반. 121, 15–23, <https://doi.org/10.1037/0096-3445.121.1.15> (1992).
26. Macleod, C. 스트루프 효과에 대한 반세기 연구 - 통합적 검토. 심리 계사관 109, 163–203, <https://doi.org/10.1037/0033-2909.109.2.163> (1991).
27. Stoet, G. PsyToolkit - Linux를 사용하여 심리 실험을 프로그래밍하기 위한 소프트웨어 패키지입니다. 행동 연구 방법 42, 1096–1104, <https://doi.org/10.3758/BRM.42.4.1096> (2010).
28. Stoet, G. PsyToolkit: 온라인 설문지 및 반응 시간 실험을 실행하기 위한 새로운 웹 기반 방법. 심리학 교육 44, 24–31, <https://doi.org/10.1177/0098628316677643> (2017).
29. Pruessner, J. C., Hellhammer, D. H. & Kirschbaum, C. 낮은 자존감, 유도된 실패 및 부신피질 스트레스 반응. 성격과 개인차 27, 477–489, [https://doi.org/10.1016/S0191-8869\(98\)00256-6](https://doi.org/10.1016/S0191-8869(98)00256-6) (1999).
30. Inbar, O., Bar-Or, O. & Skinner, J. S. Wingate 무산소 테스트. (Human Kinetics, 1996).
31. Harris, G. D. 일차 의료 및 스포츠 의학을 위한 운동 스트레스 테스트(ed. B.C.H. Evans & R.D. White) Ch. 3 (Springer, 2009).
32. Hongn, A., Bosch, F., Prado, L. & Bonomini, M. 유도된 스트레스 및 구조화된 운동 세션에서 얻은 웨어러블 장치 데이터 세트(버전 1.0.0). 피지오넷. <https://doi.org/10.13026/zzf8-xv61> (2025).
33. Hongn, A., Bosch, F., Prado, L. E. & Bonomini, M. P. 유도된 스트레스 및 구조화된 운동 세션에서 얻은 웨어러블 장치 데이터세트. Consejo Nacional de Investigaciones Científicas y Técnicas. <http://hdl.handle.net/11336/245570>. (2024).
34. Hongn, A., Bosch, F., Prado, L. E. & Bonomini, M. P. 유도된 스트레스 및 구조화된 운동 세션의 웨어러블 장치 데이터세트(버전 1.0.0) Zenodo. <https://doi.org/10.5281/zenodo.13993657>. (2024).
35. Makowski, D. et al. NeuroKit2: 신경 생리학적 신호 처리를 위한 Python 도구 상자입니다. 행동 연구 방법 53, 1689–1696, <https://doi.org/10.3758/s13428-020-01516-y> (2021).
36. Kavsaoğlu, A., Polat, K. & Bozkurt, M. 광용적맥파 신호를 위한 혁신적인 피크 감지 알고리즘: 적응형 분할 방법. 터키 전기 공학 및 컴퓨터 과학 저널 24, 1782–1796, <https://doi.org/10.3906/elk-1310-177> (2016).
37. Hongn, A., Prado, L. E., Bosch, F. & Bonomini, M. P. 스트레스 감지를 위한 웨어러블 장치 데이터세트. 중개 응용을 위한 생체모방 시스템: 로봇 공학에서 사회 공학까지(회의 논문집). 518–527, https://doi.org/10.1007/978-3-031-61137-7_49 (2024).
38. Hongn, A., Bosch, F., Prado, L. E., Ferrández, J. M. & Bonomini, M. P. 스트레스 조건 및 유산소 및 무산소 신체 활동 하에서 생리적 변수의 비침습적 기록. 생명공학 및 임상공학의 발전(컨퍼런스 논문). 30–39, https://doi.org/10.1007/978-3-031-61973-1_4 (2024).

감사의 말

이 연구는 유럽 위원회 HORIZON-MSCA-2022-SE-01 EPISTEAM의 자금 지원을 받았으며 Programa Iberoamericano de Ciencia y Tecnología para el Desarrollo(CYTED)(Red 225RT0169를 통해)의 일부 지원을 받았습니다.

저자 기여

모든 저자는 연구 프로토콜 설계에 참여했습니다. A.H., F.B. 그리고 L.E.P. 데이터 수집을 수행하고 기술 검증을 수행했습니다. A.H.는 데이터를 공개하고 원고 초안을 작성했습니다. J.M.F. 그리고 M.P.B. 프로젝트를 감독하고 원고를 검토했습니다.

이해관계 경쟁

저자는 경쟁적 이익을 선언하지 않습니다.

추가 정보

공통된 및 자료요청은 A.H로 해주시기 바랍니다.

재인쇄 및 허가 정보는 www.nature.com/reprints에서 확인할 수 있습니다.

발행인의 메모 Springer Nature는 발행된 지도 및 기관 제후에 대한 관할권 주장과 관련하여 중립을 유지합니다.

 오픈 액세스(Open Access) 이 기사는 Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License에 따라 라이선스가 부여되었으며, 이는 모든 비상업적 사용, 공인본 저작자와, 변경을 허용하지 않고 크리에이티브 커먼즈 라이선스에 대한 링크를 제공하고 라이선스 자료를 수정했는지 표시하는 한 모든 매체나 형식으로 복제 및 복제할 수 있습니다. 귀하는 이 기사 또는 그 일부에서 파생된 자료를 공유할 수 있는 라이선스에 따른 권한이 없습니다. 이 기사에 포함된 이미지 또는 기타 제3자 자료는 자료에 대한 크레딧 라인에 달리 명시되지 않는 한 기사의 크리에이티브 커먼즈 라이선스에 포함되어 있습니다. 자료가 기사의 크리에이티브 커먼즈 라이선스에 포함되어 있지 않고 귀하의 의도된 사용이 법적 규정에 의해 허용되지 않거나 허용된 사용을 초과하는 경우 저작권 보유자로부터 직접 허가를 받아야 합니다. 이 라이선스의 사본을 보려면 <http://creativecommons.org/licenses/by-nc-nd/4.0/>을 방문하십시오.